

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Data

Data yang digunakan dalam penelitian ini merupakan citra satelit Landsat 9 TOA (*Top of Atmosphere*) dengan resolusi spasial 30 meter yang diperoleh melalui platform *Google Earth Engine*. Citra yang digunakan terdiri dari dua kondisi, yaitu sebelum kejadian kebakaran (*prefire*) dan setelah kejadian kebakaran (*postfire*), yang mencakup *pathrow*, yaitu 124062 dan 125062. Rentang waktu untuk kondisi *prefire* pada rentang antara tanggal 1 Januari 2023 hingga 30 Juli 2023, sedangkan untuk kondisi *postfire* pada rentang antara 1 November 2023 hingga 30 Juni 2024.

Pada Tabel 4.1, menunjukkan citra yang tersedia pada kondisi *prefire* di *pathrow* 124062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 26 Juli 2023 dengan persentase *cloud cover* sebesar 14.07%.

Tabel 4.1 Daftar citra Landsat 9 TOA *pathrow* 124062 kondisi *Prefire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
124062	Prefire	2023-07-26	14.07	LC09_L1TP_124062_20230726_20230726_02_T1
124062	Prefire	2023-04-21	29.16	LC09_L1TP_124062_20230421_20230421_02_T1
124062	Prefire	2023-06-24	33.04	LC09_L1TP_124062_20230624_20230624_02_T1
124062	Prefire	2023-03-20	54.76	LC09_L1TP_124062_20230320_20230320_02_T1
124062	Prefire	2023-04-05	56.74	LC09_L1TP_124062_20230405_20230405_02_T1
124062	Prefire	2023-05-23	57.75	LC09_L1TP_124062_20230523_20230523_02_T1
124062	Prefire	2023-07-10	83.95	LC09_L1TP_124062_20230710_20230710_02_T1
124062	Prefire	2023-01-15	84.48	LC09_L1TP_124062_20230115_20230313_02_T1
124062	Prefire	2023-02-16	86.69	LC09_L1TP_124062_20230216_20230310_02_T1
124062	Prefire	2023-06-08	93.87	LC09_L1TP_124062_20230608_20230608_02_T1
124062	Prefire	2023-05-07	100.00	LC09_L1TP_124062_20230507_20230507_02_T1
124062	Prefire	2023-03-04	100.00	LC09_L1TP_124062_20230304_20230307_02_T1

Pada Tabel 4.2, menunjukkan citra yang tersedia pada kondisi *prefire* di *pathrow* 125062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 14 Mei 2023 dengan persentase *cloud cover* sebesar 26.38%.

Tabel 4.2 Daftar citra Landsat 9 TOA *pathrow* 125062 kondisi *Prefire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
125062	Prefire	2023-05-14	26.38	LC09_L1TP_125062_20230514_20230514_02_T1
125062	Prefire	2023-01-22	50.78	LC09_L1TP_125062_20230122_20230313_02_T1
125062	Prefire	2023-06-15	65.17	LC09_L1TP_125062_20230615_20230615_02_T1
125062	Prefire	2023-04-12	66.80	LC09_L1TP_125062_20230412_20230412_02_T1
125062	Prefire	2023-01-06	73.91	LC09_L1TP_125062_20230106_20230314_02_T1
125062	Prefire	2023-04-28	75.61	LC09_L1TP_125062_20230428_20230428_02_T1
125062	Prefire	2023-02-07	87.14	LC09_L1TP_125062_20230207_20230310_02_T1
125062	Prefire	2023-07-01	90.55	LC09_L1TP_125062_20230701_20230701_02_T1
125062	Prefire	2023-05-30	91.37	LC09_L1TP_125062_20230530_20230530_02_T1
125062	Prefire	2023-03-27	92.76	LC09_L1TP_125062_20230327_20230327_02_T1
125062	Prefire	2023-07-17	95.70	LC09_L1TP_125062_20230717_20230717_02_T1

Pada Tabel 4.3, menunjukkan citra yang tersedia pada kondisi *postfire* di *pathrow* 124062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 9 Mei 2024 dengan persentase *cloud cover* sebesar 7.42%.

Tabel 4.3 Daftar citra Landsat 9 TOA *pathrow* 124062 kondisi *Postfire*

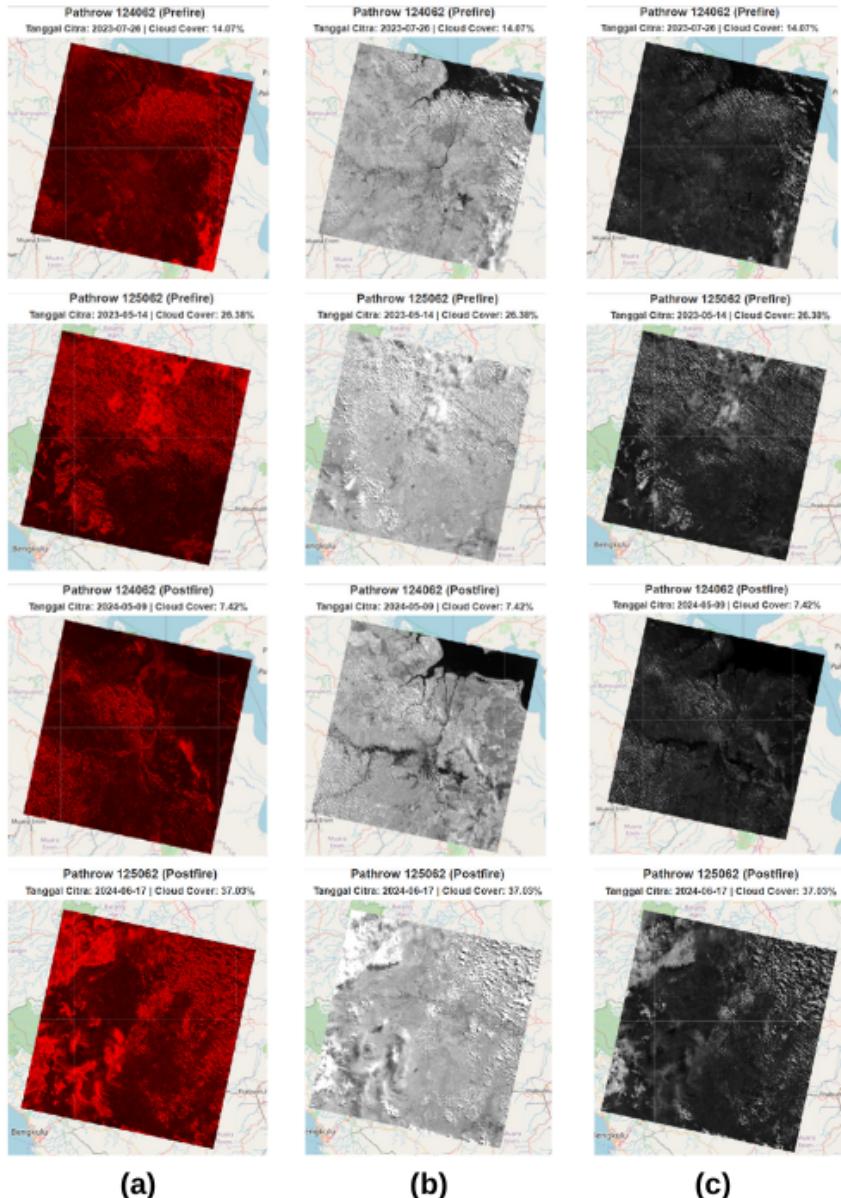
<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
124062	Postfire	2024-05-09	7.42	LC09_L1TP_124062_20240509_20240509_02_T1
124062	Postfire	2024-06-10	17.72	LC09_L1TP_124062_20240610_20240610_02_T1
124062	Postfire	2023-11-15	23.63	LC09_L1TP_124062_20231115_20231115_02_T1
124062	Postfire	2024-06-26	38.13	LC09_L1TP_124062_20240626_20240626_02_T1
124062	Postfire	2024-03-22	44.23	LC09_L1TP_124062_20240322_20240322_02_T1
124062	Postfire	2024-05-25	50.42	LC09_L1TP_124062_20240525_20240525_02_T1
124062	Postfire	2024-02-19	51.83	LC09_L1TP_124062_20240219_20240219_02_T1
124062	Postfire	2024-04-23	52.63	LC09_L1TP_124062_20240423_20240423_02_T1
124062	Postfire	2023-12-17	69.01	LC09_L1TP_124062_20231217_20231217_02_T1
124062	Postfire	2024-03-06	96.90	LC09_L1TP_124062_20240306_20240306_02_T1

Pada Tabel 4.4, menunjukkan citra yang tersedia pada kondisi *postfire* di *pathrow* 125062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 17 Juni 2024 dengan persentase *cloud cover* sebesar 37.03%.

Tabel 4.4 Daftar citra Landsat 9 TOA *pathrow* 125062 kondisi *Postfire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
125062	Postfire	2024-06-17	37.03	LC09_L1TP_125062_20240617_20240617_02_T1
125062	Postfire	2023-11-06	41.67	LC09_L1TP_125062_20231106_20231106_02_T1
125062	Postfire	2024-04-30	43.43	LC09_L1TP_125062_20240430_20240430_02_T1
125062	Postfire	2024-03-29	46.65	LC09_L1TP_125062_20240329_20240329_02_T1
125062	Postfire	2024-05-16	48.69	LC09_L1TP_125062_20240516_20240516_02_T1
125062	Postfire	2024-04-14	58.24	LC09_L1TP_125062_20240414_20240414_02_T1
125062	Postfire	2023-12-08	69.28	LC09_L1TP_125062_20231208_20231208_02_T1
125062	Postfire	2024-01-09	77.90	LC09_L1TP_125062_20240109_20240109_02_T1
125062	Postfire	2024-02-26	80.47	LC09_L1TP_125062_20240226_20240226_02_T1
125062	Postfire	2024-01-25	81.34	LC09_L1TP_125062_20240125_20240125_02_T1
125062	Postfire	2024-03-13	92.27	LC09_L1TP_125062_20240313_20240313_02_T1
125062	Postfire	2023-11-22	92.79	LC09_L1TP_125062_20231122_20231122_02_T1
125062	Postfire	2023-12-24	100.00	LC09_L1TP_125062_20231224_20231224_02_T1
125062	Postfire	2024-06-01	100.00	LC09_L1TP_125062_20240601_20240601_02_T1

Data yang digunakan dalam penelitian ini menggunakan 3 band utama, yaitu band 4, band 5, dan band 7. Ketiga band tersebut dipilih karena dianggap relevan untuk mendukung tujuan analisis yang dilakukan. Pada Gambar 4.1, visualisasi hasil data raster dari masing-masing band. Gambar 4.1 bagian (a) menunjukkan hasil visualisasi raster pada band 4, sedangkan bagian (b) memperlihatkan visualisasi raster dari band 5. Selanjutnya, Gambar 4.1 bagian (c) menampilkan data raster dari band 7. Setiap visualisasi disusun untuk merepresentasikan kondisi data secara menyeluruh. Visualisasi tersebut mencakup seluruh kombinasi *pathrow* dan kondisi citra yang digunakan dalam penelitian.

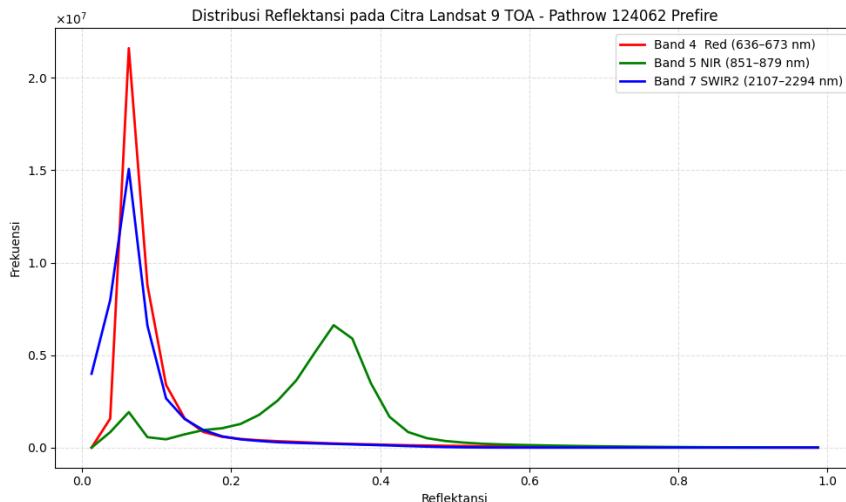


Gambar 4.1 Raster Landsat per band: (a) band 4, (b) band 5 dan (c) band 7

Data yang digunakan telah dikonversi ke reflektansi TOA dalam skala 0 hingga 1, dikarenakan data digunakan diakses melalui *Google Earth Engine* telah dilakukan koreksi radiometrik. Namun pada umumnya, data yang diakses melalui website USGS, perlu dilakukan koreksi radiometrik dikarenakan data masih dalam digital number dengan format 16 bit yang perlu dilakukan konversi ke reflektansi.

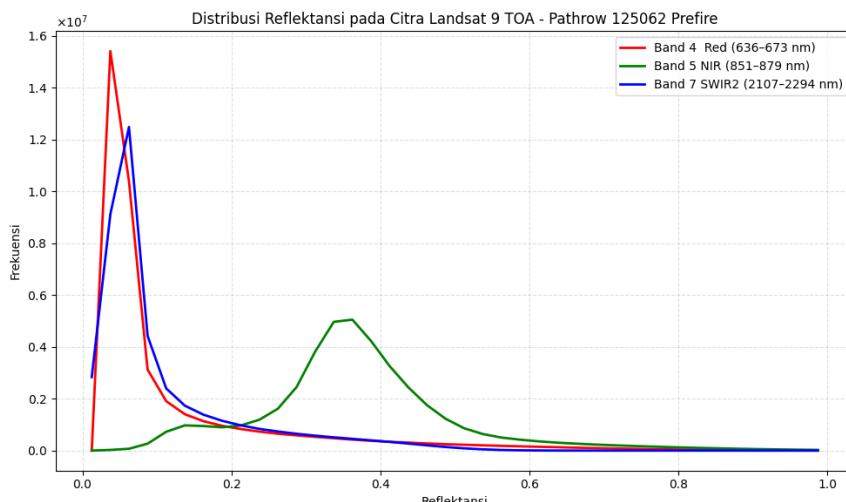
Pada Gambar 4.2 menunjukkan distribusi reflektansi pada kondisi sebelum kebakaran (*prefire*) untuk area *pathrow* 124062. Terlihat bahwa Band 5 (NIR) memiliki dua puncak distribusi, dengan intensitas tertinggi berada di rentang reflektansi sekitar 0.35. Sementara itu,

Band 4 (Red) dan Band 7 (SWIR2) menunjukkan puncak pada nilai reflektansi rendah (sekitar 0.05). Vegetasi cenderung memiliki nilai reflektansi rendah pada SWIR karena penyerapan air dan selulosa dalam jaringan tanaman [38]. Sehingga menunjukkan citra pada kondisi ini masih memiliki dominan masih memiliki vegetasi sehat.



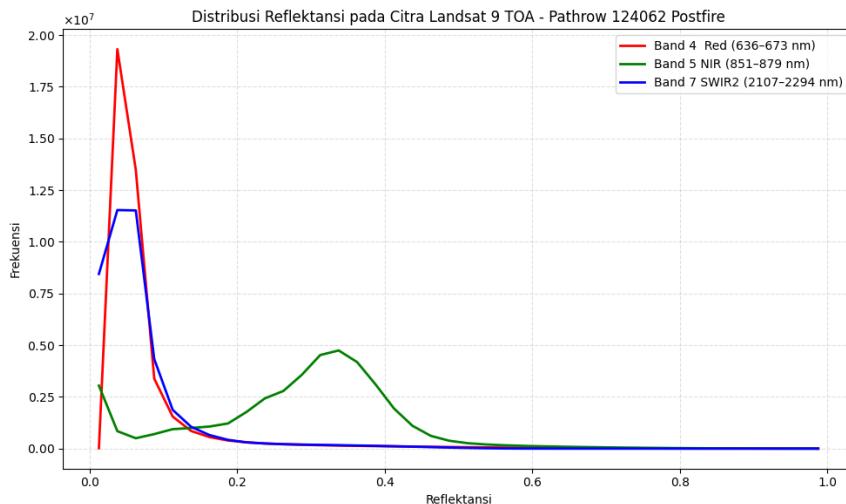
Gambar 4.2 Distribusi reflektansi Pahtrow 124062 - *Prefire*

Sementara itu, Gambar 4.3 juga menunjukkan distribusi reflektansi *prefire* namun untuk area *pathrow* 125062. Pola yang ditampilkan konsisten dengan Gambar 4.2, di mana Band 5 (NIR) kembali mendominasi reflektansi menengah (0.35 – 0.4). Band 4 dan Band 7 juga memiliki puncak di nilai rendah sekitar 0.05, menunjukkan bahwa area ini merupakan dominan masih memiliki vegetasi sehat sama seperti pada Gambar 4.2.



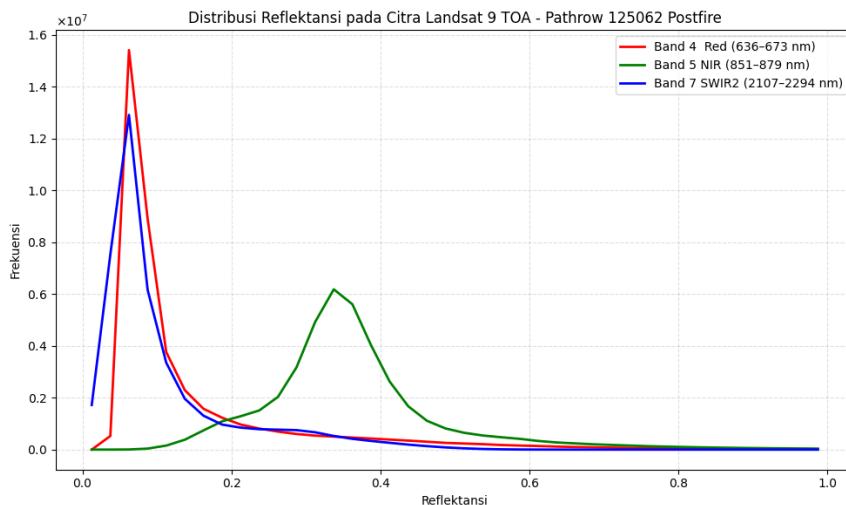
Gambar 4.3 Distribusi reflektansi Pahtrow 125062 - *Prefire*

Pada Gambar 4.4 menunjukkan perubahan penurunan signifikan pada puncak reflektansi Band 5 (NIR) daripada Gambar 4.2. Sementara itu, Band 4 (Red) dan terutama Band 7 (SWIR2) menunjukkan sedikit pergeseran dan penyebaran nilai reflektansi.



Gambar 4.4 Distribusi reflektansi Pahtrow 124062 - Postfire

Namun, Pada Gambar 4.5, terjadi penurunan drastis pada reflektansi NIR, ditandai oleh hilangnya puncak distribusi pada sekitar reflektansi 0.4. Sebaliknya, distribusi band Red dan SWIR2 meningkat pada kisaran reflektansi rendah.



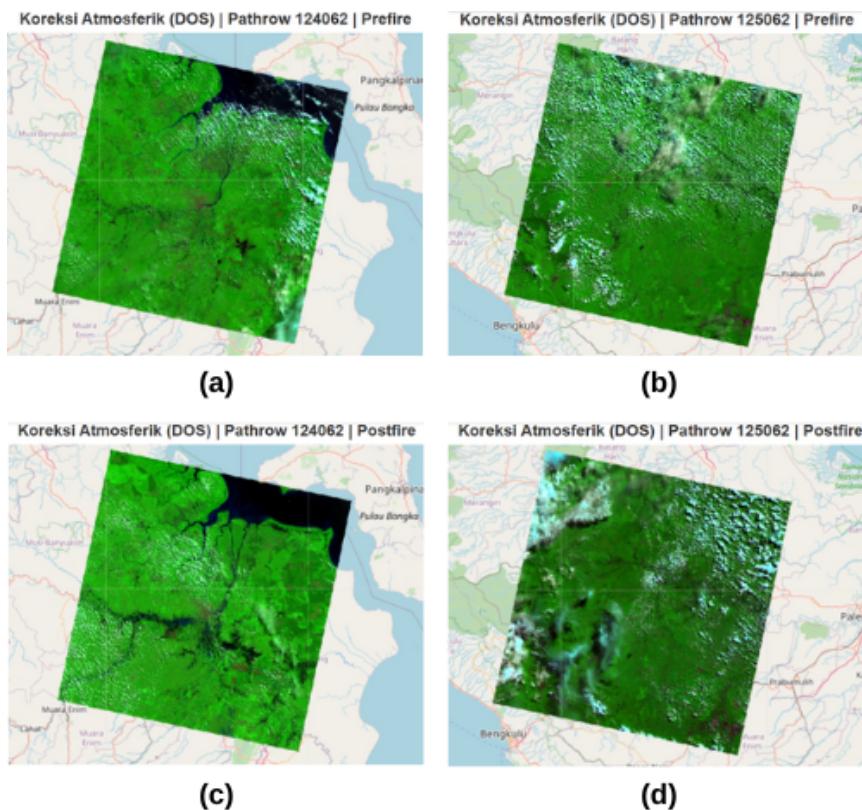
Gambar 4.5 Distribusi reflektansi Pahtrow 125062 - Postfire

4.2 Data Preprocessing

4.2.1 Koreksi Atmosferik

Koreksi atmosferik merupakan tahap penting dalam pra pemrosesan citra satelit untuk menghilangkan pengaruh atmosfer terhadap nilai reflektansi yang terekam sensor. Salah satu metode yang digunakan dalam penelitian ini adalah *Dark Object Subtraction* (DOS). Pada Gambar 4.6 bagian (a) dan (c) menunjukkan hasil dari koreksi atmosferik menggunakan metode DOS di *pathrow* 124062 pada kedua kondisi, serta pada Gambar 4.6 bagian (b) dan (d) menunjukkan hasil dari koreksi atmosferik menggunakan metode DOS di *pathrow* 125062 pada kondisi *prefire* dan *postfire*. Citra ditampilkan dalam komposit *false color* dengan kombinasi Band 7, Band 5, dan Band 4, yang umum digunakan untuk analisis vegetasi karena mampu menampilkan perbedaan tajam antara vegetasi sehat, area terbuka, dan area terbakar.

Pada Gambar 4.6, terlihat pada citra hasil koreksi atmosferik, warna hijau pada vegetasi menjadi lebih jelas dan tajam, menunjukkan bahwa nilai reflektansi telah diperbaiki dan gangguan dari efek atmosfer telah dikurangi. Dengan perbandingan antara kondisi *prefire* dan *postfire* pada masing-masing *pathrow*, khususnya pada *pathrow* 125062 *postfire*, area dengan warna cerah kehijauan pudar dan tampak lebih kasar mengindikasikan adanya degradasi vegetasi atau dampak kebakaran setelah koreksi dilakukan. Secara keseluruhan, penerapan koreksi atmosferik ini penting untuk memastikan bahwa perbandingan nilai reflektansi antar waktu menjadi lebih valid dan dapat digunakan dengan akurat dalam perhitungan indeks spektral seperti NDVI, NBR, dan dNBR.



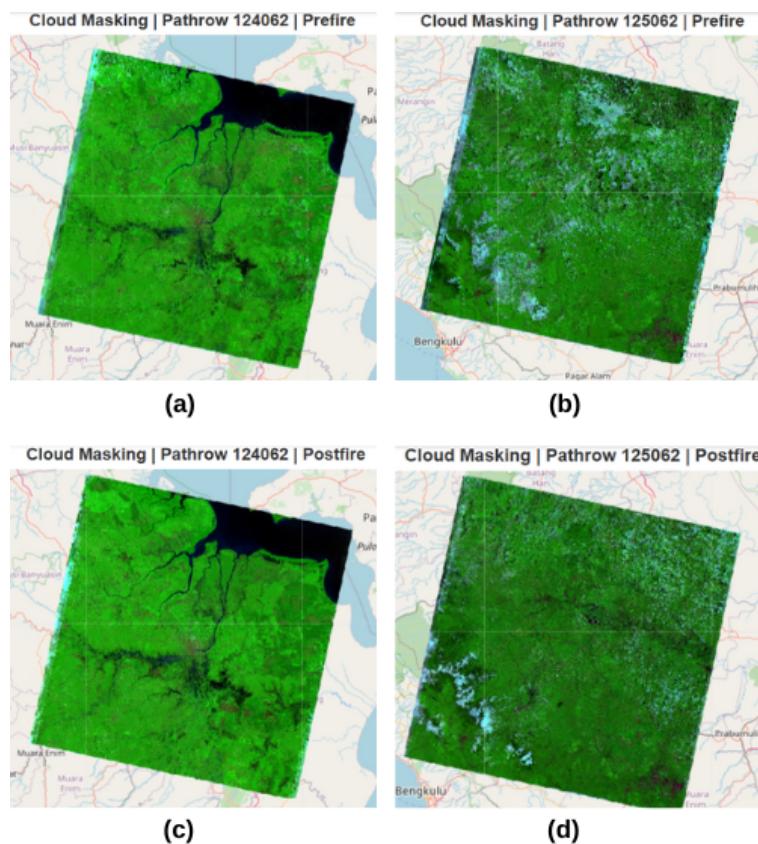
Gambar 4.6 Koreksi Atmosferik (DOS) pada kondisi *prefire* dan *postfire*

4.2.2 *Cloud Masking*

Cloud masking merupakan langkah penting dalam pra-pemrosesan citra satelit untuk mengurangi pengaruh awan dan bayangan awan yang dapat mengganggu akurasi interpretasi spasial maupun spektral. Awan cenderung memiliki reflektansi tinggi pada kanal-kanal tertentu, sehingga keberadaannya dapat menyebabkan distorsi dalam analisis indeks vegetasi maupun deteksi area terbakar. Oleh karena itu, mengidentifikasi dan menghilangkan piksel-piksel yang tertutup awan menjadi bagian krusial sebelum dilakukan analisis lebih lanjut. Dalam penelitian ini, proses *cloud masking* diterapkan pada citra Landsat 9 dengan memanfaatkan *Quality Assessment* (QA) Band, yang menyediakan informasi bitmask tentang kondisi atmosfer dan permukaan pada setiap piksel. Berdasarkan referensi Landsat Collection 2 Level-1 QA_PIXEL, masking dilakukan dengan mempertimbangkan beberapa bit penting berdasarkan Tabel 3.4.

Proses masking dilakukan dengan mempertahankan piksel yang tidak mengandung *fill*, *dilated cloud*, *cirrus*, *cloud*, dan *cloud shadow*, serta

hanya memilih piksel yang ditandai sebagai *clear*. Dengan demikian, hanya piksel yang memiliki kepercayaan tinggi sebagai wilayah bersih yang digunakan dalam proses analisis lanjutan, sementara piksel lain disaring untuk menghindari distorsi data. Pada Gambar 4.7 bagian (a) dan (c) menunjukkan hasil dari proses cloud masking di *pathrow* 124062 pada kondisi *prefire* dan *postfire*, serta Pada Gambar 4.7 bagian (b) dan (d) menunjukkan hasil dari proses *cloud masking* di *pathrow* 125062 pada kedua kondisi. Citra ditampilkan dalam komposit *false color*, yang efektif dalam menyorot vegetasi dan perubahan akibat kebakaran. Sebelum dilakukan masking, area seperti *pathrow* 125062 *postfire* menunjukkan tutupan awan dan bayangan yang luas. Setelah proses masking, area tersebut berhasil diminimalkan. Meskipun tidak semua gangguan atmosfer dapat dihilangkan.

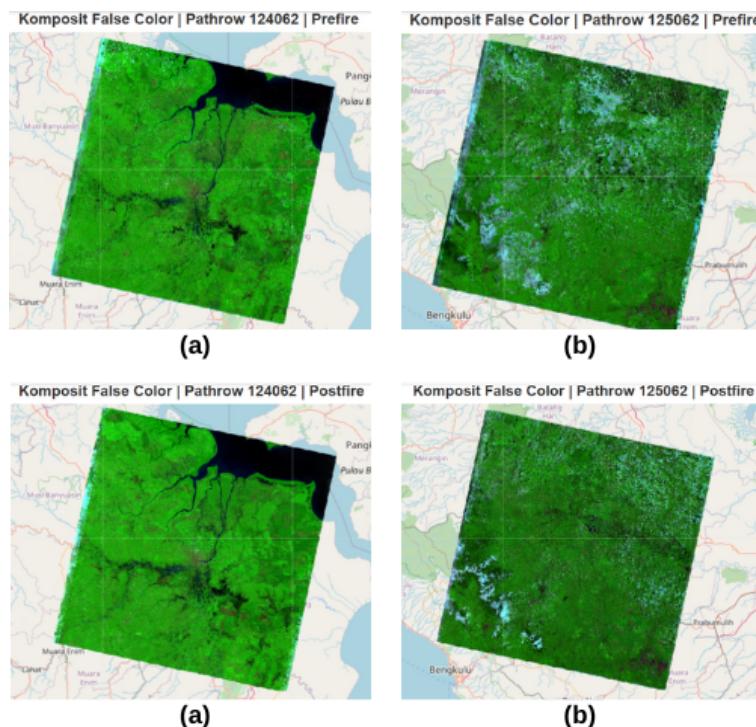


Gambar 4.7 Cloud Masking (QA Bands) pada kondisi *prefire* dan *postfire*

4.2.3 Komposit Citra

Proses komposit citra digunakan sebagai salah satu inputan citra dalam model segmentasi ini. Komposit citra menampilkan citra pada

kombinasi band tertentu, pada penelitian ini menggunakan komposit citra *False Color* dengan kombinasi band yaitu band 7 (SWIR), band 5 (NIR), dan band 4 (Red) [39]. Penggunaan Komposit Citra *false color* didasari oleh pada penelitian Made, dkk [7], yang menunjukkan hasil bahwa segmentasi citra menggunakan U-Net pada inputan komposit citra menggunakan *false color* memiliki nilai akurasi, IoU dan *Dice Coeficient* lebih unggul dibandingkan dengan komposit citra menggunakan *natural color* terkhusus pada citra satelit [7]. Gambar 4.8 menunjukkan komposit citra *false color* yang telah dilakukan Koreksi atmosferik dan cloud masking.



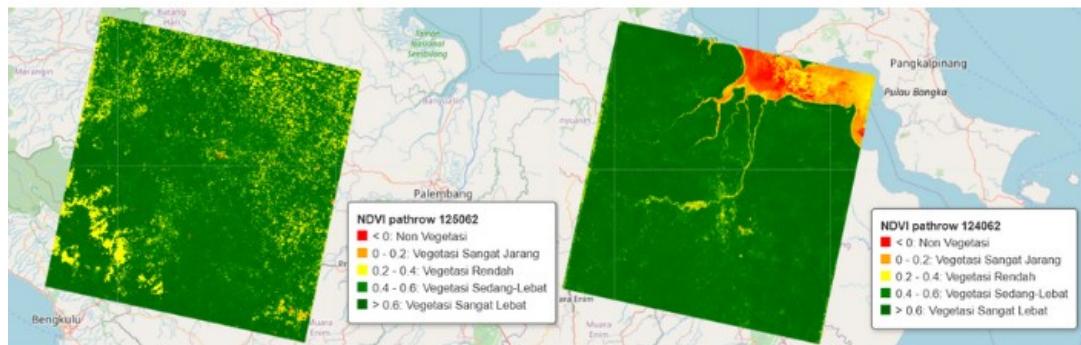
Gambar 4.8 Komposit Citra (*False Color*) pada kondisi *prefire* dan *postfire*

4.3 Ekstraksi Fitur

4.3.1 *Normalized Difference Vegetation Index (NDVI)*

Berdasarkan Gambar 4.9, hasil ekstraksi nilai NDVI kondisi *postfire* dari dua *pathrow* citra Landsat 9, yaitu *pathrow* 124062 dan *pathrow* 125062, menunjukkan variasi spasial tingkat kehijauan yang mencerminkan kondisi vegetasi di wilayah studi. Nilai NDVI dihitung berdasarkan perbedaan pantulan spektral antara kanal *Near-Infared* (NIR) dan kanal merah (Red), yang pada Landsat 9 masing-masing

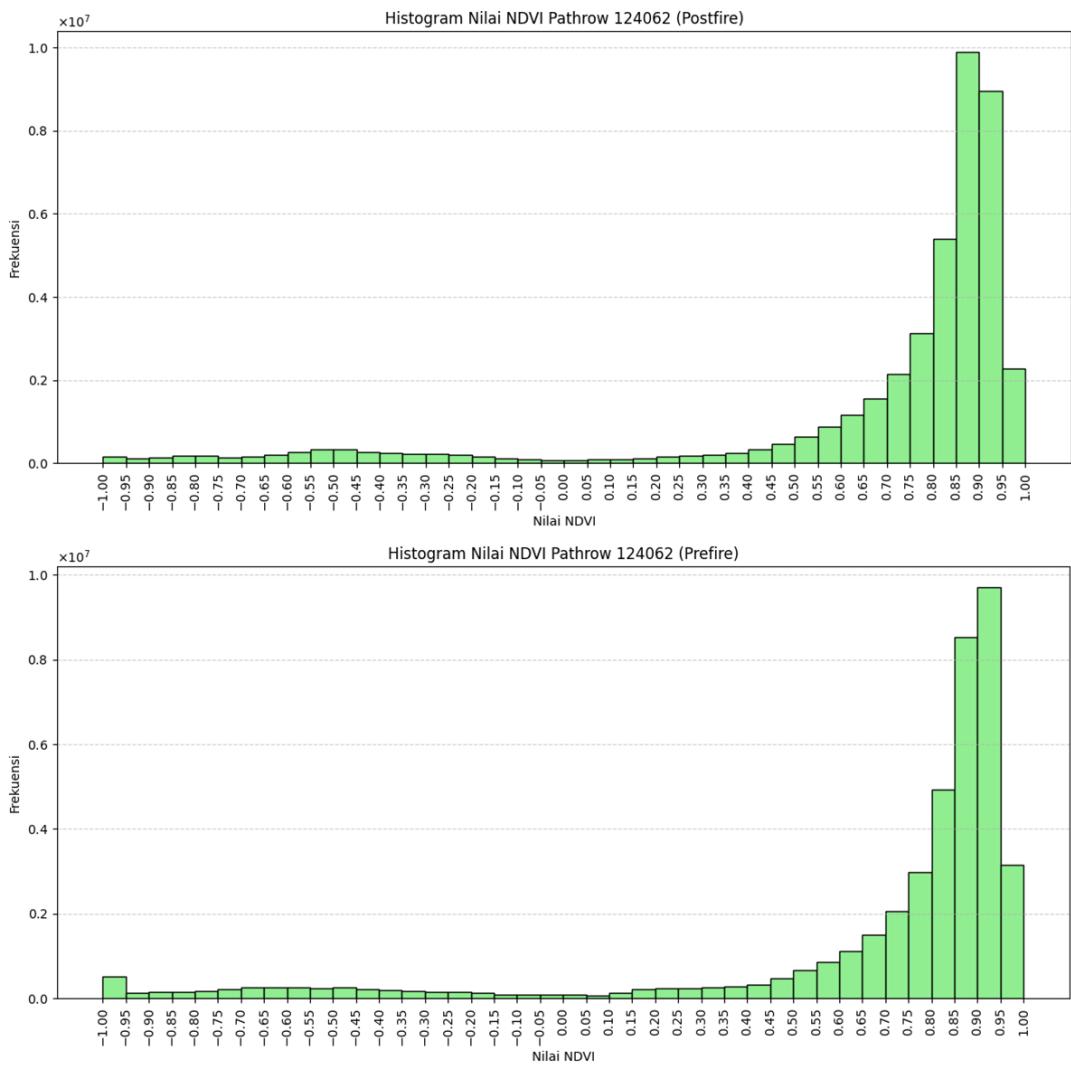
direpresentasikan oleh Band 5 dan Band 4. Perhitungan dilakukan secara piksel per piksel untuk menghasilkan informasi spasial mengenai tingkat kerapatan vegetasi.



Gambar 4.9 Citra NDVI pada *pathrow* 124062 dan *pathrow* 125062

Gambar 4.10 dan Gambar 4.11 menunjukkan distribusi nilai NDVI dari citra Landsat 9 pada wilayah dengan *pathrow* 124062 dan 125062. Histogram tersebut merepresentasikan jumlah piksel terhadap nilai NDVI yang berkisar antara -1 hingga +1. Pada Gambar 4.10 (*pathrow* 124062 - *Prefire*), distribusi nilai NDVI menunjukkan kecenderungan yang sangat kuat ke arah nilai positif tinggi. Puncak frekuensi terdapat pada rentang 0.90 hingga 0.95, yang mengindikasikan dominasi tutupan vegetasi lebat. Nilai negatif dan mendekati nol relatif sangat kecil, menandakan bahwa area non-vegetasi seperti badan air, permukiman, atau tanah terbuka hanya mencakup sebagian kecil dari keseluruhan wilayah citra.

Namun, Pada Gambar 4.10 (*pathrow* 124062 - *Postfire*), distribusi nilai NDVI menunjukkan kecenderungan yang sangat kuat ke arah nilai positif tinggi. Puncak frekuensi terdapat pada rentang 0.85 hingga 0.90, yang mengalami penurunan daripada kondisi *prefire*, yang menunjukkan terdapatnya perubahan vegetasi akibat kebakaran. Dan begitupula terjadi pada rentang 0.95 hingga 1 yang juga mengalami penurunan. Nilai negatif dan mendekati nol relatif sangat kecil, menandakan bahwa area non-vegetasi seperti badan air, permukiman, atau tanah terbuka hanya mencakup sebagian kecil dari keseluruhan wilayah citra

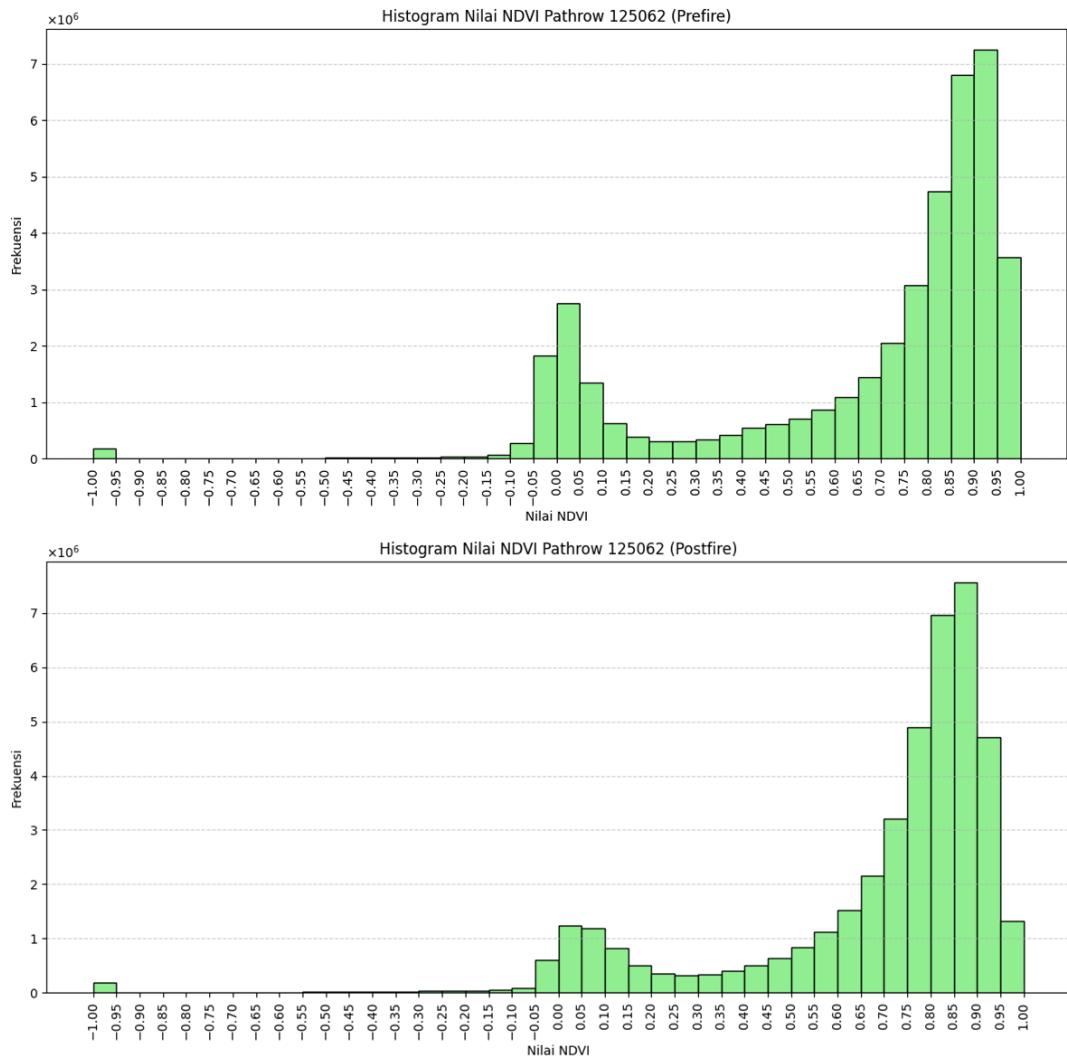


Gambar 4.10 Histogram NDVI *pathrow* 124062

Pada Gambar 4.11 (pathrow 125062 - *prefire*), distribusi nilai NDVI menunjukkan pola yang terkonsentrasi pada rentang nilai positif antara 0.70 hingga 0.90. Puncak histogram yang dominan pada kisaran ini mencerminkan kondisi tutupan lahan yang didominasi oleh vegetasi lebat dan sehat. Sebaran histogram yang sempit dan terfokus di sisi kanan mengindikasikan bahwa wilayah ini secara umum memiliki tutupan vegetasi yang relatif homogen dan belum mengalami gangguan.

Sebaliknya, pada Gambar 4.11 (pathrow 125062 - *postfire*), meskipun puncak distribusi NDVI masih berada pada kisaran yang sama (0.70 hingga 0.90), histogram menunjukkan sebaran yang lebih luas dan merata ke rentang nilai NDVI yang lebih rendah. Terdapat peningkatan

frekuensi yang signifikan pada nilai NDVI antara 0.10 hingga 0.60, yang menunjukkan keberadaan area dengan vegetasi sedang hingga rendah. Hal ini mengindikasikan adanya degradasi vegetasi atau perubahan tutupan lahan akibat kejadian kebakaran, yang menyebabkan keragaman tutupan lahan menjadi lebih tinggi dibandingkan dengan kondisi sebelum kebakaran.

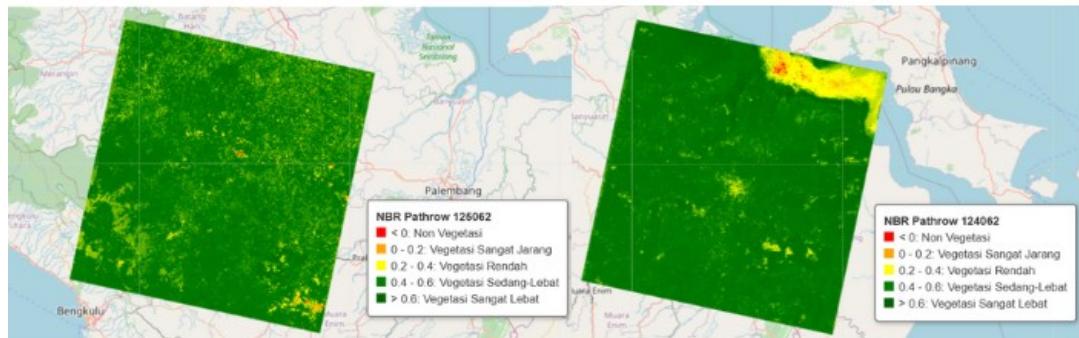


Gambar 4.11 Histogram NDVI pathrow 125062

4.3.2 Normalized Burn Ratio (NBR)

Pada Gambar 4.12 menunjukkan hasil ekstraksi nilai Normalized Burn Ratio (NBR) kondisi *postfire* dari citra Landsat 9, pada *pathrow* 125062 dan *pathrow* 124062. NBR dihitung menggunakan kanal inframerah dekat (NIR) dan kanal inframerah gelombang pendek (SWIR), yang pada citra Landsat 9 masing-masing direpresentasikan

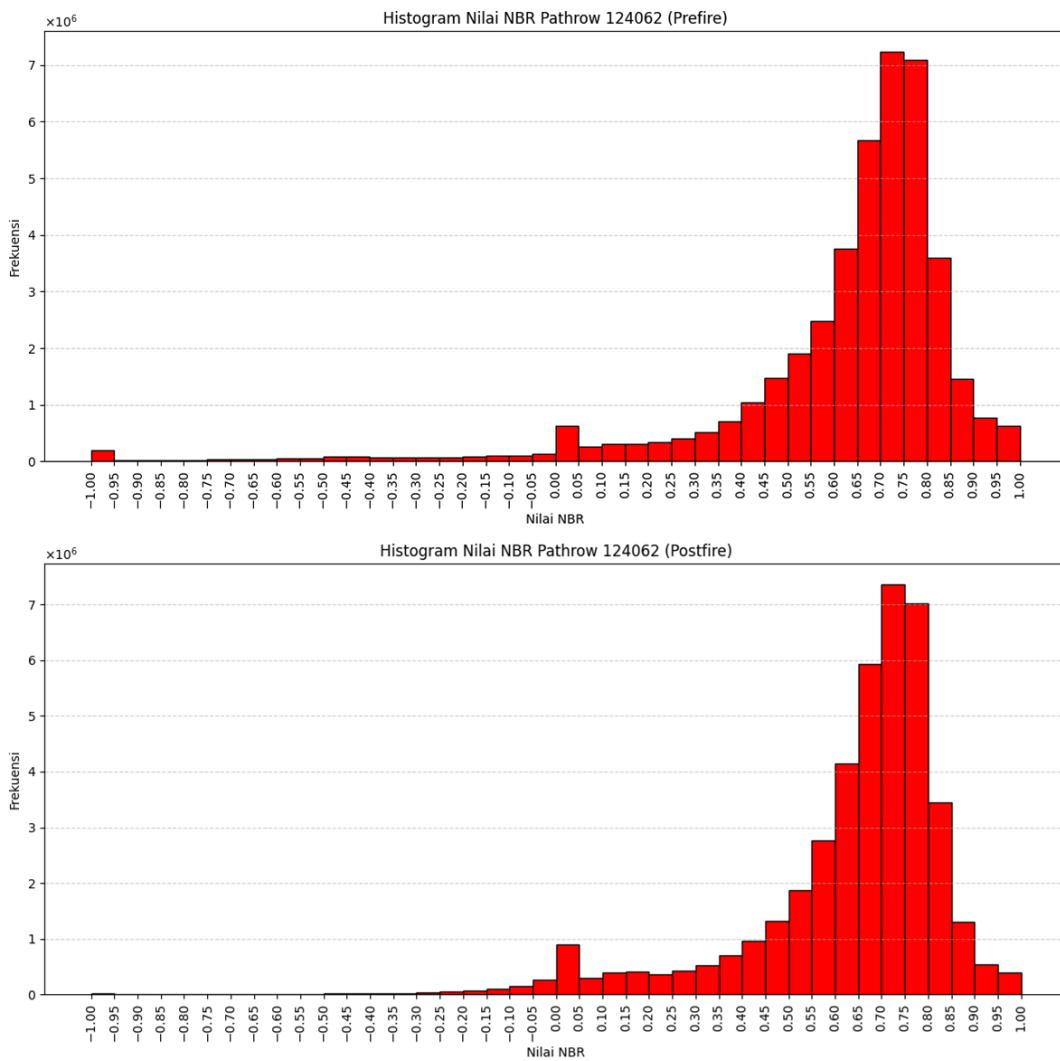
oleh Band 5 dan Band 7. NBR merupakan salah satu indeks yang umum digunakan untuk mendeteksi area yang terdampak kebakaran hutan dan lahan, dengan nilai yang menurun secara signifikan pada area terbakar akibat hilangnya vegetasi dan peningkatan kelembaban tanah.



Gambar 4.12 Citra NBR pada pathrow 125062 dan pathrow 124062

Pada Gambar 4.13 (pathrow 124062 - *prefire*) menunjukkan distribusi nilai NBR sebelum kejadian kebakaran menunjukkan puncak yang cukup tajam pada kisaran 0.65 hingga 0.80, dengan sebaran yang relatif sempit dan terpusat di sisi kanan histogram. Hal ini mengindikasikan bahwa sebagian besar wilayah memiliki kondisi vegetasi yang sehat dan tidak terbakar.

Namun, pada Gambar 4.13 (pathrow 124062 - *postfire*), setelah kebakaran, histogram NBR tetap menunjukkan puncak pada kisaran 0.60 hingga 0.80, namun terdapat peningkatan frekuensi pada nilai NBR yang lebih rendah, terutama di bawah 0.60. Munculnya distribusi yang lebih menyebar ke arah kiri menunjukkan adanya penurunan nilai NBR di beberapa area, yang mengindikasikan kerusakan vegetasi akibat kebakaran. Meskipun puncak nilai masih tinggi, penyebaran ini menandakan bahwa sebagian wilayah mengalami degradasi atau hilangnya biomassa, dengan peningkatan area yang memperlihatkan karakteristik bekas terbakar.

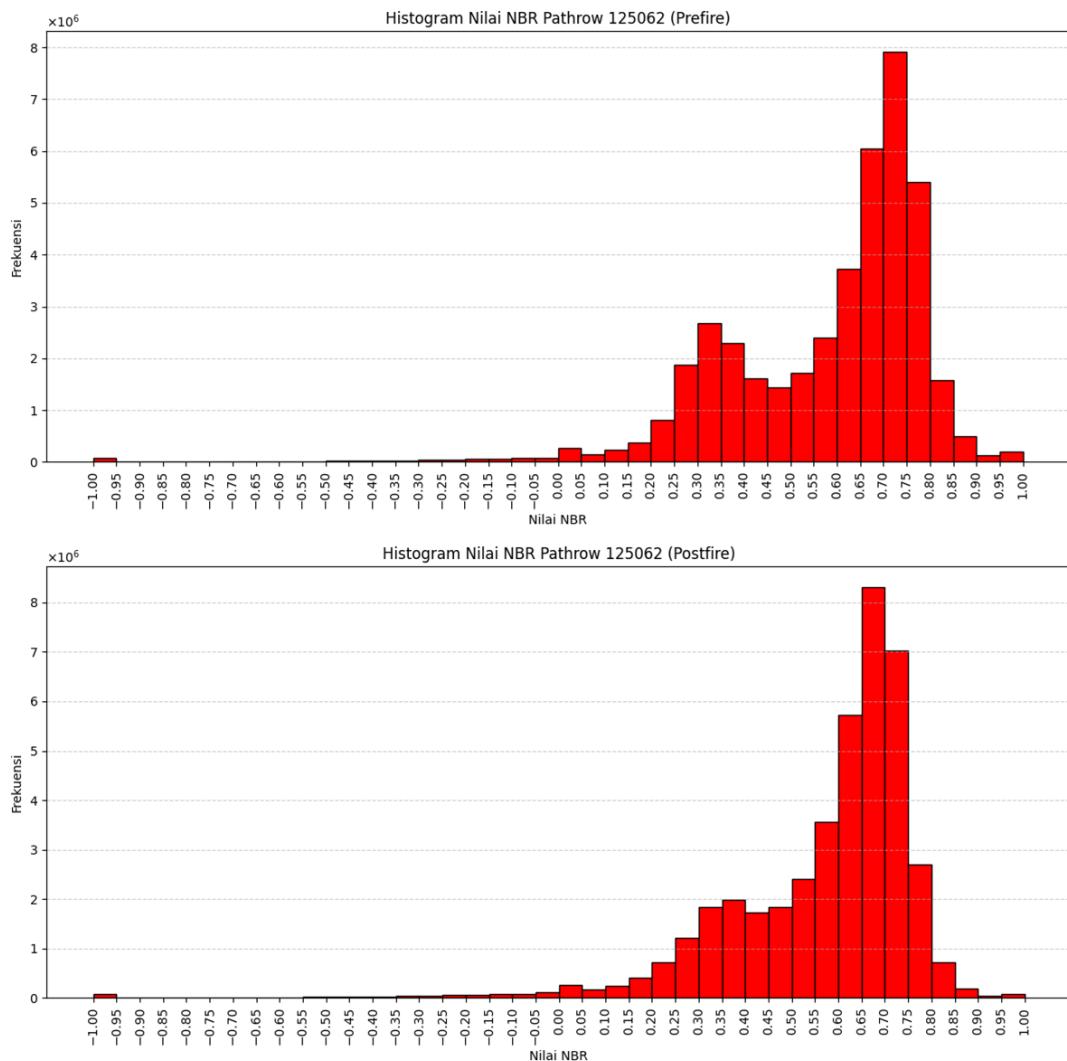


Gambar 4.13 Histogram NBR *pathrow 124062*

Pada Gambar 4.14 (*pathrow 125062 – prefire*), histogram nilai NBR menunjukkan dua puncak utama, yaitu pada kisaran 0.30–0.35 dan 0.70–0.75. Puncak tertinggi berada pada rentang nilai NBR 0.70–0.75 yang mencerminkan dominasi tutupan vegetasi lebat dan sehat sebelum terjadinya kebakaran. Sementara itu, kemunculan puncak tambahan pada nilai NBR yang lebih rendah mengindikasikan keberadaan area dengan vegetasi yang tidak terlalu rapat atau tutupan lahan campuran. Sebaran histogram yang relatif luas menunjukkan bahwa wilayah ini memiliki keragaman kondisi tutupan lahan sebelum kejadian kebakaran.

Namun, pada Gambar 4.14 (*pathrow 125062 -postfire*), distribusi nilai NBR mengalami pergeseran ke arah nilai yang lebih rendah, dengan

konsentrasi frekuensi yang lebih menyebar pada kisaran 0.40 hingga 0.70. Meskipun puncak nilai NBR masih berada pada kisaran 0.70, jumlah piksel dalam rentang tersebut terlihat menurun dibandingkan kondisi *prefire*. Hal ini mengindikasikan adanya degradasi vegetasi akibat kebakaran, di mana sebagian wilayah yang sebelumnya memiliki nilai NBR tinggi mengalami penurunan reflektansi vegetatif, yang tercermin dari penurunan nilai NBR secara keseluruhan.

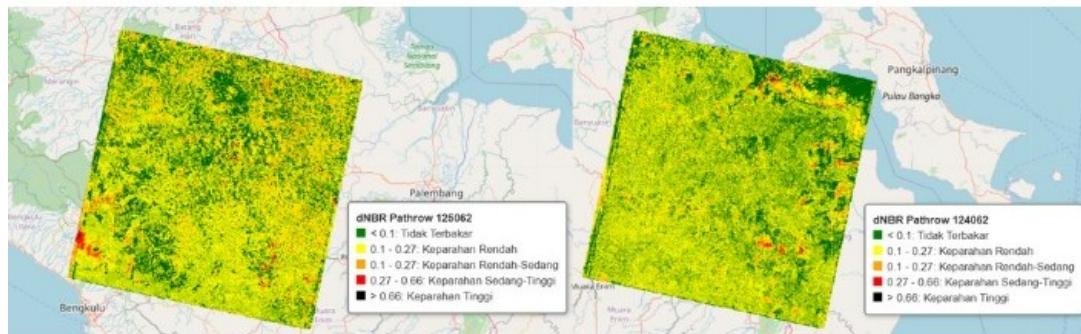


Gambar 4.14 Histogram NBR *pathrow* 125062

4.3.3 *Difference Normalized Burn Ratio (dNBR)*

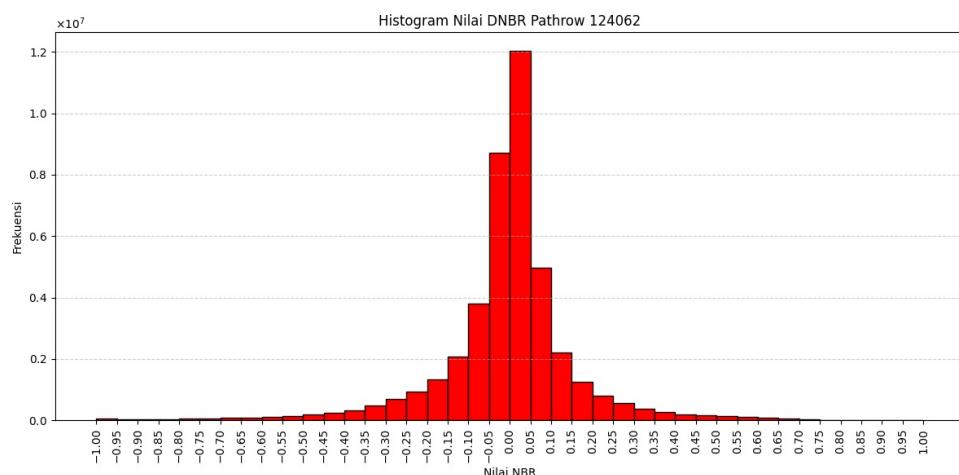
Gambar 4.15 menunjukkan hasil *difference Normalized Burn Ratio* (dNBR) untuk dua *pathrow* Landsat 9, yaitu *pathrow* 124062 (Gambar 4.15 bagian a) dan *pathrow* 125062 (Gambar 4.15 bagian b). Nilai dNBR diperoleh dengan menghitung selisih antara indeks NBR

sebelum kebakaran (*prefire*) dan setelah kebakaran (*postfire*), sehingga mampu menggambarkan tingkat keparahan perubahan vegetasi akibat kejadian kebakaran hutan dan lahan. Terlihat pada *pathrow* 124062, menunjukkan keparahan tinggi kebakaran berada diarah timur dan tenggara serta beberapa di arah utara dekat ke laut. Pada *pathrow* 125062, keparahan tinggi berada lebih tepatnya di barat daya dan tenggara.



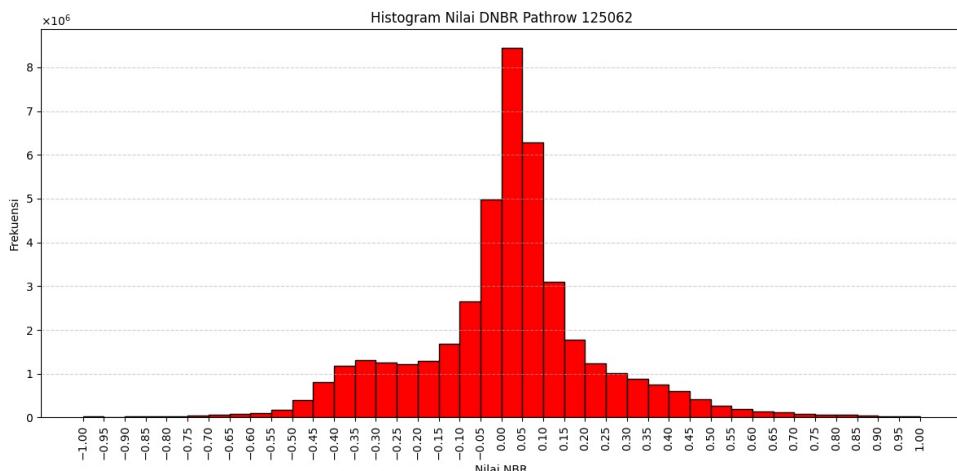
Gambar 4.15 Citra dNBR pada *pathrow* 124062 dan 125062

Pada Gambar 4.16 menunjukan dNBR pada *pathrow* 124062, histogram memperlihatkan nilai dNBR berada pada kisaran 0.00 hingga 0.05 dengan puncak tertinggi. Sebaran ini mengindikasikan bahwa area mengalami sedikit perubahan vegetasi yang signifikan atau bisa dikatakan tidak terbakar. Walaupun nilai dNBR diatas 0.1 masih ada yang menunjukkan terdapat keparahan kebakaran, walaupun pada keparahan kebakaran tinggi (>0.6) menunjukkan frekuensinya tidak banyak dibandingkan keparahan rendah dan sedang.



Gambar 4.16 Histogram dNBR Pahtrow 124062

Namun pada Gambar 4.17, distribusi nilai dNBR pada *pathrow* 125062 menunjukkan pola yang lebih menyebar dengan frekuensi piksel yang jauh lebih tinggi. Histogram memperlihatkan sebaran yang lebih luas, yang mengindikasikan adanya dampak kebakaran yang lebih besar dibandingkan dengan *pathrow* 124062. Peningkatan jumlah piksel pada kelas dNBR menengah hingga tinggi ini mencerminkan kerusakan vegetasi yang lebih luas, mulai dari tingkat ringan hingga sedang, bahkan terdapat indikasi kecil terhadap area dengan keparahan berat. Berdasarkan distribusi tersebut, dapat disimpulkan bahwa *pathrow* 125062 mengalami kejadian kebakaran yang lebih signifikan dibandingkan *pathrow* 124062.



Gambar 4.17 Histogram dNBR *pathrow* 125062

4.4 *Masking* Citra

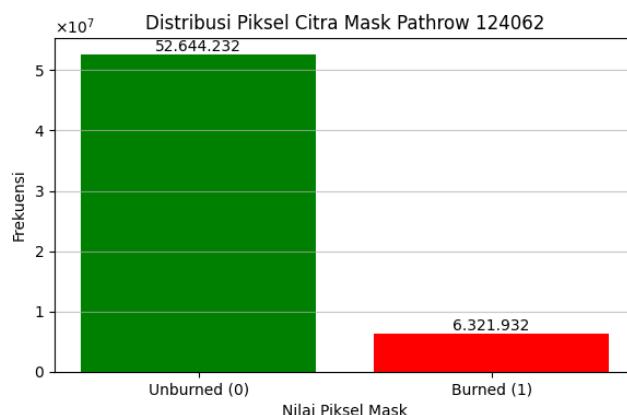
Pada Gambar 4.18 menunjukkan hasil *masking* citra dari dua *pathrow* Landsat 9, yaitu *pathrow* 125062 (Gambar 4.16 bagian a) dan *pathrow* 124062 (Gambar 4.16 bagian b), yang dihasilkan dari proses thresholding terhadap citra *differenced Normalized Burn Ratio* (dNBR). Proses ini bertujuan untuk mengidentifikasi dan memisahkan area terbakar dan area tidak terbakar yang digunakan sebagai *ground truth (actual)*. *Masking* dilakukan dengan menggunakan nilai ambang (*threshold*) pada dNBR, di mana nilai dNBR lebih besar dari 0.1 dikategorikan sebagai area terbakar (diberikan nilai 1, ditampilkan dalam warna putih pada citra *mask*), sedangkan nilai dNBR 0.1 dikategorikan sebagai area tidak terbakar (diberi nilai 0, ditampilkan

dalam warna hitam). Nilai ambang 0.1 dipilih berdasarkan tabel dNBR yang menunjukkan kondisi *burned area* pada Tabel 3.6.



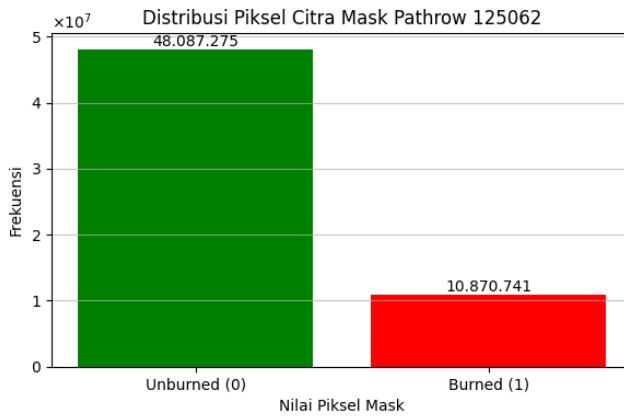
Gambar 4.18 Citra mask pada pathrow 124062 dan 125062

Pada Gambar 4.19 menunjukkan distribusi piksel pada citra *mask* pathrow 124062, berdasarkan gambar terlihat bahwa piksel menunjukkan *burned* frekuensinya sebanyak 6.321.932, sedangkan 52.644.232 diantaranya merupakan *unburned*.



Gambar 4.19 Disribusi piksel citra *mask* pathrow 124062

Pada Gambar 4.20 menunjukkan distribusi piksel pada citra *mask* pathrow 125062, berdasarkan gambar terlihat bahwa piksel menunjukkan *burned* frekuensinya sebanyak 10.870.741, sedangkan 48.087.275 diantaranya merupakan *unburned*.



Gambar 4.20 Disribusi piksel citra *mask pathrow 125062*

4.5 *Band Stacking*

Proses *band stacking* pada penelitian ini dilakukan untuk citra kondisi *postfire*, yang selanjutnya digunakan sebagai inputan dalam *training* model segmentasi U-Net. Tujuan utama dari *band stacking* adalah membentuk citra *multiband* yang menggabungkan informasi spektral dan indeks vegetasi ke dalam satu representasi data yang komprehensif. Dalam hal ini, tiga sumber kanal yang digunakan adalah: komposit citra *false color*, NDVI, dan NBR, sehingga setiap citra hasil *band stacking* memiliki total lima kanal (5 band).

Band stacking dilakukan terhadap citra pada *pathrow* 124062 dan 125062, yang sebelumnya telah melalui proses koreksi atmosferik, *cloud masking*, komposit citra, serta penghitungan indeks NDVI dan NBR. Setiap *layer* disatukan secara spasial pada domain yang sama dan dalam format numerik raster yang seragam menjadi citra *multiband*. Tabel 4.5 menunjukkan urutan band disimpan pada proses *band stacking*.

Tabel 4.5 Urutan Band citra *multiband* disimpan

Band	Informasi disimpan
Band 1	NDVI
Band 2	NBR
Band 3	False Color (Band 4)
Band 4	False Color (Band 5)
Band 5	False Color (Band 7)

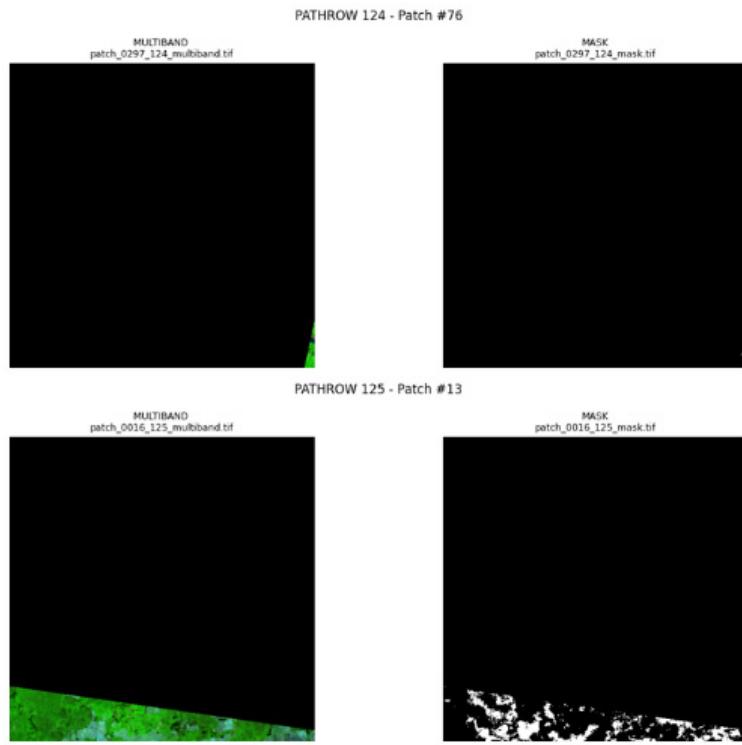
Proses *band stacking* ini memungkinkan model untuk memanfaatkan tidak hanya nilai reflektansi mentah dari kanal Landsat, tetapi juga informasi indeks vegetasi yang telah diperoleh sebelumnya. Hal ini memperkuat kemampuan model dalam membedakan antara area vegetasi sehat, area terbakar, dan area terbuka dengan akurasi spasial yang lebih baik.

4.6 *Split Data*

Tahapan sebelum proses *split data* dilakukan, terlebih dahulu dilakukan pengecekan ukuran citra pada seluruh *pathrow*. Hasil pengecekan menunjukkan bahwa ukuran citra belum seragam, di mana terdapat perbedaan beberapa piksel dari citra diunduh dari *Google Earth Engine*, walaupun sudah menggunakan *filter pathrow* di library ee. Pada citra *pathrow* 124062 tercatat memiliki ukuran 7587 x 7772 piksel, sedangkan pada *pathrow* 125062 ukurannya adalah 7584 x 7774 piksel.

Untuk menyeragamkan ukuran, dilakukan proses pemotongan (*clipping*) raster menggunakan data *shapefile World Reference System-2 (WRS-2) PathRow* milik Landsat, yang disediakan oleh U.S. Geological Survey (USGS) yang merupakan batas *pathrow* resmi [40]. Setelah proses *clipping*, ukuran citra menjadi seragam, yaitu 7313×6533 piksel. Sebelum proses split data dilakukan, citra dipecah menjadi beberapa potongan (*patch*) agar dapat digunakan dalam *training* model. Proses ini disebut *image patching*, di mana citra dibagi menjadi *patch* berukuran 512×512 piksel. Proses *image patching* dilakukan dengan tumpang tindih (*overlapping*) sebesar 50%.

Namun, berdasarkan pengamatan pada salah beberapa *patch* ditunjukkan pada Gambar 4.21, terlihat bahwa beberapa *patch* citra memiliki kualitas yang tidak layak digunakan. *Patch* tersebut sebagian besar tidak memuat informasi yang relevan karena dominan area citra hanya berisi piksel hitam yang mendominasi tampilan, sehingga tidak bermanfaat untuk proses *training* model. Jika *patch* seperti ini tetap digunakan, hal tersebut dapat menurunkan kualitas dataset dan memengaruhi kinerja model.



Gambar 4.21 Sampel citra tidak layak

Untuk mengatasi hal tersebut, diterapkan proses *image filtering* guna menghapus *patch* yang tidak layak. Suatu *patch* dinilai tidak layak apabila pada seluruh band terdapat piksel dominan berwarna hitam melebihi threshold 30%. Dengan menggunakan citra *patch* pada *multiband*. *Patch* yang memenuhi kriteria ini dihapus dan tidak digunakan dalam tahap pemrosesan selanjutnya, beserta citra mask yang pasangan citra tersebut. Hasil *image patching* sebelum dilakukan *filtering* ditunjukkan pada Tabel 4.6, di mana dari dua *pathrow* (124062 dan 125062) diperoleh total 1296 *patch* citra berpasangan (citra *multiband* dan citra mask).

Tabel 4.6 Jumlah *patch* citra sebelum filtering

<i>pathrow</i>	Jumlah <i>patch</i> Citra diperoleh
124062	648
125062	648
Total	1296

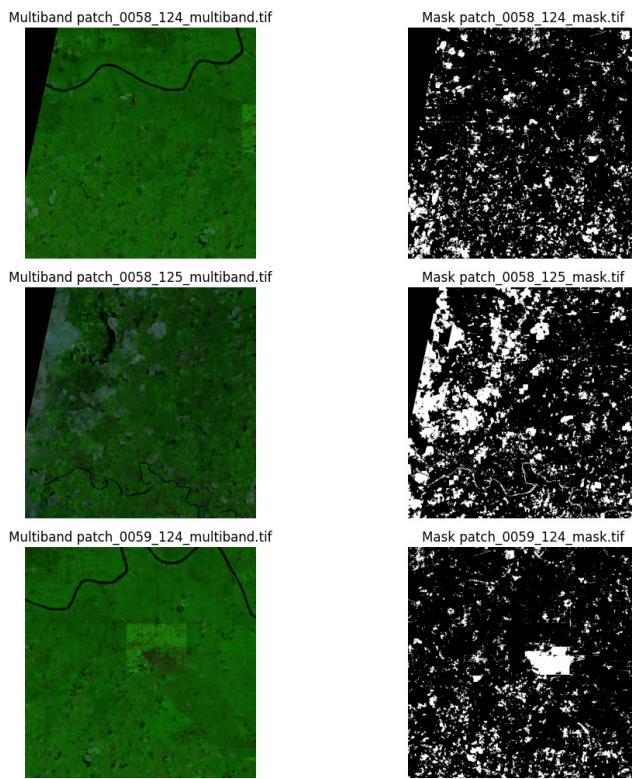
Setelah melalui proses *image filtering*, sebanyak 144 *patch* setiap *pathrow* dinyatakan tidak layak digunakan sebagaimana ditunjukkan

pada Tabel 4.7. Dengan demikian, jumlah citra layak yang digunakan dalam penelitian ini adalah 504 *patch* berpasangan setiap *pathrow* yang digunakan, dengan total *patch* sebesar 1008 pasangan (citra *multiband* dan citra mask), Citra layak ini selanjutnya digunakan pada proses *split data*.

Tabel 4.7 Jumlah data setelah *filtering*

<i>pathrow</i>	Jumlah <i>patch</i> citra tidak layak	Jumlah <i>patch</i> citra layak
124062	144	504
125062	144	504
Total	288	1008

Pada Gambar 4.22 menunjukkan beberapa pasangan citra *patch* yang layak dan bisa digunakan pada proses *split data*.



Gambar 4.22 Sampel citra layak digunakan dalam segmentasi

Citra yang telah dinyatakan layak inilah yang kemudian digunakan untuk proses *split data* menjadi tiga *subset*, yaitu data latih (*training*), data validasi (*validation*), dan data uji (*testing*). Pembagian dilakukan dengan rasio 70% untuk data latih, 15% untuk data validasi, dan 15%

untuk data uji, sehingga proporsi dataset tetap seimbang dan representatif untuk melatih sekaligus mengevaluasi kinerja model segmentasi yang dikembangkan, ditunjukkan pada Tabel 4.8.

Tabel 4.8 Rasio *split data*

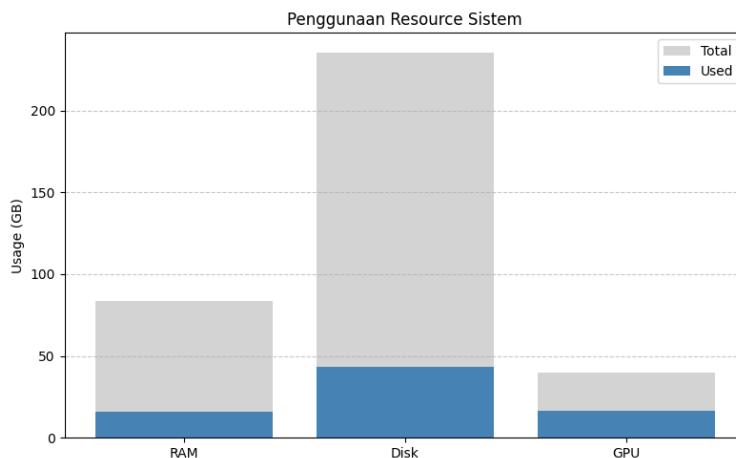
Data	Persentase	Jumlah Data
Train	70%	706
Test	15%	151
Val	15%	151
Total	100%	1008

4.7 Model U-Net

Pada tahap *training* model, data yang telah melalui proses *split data* menjadi data *training* dan *validation* digunakan sebagai inputan dalam proses *training* model U-Net. Arsitektur U-Net yang digunakan merujuk pada rancangan sebagaimana ditampilkan pada Gambar 3.3, dengan struktur simetris *encoder - decoder* yang dirancang khusus untuk segmentasi citra. Model U-Net dikompilasi menggunakan *hyperparameter* berdasarkan Tabel 3.7, berupa fungsi *loss binary_crossentropy* dan *optimizer* Adam dengan *learning rate* sebesar 0.0001, yang bertujuan mengoptimalkan konvergensi terhadap segmentasi biner. Proses *training* juga dilengkapi dengan dua mekanisme *callback*, yaitu *EarlyStopping* dan *ReduceLROnPlateau*, yang masing-masing berfungsi menghentikan *training* ketika tidak terjadi perbaikan pada *val_loss* setelah lima epoch berturut-turut, serta menurunkan nilai *learning rate* sebesar 50% jika tidak terjadi penurunan *val_loss* dalam tiga *epoch*. Model dilatih dengan jumlah *epoch* maksimum sebanyak 200 dan ukuran *batch size* 4. *EarlyStopping* berfungsi menghentikan *training* ketika *loss* berhenti membaik dan mencegah *overfitting* [41]. *ReduceLROnPlateau* berfungsi menjaga proses *training* tetap efektif dan memaksimalkan kinerja model dan mencegah *overfitting* [42].

Proses *training* ini dijalankan menggunakan perangkat komputasi dengan spesifikasi sebagaimana ditunjukkan pada Tabel 3.2. Waktu eksekusi *training* model tercatat selama 20 menit 21 detik. Selama

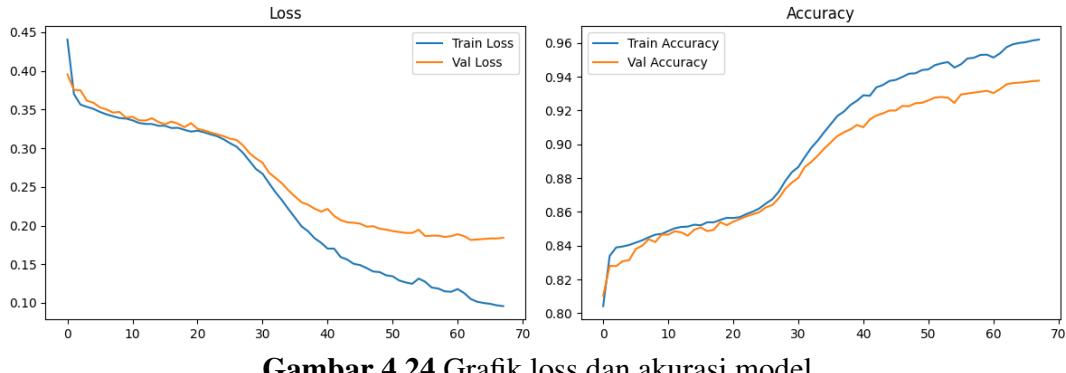
proses *training* model, penggunaan memori GPU tercatat sebesar 16.68 GB dari total kapasitas 40 GB, 16.16 GB dari total kapasitas 83.48 untuk RAM serta 43.49 GB dari total kapasitas 235.68 GB untuk Disk. Pada Gambar 4.23 menunjukkan penggunaan *resource* sistem. Hal ini menandakan bahwa model U-Net mampu beroperasi secara efisien dalam memanfaatkan kapasitas komputasi yang tersedia, tanpa mengalami kendala memori yang berarti, walaupun pada penelitian ini ukuran citra dan jumlah data dimiliki cukup besar.



Gambar 4.23 Penggunaan resource sistem

Pada Gambar 4.24 menunjukkan grafik *training loss*, *validation loss*, *training accuracy*, dan *validation accuracy* selama proses *training* menggunakan arsitektur U-Net dengan fungsi *loss binary crossentropy* dan optimasi Adam. Berdasarkan grafik tersebut, terlihat bahwa nilai *loss* untuk data *training* dan validasi sama-sama mengalami penurunan secara konsisten hingga epoch ke-68 dengan *learning rate* optimal sebesar 2.5×10^{-5} . Tidak terdapat lonjakan atau fluktuasi signifikan pada *validation loss*, yang mengindikasikan bahwa model mampu menjaga generalisasi dan tidak mengalami *overfitting*. Hal ini diperkuat oleh tren nilai akurasi yang meningkat secara bertahap, baik pada data *train* maupun *validation*. Nilai *validation accuracy* yang mendekati *training accuracy* menunjukkan bahwa model tidak hanya belajar pada data *training*, tetapi juga memiliki performa prediksi yang baik terhadap data yang belum pernah dilihat sebelumnya. Selain itu, penggunaan strategi *EarlyStopping* dan *ReduceLROnPlateau* juga turut berkontribusi dalam mengoptimalkan proses *training* dengan

menghindari overfitting [42].



Gambar 4.24 Grafik loss dan akurasi model

Pada Tabel 4.9 merupakan parameter model U-Net menunjukkan ringkasan struktur arsitektur model U-Net yang digunakan dalam penelitian. Parameter tersebut menunjukkan setiap *layer* berupa ukuran citra, *channel*, kernel dan *layer* yang terhubung.

Tabel 4.9 Parameter model U-Net

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 512, 512, 5)	0	-
conv2d (Conv2D)	(None, 512, 512, 64)	2,944	input_layer
conv2d_1 (Conv2D)	(None, 512, 512, 64)	36,928	conv2d
max_pooling2d (MaxPooling2D)	(None, 256, 256, 64)	0	conv2d_1
conv2d_2 (Conv2D)	(None, 256, 256, 128)	73,856	max_pooling2d
conv2d_3 (Conv2D)	(None, 256, 256, 128)	147,584	conv2d_2
max_pooling2d_1 (MaxPooling2D)	(None, 128, 128, 128)	0	conv2d_3
conv2d_4 (Conv2D)	(None, 128, 128, 256)	295,168	max_pooling2d_1
conv2d_5 (Conv2D)	(None, 128, 128, 256)	590,080	conv2d_4
max_pooling2d_2 (MaxPooling2D)	(None, 64, 64, 256)	0	conv2d_5
conv2d_6 (Conv2D)	(None, 64, 64, 512)	1,180,160	max_pooling2d_2
conv2d_7 (Conv2D)	(None, 64, 64, 512)	2,359,808	conv2d_6
max_pooling2d_3 (MaxPooling2D)	(None, 32, 32, 512)	0	conv2d_7
conv2d_8 (Conv2D)	(None, 32, 32, 1024)	4,719,616	max_pooling2d_3
conv2d_9 (Conv2D)	(None, 32, 32, 1024)	9,438,208	conv2d_8
conv2d_transpose (Conv2DTranspose)	(None, 64, 64, 512)	2,097,664	conv2d_9
concatenate (Concatenate)	(None, 64, 64, 1024)	0	conv2d_transpose, conv2d_7
conv2d_10 (Conv2D)	(None, 64, 64, 512)	4,719,104	concatenate
conv2d_11 (Conv2D)	(None, 64, 64, 512)	2,359,808	conv2d_10
conv2d_transpose_1 (Conv2DTranspose)	(None, 128, 128, 256)	524,544	conv2d_11
concatenate_1 (Concatenate)	(None, 128, 128, 512)	0	conv2d_transpose_1, conv2d_5
conv2d_12 (Conv2D)	(None, 128, 128, 256)	1,179,904	concatenate_1
conv2d_13 (Conv2D)	(None, 128, 128, 256)	590,080	conv2d_12
conv2d_transpose_2 (Conv2DTranspose)	(None, 256, 256, 128)	131,200	conv2d_13
concatenate_2 (Concatenate)	(None, 256, 256, 256)	0	conv2d_transpose_2, conv2d_3
conv2d_14 (Conv2D)	(None, 256, 256, 128)	295,040	concatenate_2
conv2d_15 (Conv2D)	(None, 256, 256, 128)	147,584	conv2d_14
conv2d_transpose_3 (Conv2DTranspose)	(None, 512, 512, 64)	32,832	conv2d_15
concatenate_3 (Concatenate)	(None, 512, 512, 128)	0	conv2d_transpose_3, conv2d_1
conv2d_16 (Conv2D)	(None, 512, 512, 64)	73,792	concatenate_3
conv2d_17 (Conv2D)	(None, 512, 512, 64)	36,928	conv2d_16
conv2d_18 (Conv2D)	(None, 512, 512, 1)	65	conv2d_17

4.8 Evaluasi Model

Evaluasi model U-Net dilakukan menggunakan empat metrik utama, yaitu *Binary Accuracy*, *Intersection over Union (IoU)*, *Dice Coefficient*, dan *Binary Cross Entropy (BCE)*. Berdasarkan hasil evaluasi yang disajikan pada Tabel 4.4, model berhasil mencapai nilai *Binary Accuracy* sebesar 0.93523, yang menunjukkan bahwa mayoritas piksel pada citra berhasil diklasifikasikan dengan benar. Nilai *Intersection over Union (IoU)* diperoleh sebesar 0.70858, mengindikasikan tingkat tumpang tindih yang baik antara area prediksi dan *ground truth* mendekati nilai 1. Selain itu, *Dice Coefficient* yang diperoleh mencapai 0.82944, memperkuat bukti bahwa segmentasi yang dilakukan model memiliki kesesuaian spasial yang sangat baik terhadap label *ground truth*. Sementara itu, nilai *Binary Cross Entropy (BCE)* yang dicapai adalah sebesar 0.18111, yang menunjukkan tingkat kesalahan prediksi yang relatif rendah selama proses evaluasi. Hasil evaluasi model ditunjukkan pada Tabel 4.10.

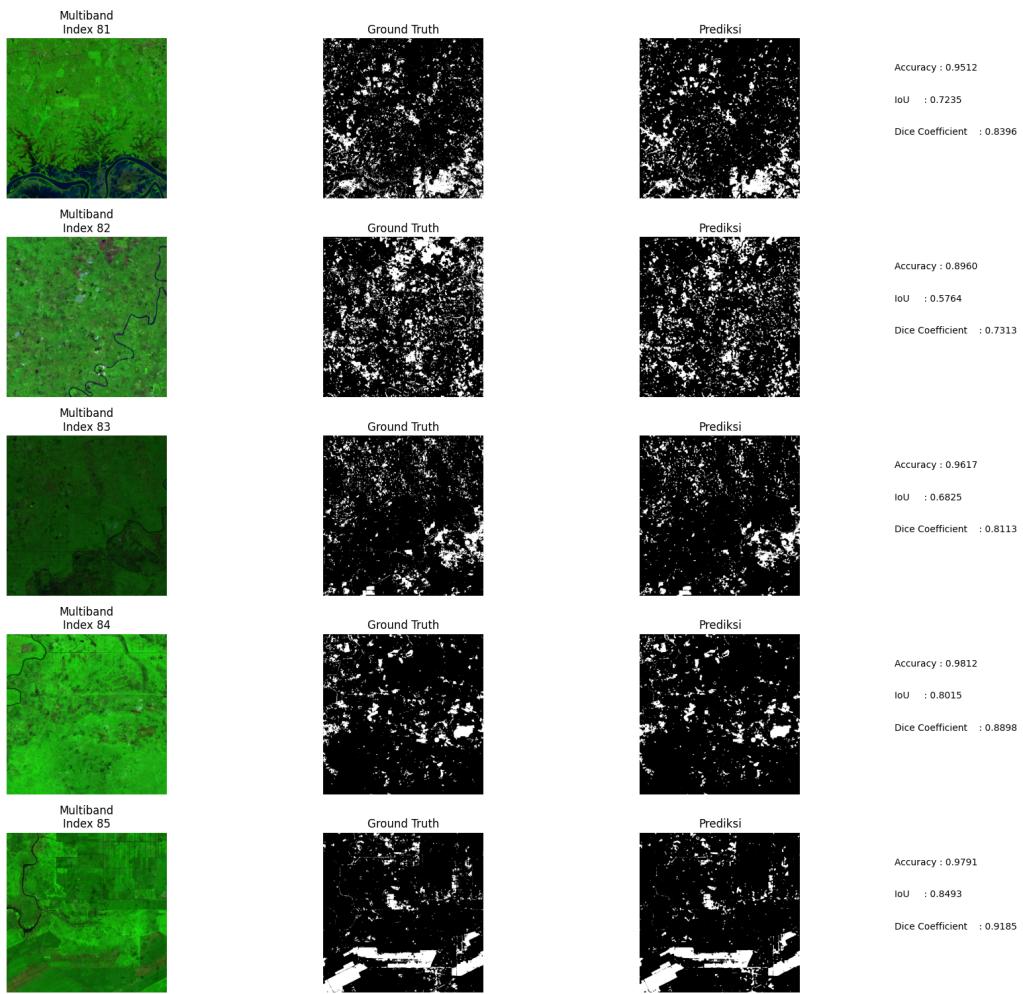
Tabel 4.10 Hasil Evaluasi Model

Evaluasi Model	Nilai
<i>Binary Accuracy</i>	0.93523
IoU	0.70858
<i>Dice Coefficient</i>	0.82944
<i>Binary Cross Entropy</i>	0.18111

Pada Gambar 4.25 merupakan visualisasi beberapa gambar hasil prediksi model yang terdiri dari citra *multiband* yang merupakan citra inputan model, pada visualisasi ini hanya menampilkan band komposit *False Color* dari 5 band yang dimiliki pada citra *multiband* tersebut yaitu NDVI dan NBR. Selanjutnya terdapat citra *ground truth* merupakan citra mask yang merupakan label dari segmentasi, terdapat prediksi, merupakan citra hasil prediksi model U-Net dalam segmentasi *burned area* di Sumatera Selatan menggunakan Citra Landsat 9 beserta dengan hasil akurasi, IoU dan *Dice Coefficient* citra. Secara umum, performa model tergolong sangat baik, yang menunjukkan bahwa sebagian besar piksel berhasil diklasifikasikan

dengan benar. Kinerja terbaik terlihat seperti pada *multiband index* 85, dengan *Binary Accuracy* 0.9791, IoU 0.8493, dan *Dice Coefficient* 0.9185, mengindikasikan segmentasi yang sangat presisi terhadap area terbakar. Demikian pula, *index* 84 juga menunjukkan performa tinggi dengan nilai *Binary Accuracy* 0.9812, IoU 0.8015 dan *Dice Coefficient* 0.8898.

Sebaliknya, prediksi pada *index* 82 menghasilkan performa terendah, dengan IoU hanya 0.5764 dan *dice coefficient* 0.7313, menunjukkan ketidaksesuaian yang lebih tinggi terhadap *ground truth*. Hal ini kemungkinan disebabkan oleh gangguan visual atau spektral seperti tutupan awan, kabut asap, atau variabilitas vegetasi yang sulit dibedakan dari area terbakar. Berdasarkan dari visualisasi hasil, prediksi model umumnya mampu merepresentasikan pola spasial kebakaran dengan baik dan mendekati *ground truth*, terutama pada area dengan tingkat kontras tinggi antara vegetasi hijau dan bekas kebakaran.



Gambar 4.25 Citra prediksi segmentasi model U-Net

4.9 Pembahasan segmentasi *burned area*

Penelitian ini mengadopsi arsitektur model U-Net yang serupa dengan pendekatan yang dikembangkan oleh Prabowo, dkk [5]. Namun, terdapat sejumlah perbedaan signifikan dalam konfigurasi input dan teknik pemrosesan data. Penelitian ini menggunakan lima kanal (band) input, yang terdiri atas tiga kanal komposit *false color*, serta dua kanal tambahan berupa indeks vegetasi *Normalized Difference Vegetation Index* (NDVI) dan indeks kebakaran *Normalized Burn Ratio* (NBR). Penambahan dua kanal ini merupakan bagian dari strategi ekstraksi fitur yang dirancang untuk memperkaya informasi spektral dari citra Landsat 9. Strategi ini secara langsung menjawab rumusan masalah pertama, yaitu mengenai bagaimana teknik ekstraksi fitur dari citra Landsat 9 diterapkan dalam segmentasi area terbakar di wilayah Sumatera Selatan.

Integrasi kanal NDVI dan NBR dalam input citra dilakukan karena kedua indeks tersebut terbukti efektif dalam mendeteksi perubahan vegetasi dan kondisi kebakaran. NDVI memberikan informasi tentang tingkat kehijauan vegetasi, sementara NBR sensitif terhadap perubahan suhu dan struktur biomassa akibat kebakaran. Dengan menggabungkan indeks-indeks ini bersama kanal spektral utama, model *deep learning* dapat belajar pola yang lebih kompleks dan kontekstual mengenai area yang terdampak kebakaran.

Dalam aspek augmentasi data, penelitian ini menerapkan skema *overlapping* secara menyeluruh pada seluruh citra *training*, berbeda dari pendekatan Prabowo, dkk [5]. Hanya menerapkan *overlapping* pada beberapa citra dan menambahkan rotasi sebagai variasi spasial. Strategi *overlapping* menyeluruh digunakan untuk mencakup variasi spasial yang luas pada wilayah yang terdampak kebakaran, terutama pada lokasi yang memiliki area terbakar dengan cakupan besar dan tidak merata.

Pelabelan *burned area* dilakukan dengan menggunakan metode *thresholding* terhadap nilai dNBR, berbeda dengan pendekatan Prabowo yang menggunakan delineasi manual oleh pakar Sistem Informasi Geografis (SIG). Pendekatan *thresholding* dipilih karena lebih efisien, konsisten, dan telah diterapkan dalam penelitian terdahulu oleh Made, dkk [7], yang menunjukkan bahwa label (*ground truth*) yang dihasilkan melalui dNBR cukup representatif untuk segmentasi area kebakaran. Dengan demikian, aspek ekstraksi fitur dan pelabelan telah mencerminkan proses awal yang kuat dalam membentuk dataset yang kaya dan informatif.

Selanjutnya, untuk menjawab rumusan masalah kedua, yaitu mengenai implementasi model U-Net dalam segmentasi area terbakar, penelitian ini membangun dan melatih arsitektur U-Net menggunakan lima kanal input yang telah dijelaskan sebelumnya. Proses *training* dilakukan dengan jumlah *epoch* sebanyak 200, menggunakan fungsi *loss Binary Cross Entropy(BCE)*. Model dilatih menggunakan GPU A100 melalui platform *Google Colab Pro* untuk mengakomodasi kebutuhan

komputasi yang tinggi akibat ukuran data yang besar dan jumlah pasangan data citra serta label yang mencapai 1008 pasang. Hal ini menunjukkan bahwa implementasi U-Net dilakukan secara *end-to-end* dengan pendekatan yang sistematis, mulai dari *data preprocessing*, ekstraksi fitur, pelabelan, hingga *training* model.

Dari sisi performa, penelitian ini menunjukkan akurasi *training* sebesar 0.97 dengan nilai *loss* sebesar 0.098, menggunakan jumlah *epoch* yang sama seperti pada penelitian Prabowo, yaitu sebanyak 200. Walaupun terdapat perlakuan memanfaatkan callback seperti *early stopping* dan *ReduceLROnPlateau*. Pada hasil penelitian ini yang menunjukkan nilai *loss* sedikit lebih tinggi dibandingkan penelitian Prabowo,dkk [5] yang mencapai *loss* sebesar 0.07, nilai akurasi yang lebih tinggi menunjukkan bahwa model mampu mempelajari pola area terbakar dengan lebih optimal. Hal ini mengindikasikan bahwa kombinasi input spektral yang lebih kaya dan strategi augmentasi yang lebih luas mampu meningkatkan performa generalisasi model.

Untuk menjawab rumusan masalah ketiga, yakni evaluasi model U-Net dalam segmentasi area terbakar, penelitian ini membandingkan hasil evaluasi model terhadap penelitian sebelumnya oleh Made, dkk [7]. Evaluasi dilakukan menggunakan empat metrik utama, yaitu *Binary Accuracy*, *Intersection over Union* (IoU), *Dice Coefficient*, dan nilai *loss Binary Cross Entropy* (BCE). Hasil perbandingan ditampilkan pada Tabel 4.11.

Tabel 4.11 Perbandingan performa segmentasi model U-Net

Evaluasi Model	Hasil Penelitian Penulis	Hasil Penelitian Made, dkk. (2023)
<i>Binary Accuracy</i>	0.94	0.95
IoU	0.71	0.78
<i>Dice Coefficient</i>	0.83	0.69
<i>Binary Cross-Entropy</i>	0.18	0.14

Nilai akurasi model dalam penelitian ini mencapai 0.94, sedikit lebih rendah dibandingkan nilai 0.95 pada penelitian Made. Namun, model dalam penelitian ini menunjukkan performa yang lebih baik pada metrik *Dice Coefficient*, yaitu sebesar 0.83 dibandingkan 0.69. Hal ini

menunjukkan bahwa model mampu menghasilkan segmentasi spasial yang lebih presisi, dengan tingkat kesesuaian yang lebih tinggi antara prediksi dan label sebenarnya. Meskipun nilai IoU yang diperoleh sebesar 0.71 berada sedikit di bawah nilai 0.78 pada penelitian Made, nilai tersebut masih berada pada kategori kinerja yang baik untuk segmentasi biner.

Nilai *Binary Cross Entropy* (BCE) yang diperoleh sebesar 0.18 sedikit lebih tinggi dibandingkan nilai 0.14 dari penelitian Made. Namun, perbedaan ini tergolong kecil dan masih dalam batas toleransi yang wajar. Secara keseluruhan, model menunjukkan performa yang kompetitif, terutama pada metrik *Dice Coefficient* yang sangat relevan dalam konteks tugas segmentasi area terbakar. Hal ini menegaskan bahwa pendekatan ekstraksi fitur berbasis kanal NDVI dan NBR, ditambah dengan metode pelabelan dNBR sebagai label segementasi, memberikan kontribusi yang signifikan dalam meningkatkan akurasi segmentasi. Namun, terdapat perbedaan hasil evaluasi model tersebut didasari dari penulis hanya menggunakan cakupan di Sumatera Selatan sedangkan peneliti Made(2023) mencakup beberapa wilayah seluruh Sumatera.

Lebih lanjut, penelitian ini memiliki keunggulan dalam hal pemanfaatan citra satelit terbaru, yaitu Landsat 9, yang memiliki keunggulan spektral dan temporal untuk pemantauan permukaan lahan secara berkala. Pengambilan dan praproses data dilakukan menggunakan platform *Google Earth Engine* (GEE), yang memberikan efisiensi dalam akuisisi dan pemrosesan data skala besar. Selain itu, implementasi model *deep learning* U-Net dikombinasikan dengan fitur spasial dan spektral yang relevan telah menghasilkan model segmentasi yang dapat diandalkan untuk deteksi area kebakaran di wilayah Sumatera Selatan pada tahun 2023.

Namun demikian, penelitian ini juga menghadapi beberapa keterbatasan. Proses *training* model memerlukan sumber daya komputasi yang besar, mengingat ukuran input citra yang cukup tinggi, jumlah kanal mencapai lima, serta jumlah pasangan data yang besar.

Proses ini hanya dapat berjalan optimal dengan dukungan GPU kelas atas seperti NVIDIA A100 melalui layanan *Google Colab Pro*. Dengan mempertimbangkan seluruh aspek tersebut, dapat disimpulkan bahwa penelitian ini berhasil menjawab ketiga rumusan masalah yang diajukan. Teknik ekstraksi fitur melalui penambahan kanal NDVI dan NBR terbukti efektif, implementasi arsitektur U-Net telah dilakukan dengan baik pada data Landsat 9, dan evaluasi model menunjukkan kinerja yang kompetitif serta relevan untuk segmentasi area terbakar di Sumatera Selatan pada tahun 2023.