

**SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL
U-NET PADA CITRA LANDSAT 9 (STUDI KASUS:
SUMATERA SELATAN)**

TUGAS AKHIR

ALBER ANALAFEAN

121450146



PROGRAM STUDI SAINS DATA

FAKULTAS SAINS

INSTITUT TEKNOLOGI SUMATERA

2025

**SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL
U-NET PADA CITRA LANDSAT 9 (STUDI KASUS:
SUMATERA SELATAN)**

TUGAS AKHIR

Diajukan sebagai syarat untuk memperoleh gelar Sarjana

**Alber Analafean
121450146**



**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2025**

HALAMAN PENGESAHAN

Tugas Akhir Sarjana dengan judul "**Segmentasi Burned Area Menggunakan Model U-Net pada Citra Landsat 9 (Studi Kasus: Sumatera Selatan)**" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 29 Agustus 2025

Penulis,

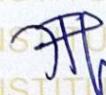


Alber Analafean

NIM. **121450146**



Diperiksa dan disetujui oleh,
Pembimbing I



Febsi Dwi Irawati, M.Si.
NIP. **199202122022032013**

Mika Alyionita S, M.Si.
NIP. **199305092025062003**

Pembimbing II

Disahkan oleh,

Koordinator Program Studi Sains Data

Fakultas Sains
Institut Teknologi Sumatera


Tirta Setiawan, S.Pd., M.Si.
NIP. **199008222022031003**

Sidang Tugas Akhir:

Pengaji I : Christyan Tamara Nadeak, M.Si.

Pengaji II : M. Syamsuddin Wisnubroto, M.Si.

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan benar.

Nama : Alber Analafean

NIM : 121450146

Tanda tangan : 

Tanggal : 29 Agustus 2025

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Alber Analafean
NIM : 121450146
Program Studi : Sains Data
Fakultas : Sains
Jenis karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan Hak Bebas Royalti Noneksklusif (*Non-Exclusive Royalty Free Right*) kepada Institut Teknologi Sumatera atas karya ilmiah saya yang berjudul:

Segmentasi *Burned Area* Menggunakan Model U-Net pada Citra Landsat 9 (Studi Kasus: Sumatera Selatan)

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan
Pada tanggal : 29 Agustus 2025

Yang menyatakan



Alber Analafean

ABSTRAK

Segmentasi *Burned Area* Menggunakan Model U-Net pada Citra Landsat 9 (Studi Kasus: Sumatera Selatan)

Alber Analafean (121450146)

Pembimbing I: Febri Dwi Irawati, M.Si.

Pembimbing II: Mika Alvionita S, M.Si.

Kebakaran hutan dan lahan (karhutla) merupakan salah satu bencana yang paling sering terjadi di Indonesia, dengan 144 kejadian tercatat pada Agustus 2023. Kondisi ini menegaskan pentingnya penanganan pasca karhutla yang efektif. Penelitian ini bertujuan untuk melakukan segmentasi area terbakar (*burned area*) menggunakan citra satelit Landsat 9 dengan pendekatan *deep learning* berbasis model U-Net. Citra diproses dalam bentuk multiband komposit, serta dilengkapi dengan ekstraksi fitur *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Burn Ratio* (NBR) sebagai input model. Pelatihan dan evaluasi model dilakukan pada wilayah Sumatera Selatan menggunakan metrik *Binary Accuracy*, *Intersection over Union* (IoU), *Dice Coefficient*, dan *Binary Cross Entropy Loss*. Hasil evaluasi menunjukkan nilai *Binary Accuracy* 0.93523, *Intersection over Union* (IoU) 0.70858, *Dice Coefficient* 0.82944, dan *Binary Cross Entropy* 0.18111. Hasil penelitian ini menunjukkan bahwa model U-Net dapat digunakan secara efektif dan efisien dalam mendeteksi area terbakar sebagai bagian dari sistem pemantauan karhutla berbasis citra satelit.

Kata kunci: *Burned Area, Deep Learning, U-Net, Segmentasi, Landsat 9.*

ABSTRACT

Burned Area Segmentation Using U-Net Model on Landsat 9 Imagery (Case Study: South Sumatra)

Alber Analafean (121450146)

Advisor I: Febri Dwi Irawati, M.Si.

Advisor II: Mika Alvionita S, M.Si.

Forest and land fires (karhutla) are among the most frequent disasters in Indonesia, with 144 incidents recorded in August 2023. This situation highlights the urgency of effective post-fire management. This study aims to perform burned area segmentation using Landsat 9 satellite imagery with a deep learning approach based on the U-Net model. The imagery was processed as multiband composites and supplemented with feature extraction of Normalized Difference Vegetation Index (NDVI) and Normalized Burn Ratio (NBR) as model inputs. The training and evaluation were conducted in the South Sumatra region using metrics such as Binary Accuracy, Intersection over Union (IoU), Dice Coefficient, and Binary Cross Entropy Loss. Evaluation results yielded an Binary Accuracy of 0.93523, IoU of 0.70858, Dice Coefficient of 0.82944, and Binary Cross Entropy of 0.18111. These findings demonstrate that the U-Net model can be effectively and efficiently utilized to detect burned areas as part of a satellite image-based karhutla monitoring system.

Keywords : *Burned Area, Deep Learning, U-Net, Segmentation, Landsat 9.*

MOTTO

"Data berbicara lebih jujur daripada opini; karena dalam deep learning, kekuatan model bukan berasal dari asumsi semata, melainkan dari pola yang jujur terbaca lewat data."

HALAMAN PERSEMBAHAN

Dengan penuh rasa syukur ke hadirat Allah SWT, Tugas Akhir ini
kupersembahkan kepada:

**Keluarga tercinta - Ayahanda Fevrymon, Ibunda Nur Akhtiartini,
dan adik-adik,** yang setia menemani dalam setiap *iteration*, memberi
makna dalam setiap *loss*, dan menjadi alasan utama mengapa proses
pembelajaran ini layak diperjuangkan.

Almamater Hitam ITERA, tempat penulis tumbuh, belajar, serta
berkembang, yang membentuk cara pandang serta kedewasaan sebagai
insan akademis dan pembelajar sejati di era *Artificial Intelligence* dan
Big Data yang bertumbuh begitu cepat seperti proses *training model*
Deep Learning pada GPU A100.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas berkah dan rahmat-Nya sehingga Tugas Akhir ini dapat terselesaikan dengan baik. Tugas Akhir ini dibuat untuk menyelesaikan pendidikan jenjang sarjana sains data pada Institut Teknologi Sumatera. Penyusunan Tugas Akhir ini banyak mendapat bantuan dan dukungan dari berbagai pihak sehingga dalam kesempatan ini, dengan penuh kerendahan hati, penulis mengucapkan terima kasih kepada:

1. Kedua orang tua serta keluarga, atas doa yang tak pernah henti dan kasih sayang tanpa batas sepanjang perjalanan ini.
2. Bapak Tirta Setiawan, S.Pd., M.Si. selaku Koordinator Program Studi Sains Data.
3. Ibu Febri Dwi Irawati, M.Si. selaku dosen pembimbing 1, atas bimbingan, waktu, kesabaran, dan ilmu yang telah diberikan dengan tulus selama proses penyusunan Tugas Akhir ini.
4. Ibu Mika Alvionita S, M.Si. selaku dosen pembimbing 2, atas waktu, arahan, dan masukan berharga yang sangat membantu dalam menyempurnakan tugas akhir ini.
5. Bapak Christyan Tamara Nadeak, M.Si. dan Bapak M. Syamsuddin Wisnubroto, M.Si. selaku dosen penguji, atas saran, kritik, dan evaluasi yang membangun demi penyempurnaan tugas akhir ini.
6. Teman-teman Sains Data Angkatan 2021 ITERA, atas kebersamaan, semangat, dukungan, dan tawa yang telah menjadi bagian tak terlupakan selama masa perkuliahan. Kalian adalah bagian penting dari perjalanan ini.
7. Teman-teman, kakak-kakak, saudara-saudari dan lainnya yang tidak bisa saya sebutkan satu persatu, telah ikut mengambil peran dan bagian dalam perjalanan studi penulis.

Penulis menyadari bahwa penyusunan tugas akhir ini jauh dari sempurna. Akhir kata penulis mohon maaf yang sebesar-besarnya apabila ada kekeliruan di dalam penulisan skripsi ini.

Lampung Selatan, 29 Agustus 2025



ALBER ANALAFEAN

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN	ii
HALAMAN PERNYATAAN ORISINALITAS	iii
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI .	iv
ABSTRAK	v
ABSTRACT	vi
MOTTO	vii
HALAMAN PERSEMBAHAN	viii
KATA PENGANTAR	ix
DAFTAR ISI	xi
DAFTAR GAMBAR	xiii
DAFTAR TABEL	xv
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	3
1.5 Manfaat Penelitian	3
II TINJAUAN PUSTAKA	5
2.1 <i>Burned Area</i>	5
2.2 Landsat 9	6
2.3 Ekstraksi Fitur	8
2.3.1 <i>Normalized Difference Vegetation Index (NDVI)</i> .	8
2.3.2 <i>Normalized Burn Ratio (NBR)</i>	9
2.3.3 <i>Difference Normalized Burn Ratio (dNBR)</i>	9
2.4 Model U-Net	9
2.4.1 Konvolusi, Max Pooling dan Konvolusi Transpos .	17
2.4.1.1 Konvolusi	17

2.4.1.2 <i>Max Pooling</i>	17
2.4.1.3 <i>Konvolusi Transpos</i>	18
2.5 <i>Overlapping Citra</i>	18
2.6 Fungsi Aktivasi	19
2.6.1 <i>Rectified Linear Unit (ReLU)</i>	19
2.6.2 <i>Sigmoid</i>	19
2.7 Evaluasi Model	20
2.7.1 <i>Confusion Matrix</i>	20
2.7.2 <i>Binary Accuracy</i>	20
2.7.3 <i>Intersection over Union (IoU)</i>	21
2.7.4 <i>Dice Coefficient</i>	21
2.7.5 <i>Binary Cross Entropy</i>	21
III METODE PENELITIAN	23
3.1 Daerah Penelitian	23
3.2 Deskripsi Data	23
3.3 Perangkat Komputasi	24
3.4 Tahapan Penelitian	25
3.4.1 <i>Data Preprocessing</i>	27
3.4.1.1 <i>Koreksi Atmosferik</i>	27
3.4.1.2 <i>Cloud Masking</i>	27
3.4.1.3 <i>Komposit Citra</i>	28
3.4.2 <i>Ekstraksi Fitur</i>	28
3.4.2.1 <i>Normalized Difference Vegetation Index (NDVI)</i>	28
3.4.2.2 <i>Normalized Burn Ratio (NBR)</i>	29
3.4.2.3 <i>differenced Normalized Burn Ratio (dNBR)</i>	29
3.4.3 <i>Band Stacking</i>	30
3.4.4 <i>Masking Citra</i>	30
3.4.5 <i>Split Data</i>	31
3.4.6 <i>Model U-Net</i>	31
3.4.7 <i>Evaluasi Model</i>	33
IV HASIL DAN PEMBAHASAN	35
4.1 Deskripsi Data	35
4.2 <i>Data Preprocessing</i>	41
4.2.1 <i>Koreksi Atmosferik</i>	41

4.2.2 <i>Cloud Masking</i>	42
4.2.3 Komposit Citra	43
4.3 Ekstraksi Fitur	44
4.3.1 <i>Normalized Difference Vegetation Index (NDVI)</i>	44
4.3.2 <i>Normalized Burn Ratio (NBR)</i>	47
4.3.3 <i>Difference Normalized Burn Ratio (dNBR)</i>	50
4.4 <i>Masking Citra</i>	52
4.5 <i>Band Stacking</i>	54
4.6 <i>Split Data</i>	55
4.7 Model U-Net	58
4.8 Evaluasi Model	61
4.9 Pembahasan segmentasi <i>burned area</i>	63
V KESIMPULAN DAN SARAN	68
5.1 Kesimpulan	68
5.2 Saran	68
DAFTAR PUSTAKA	70
LAMPIRAN	76
A Data Penelitian	77
B Perhitungan Manual Konvolusi	79
C Perhitungan Manual Konvolusi Transpos	84
D Perhitungan Manual Fungsi Aktivasi	86
E Perhitungan Manual <i>Max Pooling</i>	88
F Perhitungan Manual Evaluasi model	89
G Dataset dan Prediksi Segmentasi <i>Burned Area</i>	91

DAFTAR GAMBAR

Gambar 2.1	BPBD memadamkan Karhutla [9]	5
Gambar 2.2	Satelite Landsat 9 [11]	6
Gambar 2.3	Ilustrasi reflektansi [13]	7
Gambar 2.4	Arsitektur U-Net untuk segmentasi citra satelit [5]	11
Gambar 2.5	Ilustrasi <i>cross-correlation</i> (konvolusi) [27]	17
Gambar 2.6	Ilustrasi max pooling [27]	17
Gambar 2.7	Ilustrasi konvolusi transpos [30]	18
Gambar 2.8	Ilustrasi <i>Overlapping</i>	19
Gambar 2.9	<i>Confusion Matrix</i> [33]	20
Gambar 3.1	Peta lokasi penelitian	23
Gambar 3.2	Diagram Alir Penelitian	26
Gambar 3.3	Rancangan Arsitektur U-Net	32
Gambar 3.4	Ilustrasi Model U-Net	33
Gambar 3.5	Ilustrasi Evaluasi Model	34
Gambar 4.1	Raster Landsat per band: (a) band 4, (b) band 5 dan (c) band 7	38
Gambar 4.2	Distribusi reflektansi Pahtrow 124062 - <i>Prefire</i>	39
Gambar 4.3	Distribusi reflektansi Pahtrow 125062 - <i>Prefire</i>	39
Gambar 4.4	Distribusi reflektansi Pahtrow 124062 - <i>Postfire</i>	40
Gambar 4.5	Distribusi reflektansi Pahtrow 125062 - <i>Postfire</i>	40
Gambar 4.6	Koreksi Atmosferik (DOS) pada kondisi <i>prefire</i> dan <i>postfire</i>	42
Gambar 4.7	Cloud Masking (QA Bands) pada kondisi <i>prefire</i> dan <i>postfire</i>	43
Gambar 4.8	Komposit Citra (<i>False Color</i>) pada kondisi <i>prefire</i> dan <i>postfire</i>	44
Gambar 4.9	Citra NDVI pada pathrow 124062 dan pathrow 125062	45
Gambar 4.10	Histogram NDVI pathrow 124062	46
Gambar 4.11	Histogram NDVI pathrow 125062	47

Gambar 4.12 Citra NBR pada <i>pathrow</i> 125062 dan <i>pathrow</i>	
124062	48
Gambar 4.13 Histogram NBR <i>pathrow</i> 124062	49
Gambar 4.14 Histogram NBR <i>pathrow</i> 125062	50
Gambar 4.15 Citra dNBR pada <i>pathrow</i> 124062 dan 125062	51
Gambar 4.16 Histogram dNBR Pahtrow 124062	51
Gambar 4.17 Histogram dNBR <i>pathrow</i> 125062	52
Gambar 4.18 Citra <i>mask</i> pada <i>pathrow</i> 124062 dan 125062	53
Gambar 4.19 Disribusi piksel citra <i>mask pathrow</i> 124062	53
Gambar 4.20 Disribusi piksel citra <i>mask pathrow</i> 125062	54
Gambar 4.21 Sampel citra tidak layak	56
Gambar 4.22 Sampel citra layak digunakan dalam segmentasi	57
Gambar 4.23 Pengunaan resource sistem	59
Gambar 4.24 Grafik loss dan akurasi model	60
Gambar 4.25 Citra prediksi segmentasi model U-Net	63

DAFTAR TABEL

Tabel 2.1	Deskripsi Band Sensor OLI dan TIRS Landsat 9	8
Tabel 2.2	Penelitian terdahulu menggunakan model U-Net untuk segmentasi citra.	12
Tabel 3.1	Rentang Waktu Data	24
Tabel 3.2	Informasi Spesifikasi Perangkat Keras <i>Google Colaboratory Pro</i>	25
Tabel 3.3	Informasi Spesifikasi Library	25
Tabel 3.4	Bit QA Bands	27
Tabel 3.5	Interpretasi Nilai NDVI	29
Tabel 3.6	Interpretasi Nilai dNBR	30
Tabel 3.7	Konfigurasi Hyperparameter Model	33
Tabel 4.1	Daftar citra Landsat 9 TOA <i>pathrow 124062 kondisi Prefire</i>	35
Tabel 4.2	Daftar citra Landsat 9 TOA <i>pathrow 125062 kondisi Prefire</i>	36
Tabel 4.3	Daftar citra Landsat 9 TOA <i>pathrow 124062 kondisi Postfire</i>	36
Tabel 4.4	Daftar citra Landsat 9 TOA <i>pathrow 125062 kondisi Postfire</i>	37
Tabel 4.5	Urutan Band citra <i>multiband</i> disimpan	54
Tabel 4.6	Jumlah <i>patch</i> citra sebelum filtering	56
Tabel 4.7	Jumlah data setelah filtering	57
Tabel 4.8	Rasio <i>split data</i>	58
Tabel 4.9	Parameter model U-Net	60
Tabel 4.10	Hasil Evaluasi Model	61
Tabel 4.11	Perbandingan performa segmentasi model U-Net	65

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia mengalami 144 kejadian kebakaran hutan dan lahan (karhutla) pada bulan Agustus 2023, yang tercatat mencapai 64,29% dari total bencana bulan itu. Berdasarkan pernyataan Badan Nasional Penanggulangan Bencana (BNPB), mayoritas karhutla di Kalimantan dan Sumatera terjadi di lahan gambut [1]. Kejadian kebakaran hutan dan lahan di Desa Jungkal di Sumatera Selatan pada 2023, merupakan salah satu yang terbesar dengan ribuan hektar lahan terbakar pada tahun tersebut [2]. Dampak kebakaran hutan dan lahan (karhutla) dapat merusak ekosistem serta mengancam keberlangsungan flora dan fauna di hutan. Di Provinsi Sumatera Selatan, bencana ini menyebabkan kerugian besar dialami masyarakat, baik di sektor ekonomi maupun lingkungan [3]. Sehingga, diperlukannya upaya dalam melakukan pemantauan dan deteksi *burned area* dalam penanganan pasca kebakaran hutan dan lahan (karhutla).

Pemetaan area terbakar sangat penting untuk memantau kondisi hutan dan menghitung laju deforestasi tahunan. Namun karena cakupan hutan Indonesia yang luas, survei lapangan tidak cukup sehingga penggunaan *remote sensing* dengan citra satelit menjadi solusi efektif. Salah satu satelit yang digunakan adalah Landsat 9, yang dapat mendeteksi bekas kebakaran pada lahan vegetasi. Dalam *remote sensing*, pemetaan area terbakar dapat dilakukan melalui dua metode utama yaitu interpretasi visual, yang akurat namun membutuhkan waktu dan biaya yang besar, serta klasifikasi digital, yang lebih cepat dan efisien. Dengan dukungan kecerdasan buatan, klasifikasi digital menjadi metode unggulan dalam pemantauan *burned area* secara berkala dan akurat [4][5].

Berbagai pendekatan telah digunakan untuk memetakan area terbakar, salah satunya adalah Indeks Spektral seperti *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Burn Ratio* (NBR). Penelitian ini menunjukkan bahwa indeks ini mampu mengidentifikasi

tingkat keparahan kebakaran dan pemulihan vegetasi, dengan hasil bervariasi dari sedang hingga tinggi. Namun, metode ini terbatas dalam mengenali pola kompleks dan kurang dalam generalisasi [6]. Pendekatan *deep learning* seperti U-Net telah digunakan untuk mendeteksi karhutla di Sumatera. Pada pendekatan tersebut diperoleh hasil bahwa model U-Net menggunakan citra *false color* Landsat 8 mencapai akurasi 0.95, *IoU* 0.78, *dice coefficient* 0.69, dan *binary cross entropy* 0.14, yang menunjukkan performa stabil dan akurat [7]. Sementara itu, pendekatan serupa menemukan bahwa model serupa dengan citra Landsat 8 menghasilkan *jaccard index* 0.93 dan *loss* 0.07 setelah 200 *epochs*, mengindikasikan deteksi area terbakar yang sangat efektif [5]. Landsat 8 dan 9 adalah satelit pengamat Bumi yang menyediakan citra multispektral dan termal dengan resolusi menengah secara global. Landsat 9 membawa peningkatan signifikan melalui dua sensor utama OLI-2 dan TIRS-2 yang menghasilkan kualitas citra lebih baik dan akurasi suhu permukaan yang lebih tinggi. Satelit ini juga mampu merekam data *off-nadir* hingga ± 15 derajat, serta memiliki kapasitas penyimpanan lebih besar, memungkinkan cakupan dan pengelolaan data yang lebih efisien[4].

Berdasarkan beberapa penelitian [5][7], pendekatan segmentasi *burned area* menggunakan model U-Net menunjukkan hasil yang sangat baik. Sehingga penelitian ini menerapkan model U-Net dalam segmentasi *burned area* menggunakan citra satelit Landsat 9 di Sumatera Selatan. Model ini akan menerima input berupa citra *multiband* terdiri dari kombinasi citra komposit, NDVI, serta NBR. Evaluasi model dilakukan menggunakan *Binary Accuracy*, *IoU*, *Dice Coefficient*, dan *Binary Cross-Entropy*. Penelitian ini bertujuan untuk melakukan segmentasi *burned area* dan *non burned* di Sumatera selatan berbasis citra satelit Landsat 9 dalam mendukung pemantauan *burned area* secara efektif dan efisien.

1.2 Rumusan Masalah

Dalam upaya mewujudkan segmentasi *burned area* di Sumatera Selatan menggunakan citra Landsat 9, rumusan masalah utama dalam penelitian

ini yaitu:

1. Bagaimana teknik ekstraksi fitur dari citra Landsat 9 dalam segmentasi *burned area* di Sumatera Selatan?
2. Bagaimana implementasi model U-Net dalam segmentasi *burned area* menggunakan citra Landsat 9 di Sumatera Selatan?
3. Bagaimana evaluasi model U-Net dalam segmentasi *burned area* menggunakan citra Landsat di Sumatera Selatan?

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Menerapkan ekstraksi fitur (*Normalized Difference Vegetation Index*, *Normalized Burn Ratio*, dan *differenced Normalized Burn Ratio*) dalam segmentasi *burned area* di Sumatera Selatan menggunakan citra satelit Landsat 9.
2. Menerapkan model U-Net dalam segmentasi *burned area* di Sumatera Selatan berbasis citra satelit Landsat 9.
3. Menerapkan evaluasi model U-Net dalam segmentasi *burned area* di Sumatera Selatan berbasis citra satelit Landsat 9.

1.4 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus sesuai tujuan penelitian, maka ditetapkan beberapa batasan. Cakupan Wilayah Penelitian ini dibatasi pada wilayah Provinsi Sumatera Selatan dengan menggunakan citra Landsat 9 TOA (*Top Of Atmosphere*) pada *pathrow* 124062 dan 125062.

1.5 Manfaat Penelitian

Adapun penelitian ini memiliki manfaat sebagai berikut:

1. Memberikan kontribusi dalam perkembangan *remote sensing* dan *deep learning* berupa dataset citra berlabel untuk segmentasi ataupun klasifikasi.

2. Memberikan hasil penelitian yang dapat dimanfaatkan secara aplikatif oleh BMKG, BNPB, dan BPBD Sumatera Selatan untuk mendukung deteksi, pemetaan, serta pengambilan keputusan pasca-karhutla.
3. Menyediakan data spasial akurat yang berkontribusi pada upaya mitigasi, rehabilitasi, dan pencegahan kebakaran hutan dan lahan di Sumatera Selatan.

BAB II

TINJAUAN PUSTAKA

2.1 *Burned Area*

Kejadian kebakaran hutan semakin meluas di berbagai belahan dunia, berdasarkan penelitian terbaru dalam beberapa dekade terakhir [8]. Sehingga kejadian tersebut menyebabkan terdapatnya area yang terbakar (*burned area*) dapat menyebabkan hilangnya tutupan vegetasi, yang berdampak pada proses hidrologi, komposisi tanaman, dan erosi tanah [8]. Kebakaran hutan juga melepaskan banyak partikel dan gas rumah kaca dalam jumlah besar, seperti karbon dioksida (CO₂), karbon monoksida (CO), serta partikel kasar (PM10) dan halus (PM2.5) [8]. Luas area yang terbakar menjadi faktor utama dalam menghitung jumlah biomassa yang terbakar akibat kebakaran hutan [8]. Diperkirakan, sekitar 32% karbon monoksida dan 40% karbon dioksida di atmosfer berasal dari biomassa yang terbakar, yang memperburuk pemanasan global [8].



Gambar 2.1 BPBD memadamkan Karhutla [9]

Namun, luas area terbakar bukan satu-satunya faktor dalam menghitung jumlah biomassa yang terbakar [8]. Faktor lain yang juga berpengaruh adalah jumlah biomassa sebelum kebakaran [8]. Estimasi luas lahan yang terbakar sangat penting untuk memahami berbagai tantangan ekologis dan ilmiah, seperti perubahan fungsi ekosistem akibat gangguan dan fluks karbon [8]. Selain itu, area yang terbakar memengaruhi kualitas udara, kesehatan manusia, serta siklus umpan balik iklim-karbon [8]. Setiap tahunnya, kebakaran hutan diperkirakan melepaskan sekitar 1,6-2,8 PgC karbon ke atmosfer, yang setara

dengan 20-30% emisi karbon dari pembakaran bahan bakar fosil saat ini [8].

2.2 Landsat 9

Program Landsat adalah serangkaian misi satelit pengamat Bumi yang dikelola bersama oleh *The National Aeronautics and Space Administration (NASA)* dan *United States Geological Survey (USGS)* [7]. Hingga saat ini, telah diluncurkan sembilan satelit ke luar angkasa, tetapi hanya dua yang masih beroperasi, yaitu Landsat 8 dan Landsat 9 [7]. Landsat 9 merupakan satelit terbaru dalam rangkaian misi Landsat yang diluncurkan pada tahun 2021 untuk melanjutkan pengamatan Bumi secara konsisten dan berkelanjutan [10].

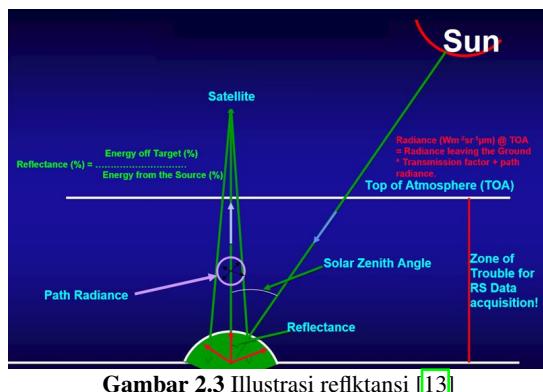


Gambar 2.2 Satelit Landsat 9 [11]

Satelit ini membawa dua sensor utama, yaitu *Operational Land Imager-2* (OLI-2) dan *Thermal Infrared Sensor-2* (TIRS-2) [10]. Dibandingkan dengan pendahulunya, OLI-1 pada Landsat 8, OLI-2 memiliki peningkatan pada akurasi radiometrik dari 12 menjadi 14 bit, serta rasio sinyal terhadap *noise* yang lebih baik [10]. Hal ini memungkinkan Landsat 9 mendekripsi perbedaan yang lebih halus, khususnya di area gelap seperti perairan atau hutan lebat [10]. Dalam hal resolusi spasial, baik Landsat 8 maupun Landsat 9 memiliki spesifikasi serupa pada sensor OLI, yaitu 30 meter untuk band multispektral, 15 meter untuk band pankromatik, dan 100 meter untuk band inframerah termal dari sensor TIRS [10].

Perbedaan utama terdapat pada rentang spektral masing-masing band, di mana OLI-2 memiliki sedikit perbedaan panjang gelombang dibandingkan OLI-1, seperti pada band biru (B2) yang berbeda sekitar 2 nm [10]. Pada Landsat informasi area permukaan bumi

direpresentasikan dalam bentuk reflektansi. Reflektansi merupakan perbandingan antara jumlah radiasi gelombang elektromagnetik yang dipantulkan oleh suatu permukaan dengan jumlah radiasi gelombang elektromagnetik yang diterimanya [12]. Gambar 2.3 menunjukkan ilustrasi reflektansi, di mana radiasi matahari melewati atmosfer, mengenai permukaan Bumi, dan sebagian dipantulkan kembali menuju sensor satelit. Energi yang terdeteksi oleh sensor tidak semata-mata berasal dari pantulan permukaan, tetapi juga mencakup kontribusi hamburan atmosfer (*path radiance*) serta dipengaruhi oleh faktor geometris seperti sudut datang radiasi matahari (*solar zenith angle*).



Gambar 2.3 Ilustrasi reflktansi [13]

Resolusi temporal satelit Landsat 9 mampu merekam ulang area yang sama setiap 16 hari [10]. Karena satelit Landsat 9 memungkinkan pengambilan data dengan frekuensi yang lebih tinggi, memperkaya ketersediaan data untuk berbagai aplikasi analisis perubahan lahan dan lingkungan secara lebih detail dan akurat [10]. Data Landsat telah digunakan dalam berbagai aplikasi pemerintah, publik, swasta, dan keamanan nasional. Contohnya meliputi pengelolaan lahan dan air, penelitian perubahan global, eksplorasi minyak dan mineral, peramalan hasil pertanian, pemantauan polusi, deteksi perubahan permukaan lahan, dan pemetaan kartografi [4]. Berikut deskripsi band sensor OLI dan TIRS beserta *range* band pada citra Landsat 9 pada tabel 2.1 [4].

Tabel 2.1 Deskripsi Band Sensor OLI dan TIRS Landsat 9

<i>Band Number</i>	<i>Band Description</i>	<i>Band Range (nm)</i>
<i>OLI-2 Sensors</i>		
1	<i>Coastal Aerosol</i>	435–451
2	<i>Blue</i>	452–512
3	<i>Green</i>	533–590
4	<i>Red</i>	636–673
5	<i>Near-Infrared (NIR)</i>	851–879
6	<i>Short Wavelength Infrared (SWIR) 1</i>	1566–1651
7	<i>Short Wavelength Infrared (SWIR) 2</i>	2107–2294
8	<i>Panchromatic</i>	503–676
9	<i>Cirrus</i>	1363–1384
<i>TIRS-2 Sensors</i>		
10	<i>Thermal Infrared Sensor 1</i>	10600–11190
11	<i>Thermal Infrared Sensor 2</i>	11500–12510

Pathrow adalah sistem koordinat berbasis *Worldwide Reference System-2* (WRS-2) yang digunakan untuk mendeskripsikan lokasi citra Landsat di permukaan bumi. Sistem ini membagi permukaan bumi menjadi grid yang diidentifikasi oleh nomor *path* (jalur lintasan satelit dari utara ke selatan) dan *row* (posisi baris dari barat ke timur pada jalur tersebut). Setiap citra mencakup area seluas $185\text{ km} \times 180\text{ km}$, dengan resolusi spasial 30 meter per piksel, yang merepresentasikan area seluas $30\text{ m} \times 30\text{ m}$ di permukaan bumi [4].

2.3 Ekstraksi Fitur

2.3.1 Normalized Difference Vegetation Index (NDVI)

Normalized Difference Vegetation Index (NDVI) merupakan indeks vegetasi yang populer karena mampu menunjukkan kondisi kesehatan tanaman secara langsung. Indeks ini bekerja dengan menghitung perbedaan ternormalisasi pada panjang gelombang yang diserap dan dipantulkan oleh klorofil. Metode ini membuat NDVI sangat informatif dalam berbagai kondisi. Vegetasi dapat diidentifikasi dengan menetapkan ambang batas nilai tinggi, sehingga elemen lain dengan pantulan lebih rendah dapat disaring atau diabaikan [14]. Persamaan 2.1 digunakan untuk menghitung NDVI dengan memanfaatkan *Near Infrared* (NIR) pada band 5 dan RED pada band 4

citra Landsat 9.

$$NDVI = \frac{NIR - RED}{NIR + RED}. \quad (2.1)$$

2.3.2 Normalized Burn Ratio (NBR)

Normalized Burn Ratio (NBR) adalah indeks penginderaan jauh yang banyak digunakan untuk mengidentifikasi area terbakar dan mengklasifikasikan tingkat keparahan kebakaran hutan. NBR terutama digunakan untuk mendeteksi kebakaran, sedangkan *differenced Normalized Burn Ratio* (dNBR) lebih sering digunakan untuk menilai tingkat keparahan kebakaran [15]. Persamaan 2.2 digunakan untuk menghitung NBR dengan memanfaatkan *Near Infrared* (NIR) pada band 5 dan *Shortwave Infrared* (SWIR) pada band 7 citra Landsat 9.

$$NBR = \frac{NIR - SWIR}{NIR + SWIR}. \quad (2.2)$$

2.3.3 Difference Normalized Burn Ratio (dNBR)

Differenced Normalized Burn Ratio (dNBR) adalah indeks penginderaan jauh yang digunakan untuk mengukur tingkat keparahan kebakaran hutan dengan cara membandingkan nilai *Normalized Burn Ratio* (NBR) sebelum dan sesudah kebakaran. NBR sendiri dihitung dari rasio perbedaan pantulan spektral pita *near-infrared* (NIR) dan *shortwave infrared* (SWIR2)[15]. Persamaan 2.3 digunakan untuk menghitung dNBR dengan memanfaatkan *NBRPrefire* merupakan NBR sebelum kejadian kebakaran dan *NBRPostfire* merupakan NBR setelah kejadian kebakaran.

$$dNBR = NBRPrefire - NBRPostfire. \quad (2.3)$$

2.4 Model U-Net

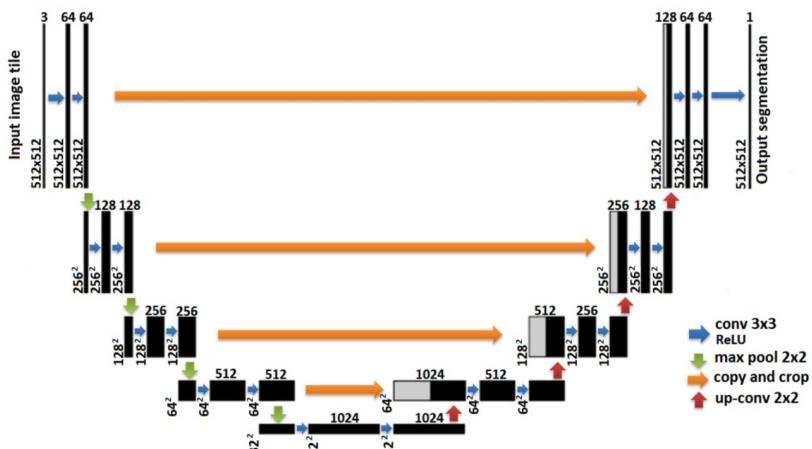
Arsitektur U-Net adalah jenis *Convolutional Neural Network* (CNN) yang dirancang khusus untuk segmentasi citra [16]. U-Net dikembangkan oleh Ronneberger et al.(2015) untuk segmentasi citra

biomedis, yang dimodifikasi agar dapat menghasilkan segmentasi presisi tinggi meskipun dengan jumlah data pelatihan yang terbatas [17]. Struktur U-Net berbentuk huruf "U" yang terdiri dari 4 blok *encoder* (kontraksi) dan 4 blok *decoder* (ekspansi), yang dihubungkan oleh *bottleneck* [16]. Pada lapisan *encoder*, U-Net mengekstrak informasi kontekstual dari citra menggunakan serangkaian lapisan konvolusi terdiri dari dua konvolusi 3×3 , yang dilengkapi dengan fungsi aktivasi ReLU, diikuti oleh operasi *max-pooling* 2×2 dengan stride 2 untuk mengecilkan ukuran fitur merupakan proses *downsampling* [16] [17].

Pada arsitektur U-Net, terdapat bagian *bottleneck* berada di antara *encoder* dan *decoder* yang berfungsi menangkap fitur paling abstrak dari citra. *Bottleneck* terdiri dari dua lapisan konvolusi 3×3 dengan fungsi aktivasi ReLU [16] [18]. Selanjutnya pada lapisan *decoder*, U-Net merekonstruksi citra dari fitur-fitur abstrak yang ditangkap pada bagian *bottleneck*. Jalur ini terdiri dari serangkaian operasi *upsampling* dengan konvolusi 2×2 ("up-convolution") yang mengurangi jumlah saluran fitur menjadi setengah, dilanjutkan dengan penggabungan (*concatenation*) dengan *feature map* dari jalur *encoder*, serta dua konvolusi 3×3 yang masing-masing diikuti oleh fungsi aktivasi ReLU [16] [7].

Selain itu, bagian *skip connection* pada arsitektur U-Net merupakan komponen sangat penting. Bagian *Skip connection* pada U-Net menghubungkan langsung lapisan *encoder* dan *decoder* untuk mempertahankan informasi spasial yang hilang saat *downsampling*. Hal ini memungkinkan deteksi struktur halus dan tepi objek secara lebih akurat, yang penting dalam segmentasi. Dengan menggabungkan detail spasial dari lapisan dangkal dan konteks dari lapisan dalam, model menghasilkan segmentasi yang lebih presisi [16]. Lapisan terakhir adalah lapisan konvolusi 1×1 dengan fungsi aktivasi sigmoid, yang menghasilkan nilai probabilitas per piksel dari citra masukan. Fungsi sigmoid digunakan untuk tugas segmentasi atau klasifikasi biner. Namun, jika digunakan untuk tugas segmentasi atau klasifikasi dengan lebih dari dua kelas menggunakan fungsi softmax [19] [20].

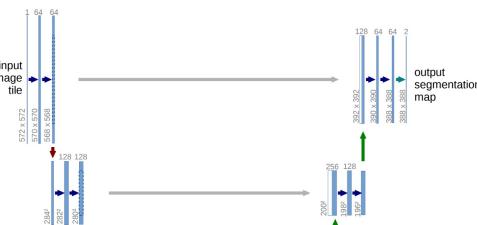
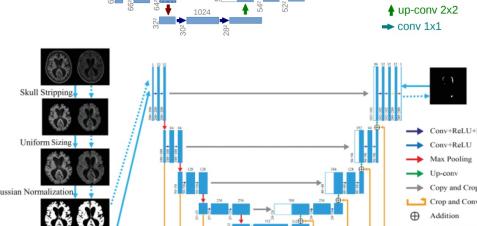
Gambar 2.4 merupakan arsitektur U-Net digunakan segmentasi dengan memanfaatkan data citra satelit [5].



Gambar 2.4 Arsitektur U-Net untuk segmentasi citra satelit [5]

Pada Tabel 2.2 menunjukkan penelitian terdahulu menggunakan model U-Net untuk segmentasi citra.

Tabel 2.2 Penelitian terdahulu menggunakan model U-Net untuk segmentasi citra.

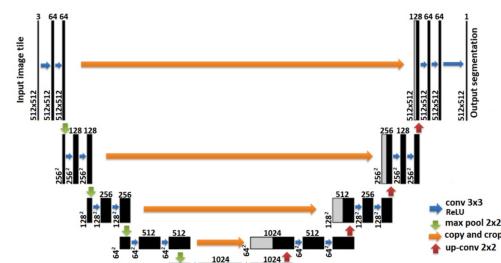
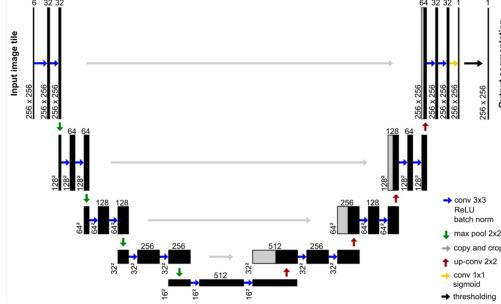
Referensi	Data	Hasil	Arsitektur
Olaf Ronneberger, dkk (2015) [17]	Citra Biomedis Mikroskopis (Neuron struktur)	U-Net berhasil meningkatkan segmentasi citra biomedis dengan akurasi tinggi, mencatat IOU 92% (PhC-U373), 77.5% (DIC-HeLa), serta <i>warping error</i> 0.00035 pada data neuron EM. Model ini juga sangat cepat, memproses gambar < 1 detik di GPU.	
Jiong Wu, dkk (2019) [21]	Citra MRI	Model SC U-Net dengan <i>skip connection</i> untuk segmentasi WMH dari MRI mencapai <i>Dice score</i> 78.36%, lebih tinggi dari model U-Net sebelumnya (74.99%). <i>Skull-stripping</i> dan augmentasi data meningkatkan akurasi lintas-scanner.	

Lisa Knopp, Citra
dkk (2020) Sentinel-
[22] 2

Mengembangkan model segmentasi area kebakaran berbasis *deep learning* menggunakan arsitektur U-Net pada citra Sentinel-2. Model dilatih dengan kombinasi spektral optimal (RGB, NIR, SWIR) untuk meningkatkan akurasi segmentasi. Hasil penelitian menunjukkan model U-Net mencapai akurasi 98% dengan kappa 94%, serta kecepatan inferensi yang jauh lebih cepat dibanding metode *Random Forest*, menjadikannya efektif untuk pemetaan cepat area kebakaran tanpa membutuhkan data pra-kejadian.

Yudhi Landsat-8
Prabowo,
dkk (2022)
[5]

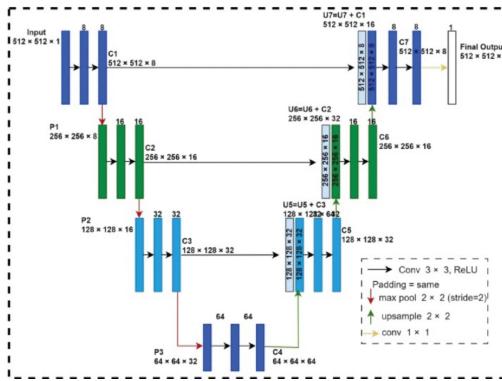
Model U-Net menunjukkan kinerja baik dengan *Jaccard Index* 0.93 dan nilai *loss* 0.07 setelah 200 *epoch* pelatihan. Penggunaan *false color composite* (SWIR-2, NIR, Red) terbukti efektif untuk visualisasi area terbakar.



- I. Made Lansat-8
Murwantara,
dkk (2023) 2
[7]
- Model terbaik menggunakan citra *false color* pada Lansat-8, mencapai *Binary Accuracy* 0.95, IoU 0.78, *Dice Coefficient* 0.69, dan *Binary Cross-Entropy Loss* 0.14. *False color* lebih efektif untuk mengidentifikasi area terbakar dibandingkan natural color.

- Iftikhar CT Scan
Naseer, dkk (Paru-paru)
(2023) [23]
- Menggunakan Attention U-Net untuk segmentasi *white matter hyperintensities* (WMH) pada citra MRI. Mekanisme atensi memperkuat fitur spasial penting, meningkatkan akurasi segmentasi. Hasil menunjukkan peningkatan signifikan dibanding U-Net biasa, dengan *Dice score* mencapai 88.73%, lebih tinggi dari 85.12% pada model *baseline*.

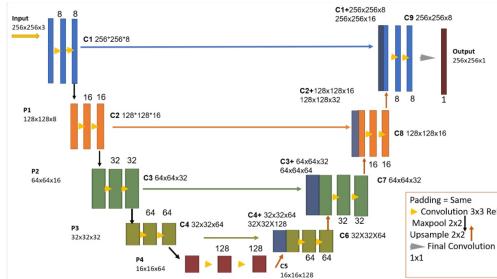
Tidak Digambarkan, hanya dijelaskan jumlah filter awal digunakan yaitu antara 16 hingga 32



Nair Shruti,
Landsat-8
dkk (2024)

[14]

Model U-Net dengan ResNet50 memiliki akurasi lebih baik daripada DeepLabV3+, mencapai akurasi 86.92% dan IoU 83.12%. Penambahan data sintetis hingga 22.85% dari total dataset meningkatkan akurasi model. Band NDVI, SWIR, dan NIR meningkatkan segmentasi dibandingkan RGB tradisional.

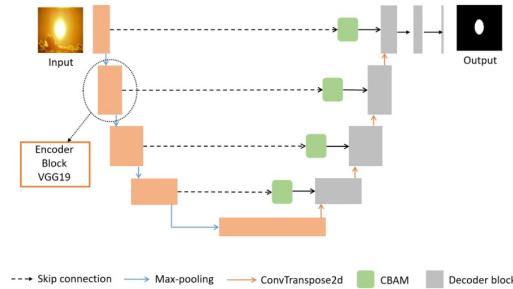


15

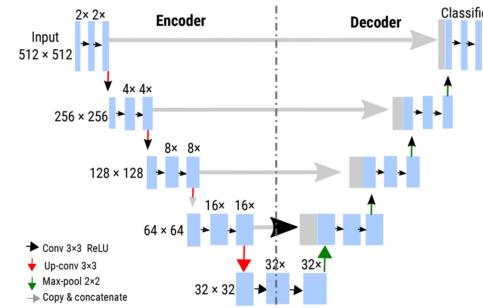
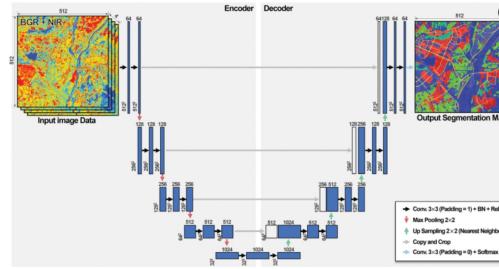
Nabila Zirira,
Citra Sun
dkk (2024)
Glare
(efek silau
matahari)

[16]

Penggunaan GCBAM-UNet, gabungan VGG19-UNet dan CBAM untuk meningkatkan segmentasi *sun glare*. Dengan 200 citra yang diaugmentasi menjadi 1.200, model ini diperoleh akurasi 92.78%, Dice 86.09%, IoU 66.52%, sensitivitas 90.13%, dan spesifitas 99.21%, melampaui U-Net dan SegNet karena CBAM mampu memfokuskan fitur penting pada kanal dan spasial sehingga hasil segmentasi lebih presisi.



Won Kyung Baek, dkk (2024) [24]	Sentinel-2	Model SiU-Net dengan input terpisah RGB dan NIR mampu meningkatkan akurasi klasifikasi tutupan lahan dibandingkan U-Net dan DeepLabV3+, dengan F1 Score tertinggi 0.797. SiU-Net efektif mengurangi bias pada data tidak seimbang dan lebih baik dalam mendeteksi batas objek, terutama pada kelas minoritas.
Fernando Pech-May, dkk (2024) [25]	Sentinel-1 SAR	Model U-Net untuk segmentasi daerah banjir dengan citra SAR Sentinel-1 di wilayah Tabasco, Meksiko. Model dilatih menggunakan dataset Sen1Floods11 dan menunjukkan kinerja terbaik pada 200 epoch dengan akurasi 94.31% dan IoU score sebesar 73.02%. Hasil ini menunjukkan bahwa U-Net mampu mengidentifikasi area banjir secara efektif meskipun terdapat tantangan ketidakseimbangan data dan kompleksitas citra radar.



2.4.1 Konvolusi, Max Pooling dan Konvolusi Transpos

2.4.1.1 Konvolusi

Konvolusi merupakan proses inti yang menerapkan filter pada data input untuk menghasilkan peta fitur, melibatkan perkalian elemen demi elemen antara filter dan bagian lokal dari input, diikuti oleh penjumlahan hasilnya [26]. Dengan cara ini, dapat mengenali pola spasial seperti tepi, tekstur, atau bentuk kompleks, dan menyusunnya secara bertingkat menjadi representasi fitur tingkat tinggi [26]. Gambar 2.5 menunjukkan proses *cross-correlation* yang juga disebut konvolusi [27].

Input	Kernel	Output													
<table border="1" style="display: inline-table; vertical-align: middle;"><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	\ast	<table border="1" style="display: inline-table; vertical-align: middle;"><tr><td>0</td><td>1</td></tr><tr><td>2</td><td>3</td></tr></table>	0	1	2	3
0	1	2													
3	4	5													
6	7	8													
0	1														
2	3														
	=	<table border="1" style="display: inline-table; vertical-align: middle;"><tr><td>19</td><td>25</td></tr><tr><td>37</td><td>43</td></tr></table>	19	25	37	43									
19	25														
37	43														

Gambar 2.5 Ilustrasi *cross-correlation* (konvolusi) [27]

2.4.1.2 Max Pooling

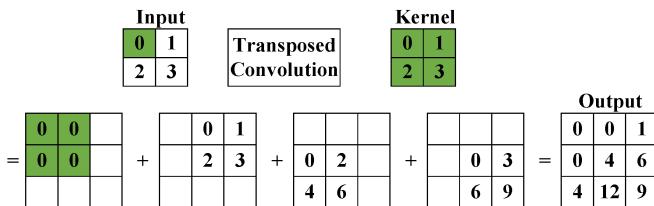
Lapisan pooling merupakan tahapan memproses peta fitur dari lapisan konvolusi untuk mengurangi parameter dan beban komputasi, tanpa kehilangan informasi penting, serta meningkatkan efisiensi dan mencegah *overfitting* [28]. Salah satu metode yang umum digunakan adalah *max pooling*, yaitu teknik yang melakukan *downsampling* dengan cara membagi citra menjadi beberapa sel yang teratur dan tidak saling tumpang tindih, kemudian memilih nilai maksimum dari setiap sel tersebut sebagai representasi [28]. Proses ini membantu jaringan menjadi lebih toleran terhadap variasi posisi atau orientasi fitur di dalam citra [28]. Gambar 2.6 merupakan ilustrasi proses *max pooling* [27].

Input	Output													
<table border="1" style="display: inline-table; vertical-align: middle;"><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	<table border="1" style="display: inline-table; vertical-align: middle;"><tr><td>4</td><td>5</td></tr><tr><td>7</td><td>8</td></tr></table>	4	5	7	8
0	1	2												
3	4	5												
6	7	8												
4	5													
7	8													
	2×2 Max-pooling													

Gambar 2.6 Ilustrasi max pooling [27]

2.4.1.3 Konvolusi Transpos

Konvolusi transpos adalah jenis konvolusi yang melakukan operasi kebalikan dari konvolusi biasa [29]. Jika konvolusi standar umumnya menurunkan atau mempertahankan dimensi citra masukan, maka konvolusi transpos digunakan untuk memperbesar ukuran citra [30]. Operasi ini berfungsi menguraikan kembali data yang telah dikonvolusi guna mengekstraksi kembali komponen spasial yang sebelumnya dipadatkan [30] [29]. Kemampuan ini menjadikannya penting dalam proses rekonstruksi spasial dalam arsitektur U-Net [30] [29]. Gambar 2.7 merupakan ilustrasi proses konvolusi transpos [30].

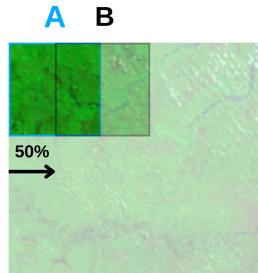


Gambar 2.7 Ilustrasi konvolusi transpos [30]

2.5 Overlapping Citra

Penerapan *overlapping* pada citra dalam model *deep learning* berperan dalam memperluas cakupan konteks semantik serta menjaga kesinambungan informasi di sekitar batas citra [31]. Strategi ini memungkinkan model mendapatkan informasi spasial yang lebih lengkap, mengurangi potensi kesalahan klasifikasi di area tepi, dan meningkatkan kemampuan model dalam melakukan generalisasi [31].

Selain itu, *overlapping* juga berperan sebagai metode augmentasi data alami yang efektif, sehingga model menjadi lebih stabil dan presisi [31]. Penerapan *overlapping* terbukti meningkatkan akurasi model sebagaimana ditunjukkan oleh peningkatan nilai metrik evaluasi [31]. Pada Gambar 2.8 menunjukkan ilustrasi *overlapping* 50% pada citra.



Gambar 2.8 Ilustrasi *Overlapping*

2.6 Fungsi Aktivasi

2.6.1 *Rectified Linear Unit (ReLU)*

Rectified Linear Unit (ReLU) merupakan sebuah fungsi aktivasi melakukan transformasi nonlinier yang sangat sederhana [27]. Persamaan 2.4 digunakan untuk menghitung ReLU, dengan terdapat sebuah elemen x , fungsi ini didefinisikan sebagai nilai maksimum antara 0 dan elemen tersebut [27]. Secara sederhana, ReLU akan mempertahankan nilai input yang positif dan mengabaikan nilai negatif dengan mengubahnya menjadi nol [27]

$$\text{ReLU}(x) = \max(0, x). \quad (2.4)$$

2.6.2 *Sigmoid*

Sigmoid merupakan salah satu fungsi aktivasi yang mengubah nilai input dari domain bilangan real \mathbb{R} menjadi output yang terbatas dalam kisaran $(0, 1)$ [27]. Karena kemampuannya ini, sigmoid kerap disebut sebagai fungsi pemampat (*squashing function*), karena memampatkan atau membatasi seluruh nilai input dari rentang $(-\infty, \infty)$ menjadi nilai yang berada di antara 0 dan 1 [27]. Persamaan 2.5 digunakan untuk menghitung sigmoid.

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}. \quad (2.5)$$

Sigmoid masih banyak digunakan sebagai fungsi aktivasi pada unit output ketika kita ingin menginterpretasikan hasil keluaran sebagai probabilitas dalam permasalahan klasifikasi biner [27].

2.7 Evaluasi Model

2.7.1 Confusion Matrix

Confusion matrix adalah tabel ringkasan yang menunjukkan jumlah prediksi benar ataupun salah untuk setiap kelas, yang berdasarkan label sebenarnya dan label prediksi [32]. Pada *confusion matrix* terdapat 4 elemen utama yang terdiri dari: TP (*True Positive*) merupakan hasil ketika model memprediksi kelas positif dengan benar, FP (*False Positive*) merupakan hasil ketika model salah memprediksi kelas positif, TN (*True Negative*) merupakan hasil ketika model benar memprediksi kelas negatif dan FN (*False Negative*) merupakan hasil dimana model salah memprediksi kelas negatif [7] [32]. Gambar 2.9 menunjukkan ilustrasi dalam memperoleh TP, TN, FP dan FN dari *confusion matrix* [33].

		Predicted	
		Yes	No
Actual	Yes	True Positives (TP)	False Negatives (FN)
	No	False Positives (FP)	True Negatives (TN)

Gambar 2.9 *Confusion Matrix* [33]

2.7.2 Binary Accuracy

Binary accuracy adalah metode untuk mengukur seberapa tepat sebuah model dalam membedakan dua kelas, yaitu benar atau salah, misalnya area terbakar (1) dan tidak terbakar (0) [7]. Cara menghitungnya cukup sederhana, yaitu dengan membandingkan jumlah prediksi yang benar (baik yang terbakar maupun tidak terbakar) dengan seluruh prediksi yang dibuat. Persamaan 2.6 digunakan untuk menghitung *binary accuracy*.

$$\text{Binary Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \quad (2.6)$$

2.7.3 Intersection over Union (IoU)

Intersection over Union (IoU) juga disebut sebagai *jaccard index*, salah satu metrik mengukur kesamaan antara dua himpunan piksel, khususnya tingkat tumpang tindih antara hasil segmentasi yang diprediksi dan segmentasi *ground truth* [34]. IoU dihitung sebagai rasio antara area irisan (*intersection*) dari segmentasi prediksi dan *ground truth* terhadap gabungan (*union*) dari keduanya [34]. Persamaan 2.7 digunakan untuk menghitung *intersection over union* (*IoU*).

$$IoU = \frac{TP}{TP + FP + FN}. \quad (2.7)$$

2.7.4 Dice Coefficient

Dice coefficient merupakan salah satu metrik yang digunakan untuk mengukur tingkat kesamaan antara dua himpunan [35]. Dalam konteks segmentasi, metrik ini digunakan untuk mengevaluasi seberapa mirip hasil prediksi dengan label referensi (*ground truth*) [35]. Untuk setiap kategori, *dice coefficient* dihitung berdasarkan tingkat tumpang tindih antara area segmentasi yang diprediksi dan area segmentasi sebenarnya [35]. Secara spesifik, *dice coefficient* dihitung sebagai rasio luas area yang saling bertumpang tindih terhadap total luas gabungan dari hasil prediksi dan label asli [35]. Persamaan 2.8 digunakan untuk menghitung *dice coefficient*.

$$Dice Coefficient = \frac{2 \times TP}{(2 \times TP) + FP + FN}. \quad (2.8)$$

2.7.5 Binary Cross Entropy

Binary Cross Entropy (BCE) adalah salah satu fungsi *loss* yang paling umum digunakan dalam masalah klasifikasi biner, termasuk segmentasi citra seperti identifikasi area kebakaran hutan. Fungsi ini mengukur seberapa jauh hasil prediksi model berbeda dari label yang sebenarnya. BCE bekerja dengan cara menghitung perbedaan antara nilai probabilitas prediksi dan label sebenarnya, dengan label biasanya

bernilai 0 (negatif) atau 1 (positif) [7]. Persamaan 2.9 digunakan untuk menghitung *binary cross entropy* dengan y_i adalah label sebenarnya dan p_i adalah probabilitas prediksi. Semakin kecil nilai BCE, semakin baik performa model dalam mencocokkan prediksi dengan data sebenarnya [7]

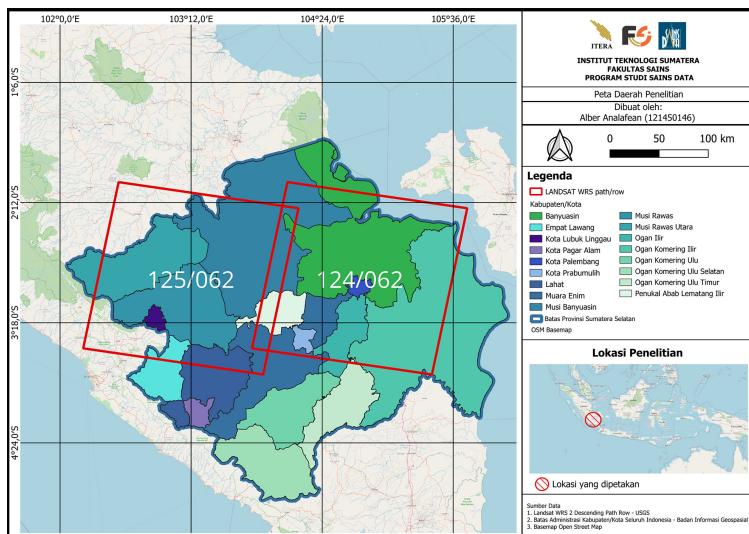
$$BCE = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)]. \quad (2.9)$$

BAB III

METODE PENELITIAN

3.1 Daerah Penelitian

Daerah penelitian di Provinsi Sumatera Selatan yang berada pada posisi 1° - 4° lintang selatan dan 102° - 106° bujur timur dengan luas daerah seluruhnya sebesar $86.771,68 \text{ km}^2$ [36], yang ditunjukkan pada Gambar 3.1. Penentuan Provinsi Sumatera Selatan sebagai fokus penelitian yang didasari oleh banyaknya terjadi karhutla diwilayah tersebut terutama di pulau Sumatera. Karakteristik geografis dan lingkungan Sumatera Selatan dapat mempengaruhi terdapatnya *burned area* di daerah tersebut. Rentang waktu penelitian yang dilakukan adalah pada rentang pada tahun 2023, yang dirancang untuk mendukung proses segmentasi *burned area* berbasis citra satelit Landsat dalam menilai deteksi area terbakar di Sumatera Selatan.



Gambar 3.1 Peta lokasi penelitian

3.2 Deskripsi Data

Penelitian ini menggunakan data citra satelit Landsat 9 yang diperoleh melalui platform *Google Earth Engine* (GEE) API. Citra yang digunakan berasal dari koleksi pada *Google Earth Engine* dengan ID

'LANDSAT/LC09/C02/T1_TOA', yaitu koleksi *Collection 2 Tier 1* dari satelit Landsat 9 yang telah melalui koreksi radiometrik dan geometrik, serta disediakan dalam bentuk reflektansi *Top of Atmosphere* (TOA). Koleksi Tier 1 menjamin kualitas citra yang tinggi, baik dari segi geolokasi maupun kalibrasi. Dalam penelitian ini citra yang digunakan meliputi band 4 (RED), band 5 (NIR), dan band 7 (SWIR2). Data penelitian digunakan diambil dari wilayah Provinsi Sumatera Selatan pada 1 Januari - 31 Juli 2023 (sebelum kebakaran) & 1 November - 31 Desember 2023 (sesudah kebakaran), dengan kondisi kebakaran terjadi pada bulan Agustus hingga Oktober 2023, yang ditunjukkan pada Tabel 3.1.

Tabel 3.1 Rentang Waktu Data

Kondisi	Rentang Waktu	Citra
Prefire (Sebelum Kebakaran)	1 Januari – 31 Juli 2023	Komposit(False Color), NDVI, NBR, dNBR (NBR Prefire)
Kejadian Kebakaran	1 Agustus – 31 Oktober 2023	-
Postfire (Setelah Kebakaran)	1 November – 30 Juni 2024	Komposit(False Color), NDVI, NBR, dNBR (NBR Postfire)

Citra yang digunakan dipilih secara selektif dengan mengurutkan berdasarkan nilai tutupan awan terendah menggunakan fungsi `.sort('CLOUD_COVER')` pada library ee (Earth Engine), diperoleh citra terbaik pada rentang waktu tersebut dengan meminimalkan gangguan awan, sehingga kualitas data reflektansi permukaan lebih akurat. Berdasarkan Gambar 3.1, citra yang digunakan pada cakupan *pathrow* 124062 dan 125062. Format data yang digunakan berupa raster GeoTIFF (.tiff), dengan setiap band berisi *array* 2D nilai reflektansi *Top of Atmosphere* (TOA) dalam skala 0 hingga 1 dengan contoh yang ditunjukkan seperti pada lampiran A.

3.3 Perangkat Komputasi

Penelitian ini menggunakan perangkat keras komputasi yang disediakan melalui lingkungan pemrograman daring berbasis notebook, yaitu *Google Colaboratory Pro*, dengan spesifikasi ditunjukkan pada Tabel 3.2.

Tabel 3.2 Informasi Spesifikasi Perangkat Keras *Google Colaboratory Pro*

Spesifikasi	Detail
Akselerator	A100 GPU
CPU Core	8
Tipe GPU	NVIDIA A100-SXM4
GPU Memory	40 GB
RAM	83.5 GB
Disk Space	235.7 GB

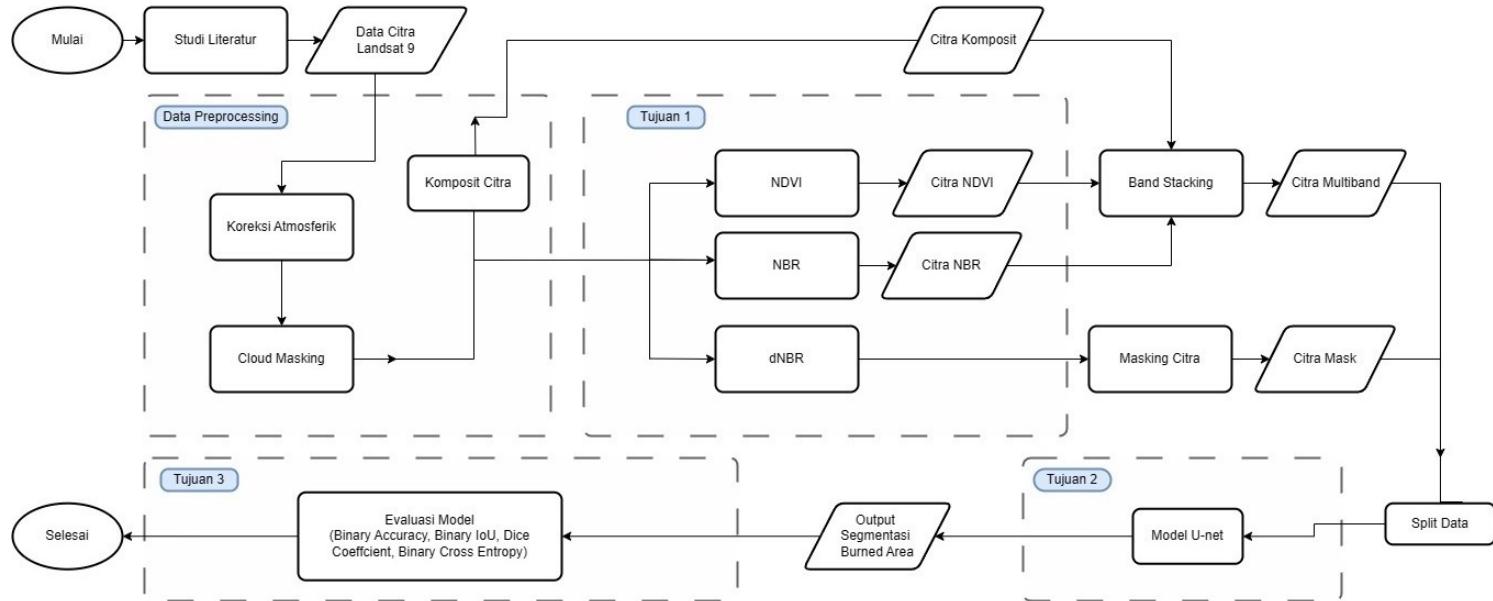
Selain perangkat keras tersebut, penelitian ini juga memanfaatkan beberapa perangkat lunak pendukung, yaitu *QGIS* digunakan dalam melakukan visualisasi citra satelit, *Google Earth Engine* digunakan dalam mengakses sumber data dan melakukan *data preprocessing* pada data citra Landsat 9, serta *Google Colaboratory Pro* digunakan dalam melakukan *training* model U-Net serta evaluasi model. Pada Tabel 3.3 menunjukkan *library* yang digunakan pada proses komputasi.

Tabel 3.3 Informasi Spesifikasi Library

Library	Versi	Kegunaan
ee	1.5.24	Akses dan praproses data dari <i>Google Earth Engine</i>
Pandas	2.2.2	Manipulasi data
Numpy	2.0.2	Manipulasi array atau matriks
Folium	0.19.7	Visualisasi data spasial
Geemap	0.35.3	Membuat peta interaktif
Rasterio	1.4.3	Membaca dan memanipulasi data raster geospasial
Patchify	0.2.3	Memotong gambar besar menjadi patch kecil
Matplotlib	3.10.0	Membuat grafik, plot, dan visualisasi data
Tensorflow	2.18.0	Membangun model <i>machine learning</i> dan <i>deep learning</i>
GDAL	3.8.4	Membaca dan mengolah data geospasial

3.4 Tahapan Penelitian

Tahapan penelitian yang dilakukan terdiri dari studi literatur, *data preprocessing* (koreksi atmosferik, *cloud masking*, komposit citra), ekstraksi fitur (NDVI, NBR, dNBR), *band stacking*, *masking* citra, model U-Net, hingga evaluasi model untuk menghasilkan output segmentasi burned area, sebagaimana ditunjukkan pada Gambar 3.2 berikut.



Gambar 3.2 Diagram Alir Penelitian

3.4.1 Data Preprocessing

Tahapan penelitian diawali dengan *data preprocessing* berupa koreksi atmosferik, *cloud masking* dan komposit citra berdasarkan Gambar 3.4, berfungsi untuk mempersiapkan data yang akan digunakan.

3.4.1.1 Koreksi Atmosferik

Koreksi atmosferik dilakukan untuk menghilangkan pengaruh gangguan atmosfer seperti aerosol dan uap air, sehingga diperoleh nilai reflektansi permukaan (*Surface Reflectance*) yang lebih akurat. Dalam penelitian ini, koreksi dilakukan menggunakan metode *Dark Object Subtraction* (DOS), yaitu dengan mengidentifikasi piksel paling gelap (*dark object*) yang diasumsikan memiliki reflektansi mendekati nol, kemudian nilai ini dikurangkan dari seluruh piksel citra. Proses ini bertujuan untuk mengoreksi efek kabut dan hamburan atmosfer secara sederhana, sehingga data yang dihasilkan lebih merepresentasikan kondisi sebenarnya di permukaan bumi.

3.4.1.2 Cloud Masking

Pada tahapan penelitian terdapat proses *Cloud Masking*, *Cloud Masking* adalah proses menghapus atau menandai piksel pada citra satelit yang tertutup awan dan bayangan awan. Piksel-piksel tersebut biasanya tidak mewakili permukaan Bumi dengan akurat, sehingga bisa mengganggu analisis. Proses ini dilakukan menggunakan *Quality Assessment (QA) bands*. Pada Tabel 3.4 menunjukkan bit QA Band beserta nilainya [4].

Tabel 3.4 Bit QA Bands

Bit	Flag Description	Values
0	Fill	0 for Image Data 1 for Fill data
1	Dilated Cloud	0 for cloud is not dilated or no cloud 1 for cloud dilation
2	Cirrus	0 for cirrus confidence: no confidence level set or Low Confidence 1 for high confidence cirrus
3	Cloud	0 for cloud confidence is not high 1 for high confidence cloud
4	Cloud Shadow	0 for cloud shadow confidence is not high 1 for high confidence cloud shadow

5	Snow	0 for snow/ice confidence is not high 1 for high confidence snow cover
6	Clear	0 if Cloud or Dilated Cloud bits are set 1 if Cloud and Dilated Cloud bits are not set
7	Water	0 for land or cloud 1 for water
8-9	Cloud Confidence	00 for no confidence level set 01 Low confidence 10 Medium confidence 11 High confidence
10-11	Cloud Shadow Confidence	00 for no confidence level set 01 Low confidence 10 Reserved 11 High confidence
10-11	Cloud Shadow Confidence	00 for no confidence level set 01 Low confidence 10 Reserved 11 High confidence
12-13	Snow/Ice Confidence	00 for no confidence level set 01 Low confidence 10 Reserved 11 High confidence
14-15	Cirrus Confidence	00 for no confidence level set 01 Low confidence 10 Reserved 11 High confidence

3.4.1.3 Komposit Citra

Dilakukan komposit citra, untuk memperoleh citra komposit, citra komposit yang digunakan adalah citra *false color*, untuk meningkatkan kejelasan dalam mendeteksi area terbakar. Citra *false color* dibuat dengan menggabungkan band spektral tertentu yang sensitif terhadap perubahan vegetasi dan kelembapan lahan pasca kebakaran. Kombinasi band yang digunakan adalah *Shortwave Infrared* (SWIR), dan *Red*, yaitu Band 7 (SWIR2), Band 5 (NIR), dan Band 4 (*Red*) [5].

3.4.2 Ekstraksi Fitur

3.4.2.1 Normalized Difference Vegetation Index (NDVI)

Selanjutnya dilakukan proses NDVI pada citra landsat 9 yang digunakan. NDVI berguna sebagai salah satu kanal dari citra *multiband* yang akan digunakan sebagai inputan model. Tahapan-tahapan yang dilakukan dalam proses perhitungan NDVI: Setelah diperoleh citra yang telah dilakukan *data preprocessing*,

selanjutnya dilakukan pemilihan kanal untuk menghitung NDVI berdasarkan band yaitu dengan band 5 dan band 4. Selanjutnya dilakukan perhitungan NDVI berdasarkan persamaan 2.1. Proses ini menghasilkan citra raster yang menunjukkan variasi kerapatan vegetasi pada area yang diamati. Dilakukan Interpretasi Nilai NDVI. Hasil NDVI berada dalam rentang nilai -1 hingga $+1$, dengan interpretasi nilai NDVI ditunjukkan pada Tabel 3.5.

Tabel 3.5 Interpretasi Nilai NDVI

Nilai	Kelas Vegetasi	Area
< 0	Non Vegetasi	Badan air, Awan, dan Salju
$0 - 0.2$	Vegetasi Sangat Jarang	Tanah kosong/Tanah gersang
$0.2 - 0.4$	Vegetasi Rendah	Padang rumput/Semak
$0.4 - 0.6$	Vegetasi Sedang hingga Lebat	Hutan sekunder/Lahan pertanian
> 0.6	Vegetasi Sangat Lebat dan Sehat	Hutan tropis/Lahan pertanian subur

3.4.2.2 *Normalized Burn Ratio (NBR)*

Selanjutnya dilakukan proses perhitungan NBR pada citra Landsat 9 yang digunakan. NBR berguna sebagai salah satu kanal dari citra *multiband* yang akan digunakan sebagai inputan model. Tahapan-tahapan yang dilakukan dalam proses perhitungan NBR adalah sebagai berikut: Setelah diperoleh citra yang telah dilakukan *data preprocessing*, selanjutnya dilakukan pemilihan kanal untuk menghitung NBR, yaitu menggunakan band 5 (NIR) dan band 7 (SWIR2). Selanjutnya dilakukan perhitungan NBR berdasarkan persamaan 2.2. Proses ini menghasilkan citra raster yang menunjukkan tingkat perubahan vegetasi yang berkaitan dengan kebakaran. Dilakukan interpretasi nilai NBR. Hasil NBR berada dalam rentang nilai -1 hingga $+1$.

3.4.2.3 *differenced Normalized Burn Ratio (dNBR)*

Selanjutnya dilakukan proses penghitungan indeks dNBR dihitung berdasarkan persamaan 2.3. dNBR digunakan sebagai ambang batas untuk menghasilkan citra *mask* yang menunjukkan area terbakar.

dNBR dihitung dengan membandingkan nilai NBR sebelum dan sesudah kebakaran untuk mendeteksi perubahan vegetasi. Pertama, dihitung nilai NBR pada citra pra-kebakaran (*prefire*) dan pasca-kebakaran (*postfire*) untuk setiap piksel. Selisih antara kedua nilai NBR tersebut menghasilkan nilai dNBR, yang menggambarkan perubahan vegetasi akibat kebakaran. Hasil perhitungan dNBR ini divisualisasikan dalam citra yang menunjukkan tingkat keparahan kebakaran. Pada Tabel 3.6 menunjukkan interpretasi rentang DNBR yang digunakan oleh USGS [37].

Tabel 3.6 Interpretasi Nilai dNBR

Nilai	Tingkat Keparahan	Deskripsi
> 0.66	Keparahan Sangat Tinggi	Hilangnya vegetasi secara luas dan tanah yang terbuka
0.44 - 0.66	Keparahan Tinggi	Kehilangan vegetasi yang signifikan
0.27 - 0.44	Keparahan Sedang	Hilangnya sebagian vegetasi
0.10 - 0.27	Keparahan Rendah	Kehilangan vegetasi kecil atau tanda-tanda awal kerusakan
< 0.10	<i>Unburned</i> atau <i>Regrowth</i>	Kerusakan kecil atau pemulihannya vegetasi

3.4.3 Band Stacking

Proses *band stacking* dilakukan untuk menggabungkan beberapa layer atau kanal citra satelit, seperti komposit *false color*, NDVI, dan NBR, menjadi satu citra *multiband* yang mencakup seluruh informasi spektral. Citra *multiband* ini mempermudah analisis lebih lanjut, seperti segmentasi, karena seluruh data sudah terintegrasi dalam satu file raster. Setiap kanal memiliki fungsi spesifik, misalnya kanal komposit untuk tampilan visual, NDVI untuk kesehatan vegetasi, dan NBR untuk mendeteksi area kebakaran. Hasil akhir *band stacking* disimpan dalam format geoTIFF.

3.4.4 Masking Citra

Masking citra merupakan proses pembuatan citra biner (*mask*) yang dilakukan berdasarkan nilai dNBR. Proses ini bertujuan untuk menghasilkan label atau *ground truth* yang akan digunakan dalam proses segmentasi. Proses masking ini menggunakan metode *thresholding*, dengan nilai *threshold* (ambang batas) ditentukan berdasarkan nilai dNBR. Jika nilai dNBR lebih besar dari 0.1, maka area tersebut diklasifikasikan sebagai *burned area*, dan pada citra *mask*

ditandai dengan nilai 1 berwarna putih; sedangkan jika nilai dNBR kurang dari atau sama dengan 0.1, maka diklasifikasikan sebagai area tidak terbakar, ditandai dengan nilai 0 berwarna hitam, sehingga citra diperoleh dari masking citra adalah citra *mask* berbentuk biner. Citra *mask* ini berfungsi sebagai label referensi (*ground truth*) dalam pelatihan model segmentasi, karena membedakan secara jelas antara area terbakar dan tidak terbakar, mengingat tidak bisa dilakukan pengambilan data secara langsung yang membutuhkan waktu.

3.4.5 *Split Data*

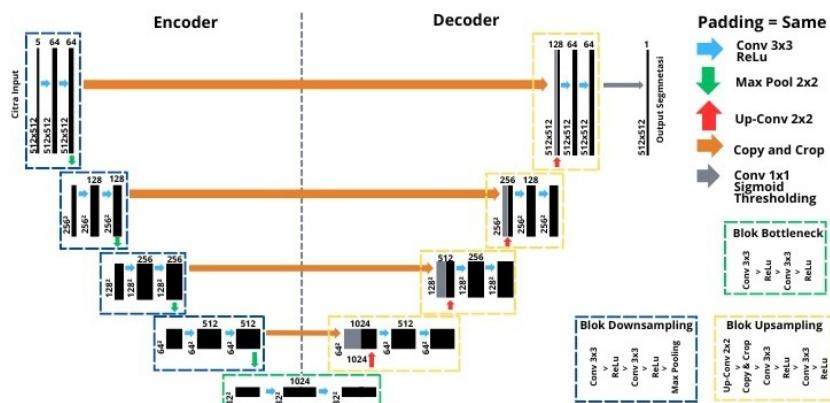
Split data adalah proses pembagian dataset menjadi beberapa bagian. Data dibagi menjadi tiga bagian: *data training*, *data validation*, dan *data testing*. Pembagian ini memisahkan data untuk pelatihan model, evaluasi selama pelatihan, dan pengujian performa akhir model. Tahapan sebelum dilakukan *split data*, diawali dengan *image patching* berfungsi memotong citra satu *scene* menjadi beberapa banyak *patch* kecil, dengan patch dipotong menggunakan *overlapping* 50% untuk memperbanyak data. Dengan setiap bagian *patch* terdiri dari pasangan citra *multiband* dan citra *mask* yang berasal dari area yang sama. Selanjutnya dilakukan split data dengan rasio pembagian data dengan 70% untuk *training*, dan 15% masing-masing untuk *validation* dan *testing*.

3.4.6 Model U-Net

Berdasarkan arsitektur rancangan yang akan digunakan pada Gambar 3.3, dilakukan tahapan segmentasi *burned area* menggunakan model U-Net. Proses dimulai dengan menerima citra sebagai input berukuran 512x512 dengan 5 *channel*. Citra diproses melalui jalur (*encoder*) melakukan tahapan *downsampling* menggunakan lapisan konvolusi 3x3 dan fungsi aktivasi ReLu diikuti *max pooling* 2x2 untuk memperkaya fitur dan mengecilkan resolusi, dilakukan sebanyak 4 blok *downsampling* ditunjukkan pada Gambar 3.3. Pada model U-Net digunakan *padding*, yaitu teknik penambahan piksel nol di tepi citra agar ukuran *output* tetap sama dengan ukuran *input*, sehingga

informasi tepi citra tidak hilang. *Padding* yang digunakan adalah *same*, yaitu *padding* yang mempertahankan ukuran citra output tetap sama dengan ukuran citra input berukuran 512x512.

Setelah jalur *encoder* masuk ke blok *bottleneck* yang ditunjukkan pada Gambar 3.3. Setelah mencapai *bottleneck*, citra dilanjutkan ke jalur (*decoder*) melalui proses upsampling menggunakan transpos konvolusi 2x2. Fitur hasil *upsampling* digabungkan dengan fitur dari jalur *encoder* melalui *skip connection* untuk mempertahankan informasi spasial yang ditunjukkan pada panah berwarna orange pada gambar 3.3. Proses ini diulang hingga resolusi citra kembali seperti semula, dilakukan sebanyak 4 blok *upsampling* ditunjukkan pada gambar 3.3. Terakhir, lapisan konvolusi 1x1 diikuti sigmoid lalu *thresholding* digunakan untuk menghasilkan citra segmentasi yang mengklasifikasikan setiap piksel sebagai terbakar atau tidak terbakar berukuran 512x512.



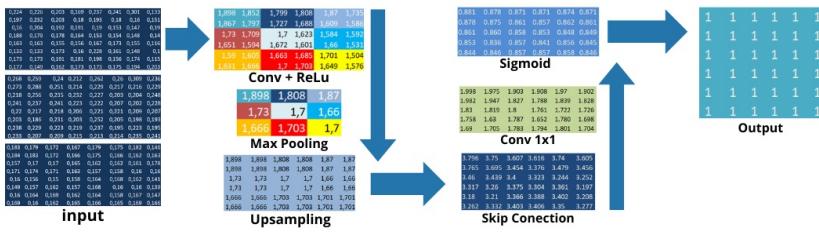
Gambar 3.3 Rancangan Arsitektur U-Net

Tabel 3.7 menunjukkan konfigurasi *hyperparameter* pada model yang digunakan terdiri dari konfigurasi *learning rate*, *epochs*, *optimizer*, *callback* dan *batch size*.

Tabel 3.7 Konfigurasi Hyperparameter Model

Hyperparamater	Konfigurasi
Learning rate	0.0001
Epochs	200
Optimizer	Adam
Callback	Early Stopping dan ReduceLROnPlateau
Batch Size	4

Pada Gambar 3.4 merupakan ilustrasi sederhana dalam proses penghitungan model U-Net dari *input* sampai *output*.



Kelas Prediksi		Kelas Ground Truth	
		Positive(1)	Negative(0)
Negative(0)	TP	FP	
	FN	TN	

Prediksi	Ground Truth
1 0 0 1 1	1 0 0 1 1
0 1 1 1 0	0 1 0 0 1
0 1 1 1 1	1 1 1 1 1
1 0 1 1 0	1 0 1 0 0
1 1 1 1 1	1 0 1 1 1

Diketahui: TP = 14, TN = 5, FP = 4, FN = 2

$$\text{Binary Accuracy} = \frac{(TP+TN)}{(TP+TN+FP+FN)} = \frac{(14+5)}{(14+5+4+2)} = 0.76$$

$$\text{Binary IoU} = \frac{(TP+FN)}{(TP+FP+FN)} = \frac{(14+4)}{(14+4+2)} = 0.70$$

$$\text{Dice Coefficient} = \frac{(2TP)}{(2TP+FP+FN)} = \frac{(2 \times 14)}{(2 \times 14 + 4 + 2)} = 0.82$$

(a)
Gambar 3.5 Ilustrasi Evaluasi Model

GT	Prediksi	Probabilitas	Loss	BCE
1	1	0.95	-0.022	0,05925
0	0	0.10	-0.046	
0	0	0.15	-0.071	
1	1	0.85	-0.071	
0	0	0.05	-0.022	
1	1	0.90	-0.046	
1	1	0.80	-0.097	
0	0	0.20	-0.097	
0	0	0.20	-0.097	
1	1	0.88	-0.055	
1	1	0.92	-0.036	
1	1	0.89	-0.051	

(b)

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Data

Data yang digunakan dalam penelitian ini merupakan citra satelit Landsat 9 TOA (*Top of Atmosphere*) dengan resolusi spasial 30 meter yang diperoleh melalui platform *Google Earth Engine*. Citra yang digunakan terdiri dari dua kondisi, yaitu sebelum kejadian kebakaran (*prefire*) dan setelah kejadian kebakaran (*postfire*), yang mencakup *pathrow*, yaitu 124062 dan 125062. Rentang waktu untuk kondisi *prefire* pada rentang antara tanggal 1 Januari 2023 hingga 30 Juli 2023, sedangkan untuk kondisi *postfire* pada rentang antara 1 November 2023 hingga 30 Juni 2024.

Pada Tabel 4.1, menunjukkan citra yang tersedia pada kondisi *prefire* di *pathrow* 124062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 26 Juli 2023 dengan persentase *cloud cover* sebesar 14.07%.

Tabel 4.1 Daftar citra Landsat 9 TOA *pathrow* 124062 kondisi *Prefire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
124062	Prefire	2023-07-26	14.07	LC09_L1TP_124062_20230726_20230726_02_T1
124062	Prefire	2023-04-21	29.16	LC09_L1TP_124062_20230421_20230421_02_T1
124062	Prefire	2023-06-24	33.04	LC09_L1TP_124062_20230624_20230624_02_T1
124062	Prefire	2023-03-20	54.76	LC09_L1TP_124062_20230320_20230320_02_T1
124062	Prefire	2023-04-05	56.74	LC09_L1TP_124062_20230405_20230405_02_T1
124062	Prefire	2023-05-23	57.75	LC09_L1TP_124062_20230523_20230523_02_T1
124062	Prefire	2023-07-10	83.95	LC09_L1TP_124062_20230710_20230710_02_T1
124062	Prefire	2023-01-15	84.48	LC09_L1TP_124062_20230115_20230313_02_T1
124062	Prefire	2023-02-16	86.69	LC09_L1TP_124062_20230216_20230310_02_T1
124062	Prefire	2023-06-08	93.87	LC09_L1TP_124062_20230608_20230608_02_T1
124062	Prefire	2023-05-07	100.00	LC09_L1TP_124062_20230507_20230507_02_T1
124062	Prefire	2023-03-04	100.00	LC09_L1TP_124062_20230304_20230307_02_T1

Pada Tabel 4.2, menunjukkan citra yang tersedia pada kondisi *prefire* di *pathrow* 125062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 14 Mei 2023 dengan persentase *cloud cover* sebesar 26.38%.

Tabel 4.2 Daftar citra Landsat 9 TOA *pathrow* 125062 kondisi *Prefire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
125062	Prefire	2023-05-14	26.38	LC09_L1TP_125062_20230514_20230514_02_T1
125062	Prefire	2023-01-22	50.78	LC09_L1TP_125062_20230122_20230313_02_T1
125062	Prefire	2023-06-15	65.17	LC09_L1TP_125062_20230615_20230615_02_T1
125062	Prefire	2023-04-12	66.80	LC09_L1TP_125062_20230412_20230412_02_T1
125062	Prefire	2023-01-06	73.91	LC09_L1TP_125062_20230106_20230314_02_T1
125062	Prefire	2023-04-28	75.61	LC09_L1TP_125062_20230428_20230428_02_T1
125062	Prefire	2023-02-07	87.14	LC09_L1TP_125062_20230207_20230310_02_T1
125062	Prefire	2023-07-01	90.55	LC09_L1TP_125062_20230701_20230701_02_T1
125062	Prefire	2023-05-30	91.37	LC09_L1TP_125062_20230530_20230530_02_T1
125062	Prefire	2023-03-27	92.76	LC09_L1TP_125062_20230327_20230327_02_T1
125062	Prefire	2023-07-17	95.70	LC09_L1TP_125062_20230717_20230717_02_T1

Pada Tabel 4.3, menunjukkan citra yang tersedia pada kondisi *postfire* di *pathrow* 124062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 9 Mei 2024 dengan persentase *cloud cover* sebesar 7.42%.

Tabel 4.3 Daftar citra Landsat 9 TOA *pathrow* 124062 kondisi *Postfire*

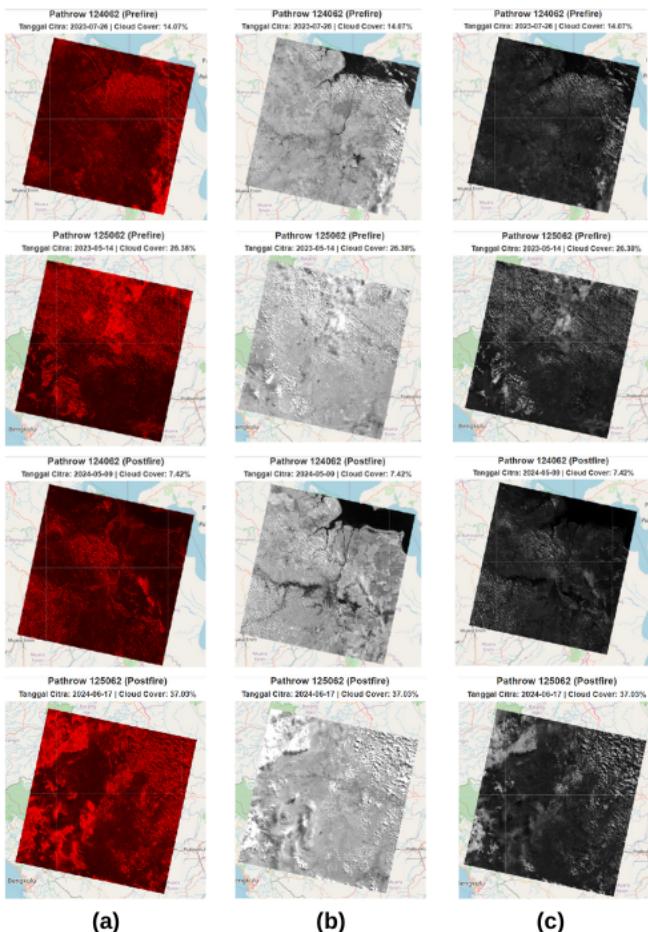
<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
124062	Postfire	2024-05-09	7.42	LC09_L1TP_124062_20240509_20240509_02_T1
124062	Postfire	2024-06-10	17.72	LC09_L1TP_124062_20240610_20240610_02_T1
124062	Postfire	2023-11-15	23.63	LC09_L1TP_124062_20231115_20231115_02_T1
124062	Postfire	2024-06-26	38.13	LC09_L1TP_124062_20240626_20240626_02_T1
124062	Postfire	2024-03-22	44.23	LC09_L1TP_124062_20240322_20240322_02_T1
124062	Postfire	2024-05-25	50.42	LC09_L1TP_124062_20240525_20240525_02_T1
124062	Postfire	2024-02-19	51.83	LC09_L1TP_124062_20240219_20240219_02_T1
124062	Postfire	2024-04-23	52.63	LC09_L1TP_124062_20240423_20240423_02_T1
124062	Postfire	2023-12-17	69.01	LC09_L1TP_124062_20231217_20231217_02_T1
124062	Postfire	2024-03-06	96.90	LC09_L1TP_124062_20240306_20240306_02_T1

Pada Tabel 4.4, menunjukkan citra yang tersedia pada kondisi *postfire* di *pathrow* 125062 beserta rentang waktu pengambilan citra dan persentase *cloud cover*. Berdasarkan *sort cloud cover*, Citra terbaik pada kondisi ini, diperoleh pada citra yang diambil pada 17 Juni 2024 dengan persentase *cloud cover* sebesar 37.03%.

Tabel 4.4 Daftar citra Landsat 9 TOA *pathrow* 125062 kondisi *Postfire*

<i>pathrow</i>	Kondisi	Tanggal Citra	Cloud Cover (%)	Product ID
125062	Postfire	2024-06-17	37.03	LC09_L1TP_125062_20240617_20240617_02_T1
125062	Postfire	2023-11-06	41.67	LC09_L1TP_125062_20231106_20231106_02_T1
125062	Postfire	2024-04-30	43.43	LC09_L1TP_125062_20240430_20240430_02_T1
125062	Postfire	2024-03-29	46.65	LC09_L1TP_125062_20240329_20240329_02_T1
125062	Postfire	2024-05-16	48.69	LC09_L1TP_125062_20240516_20240516_02_T1
125062	Postfire	2024-04-14	58.24	LC09_L1TP_125062_20240414_20240414_02_T1
125062	Postfire	2023-12-08	69.28	LC09_L1TP_125062_20231208_20231208_02_T1
125062	Postfire	2024-01-09	77.90	LC09_L1TP_125062_20240109_20240109_02_T1
125062	Postfire	2024-02-26	80.47	LC09_L1TP_125062_20240226_20240226_02_T1
125062	Postfire	2024-01-25	81.34	LC09_L1TP_125062_20240125_20240125_02_T1
125062	Postfire	2024-03-13	92.27	LC09_L1TP_125062_20240313_20240313_02_T1
125062	Postfire	2023-11-22	92.79	LC09_L1TP_125062_20231122_20231122_02_T1
125062	Postfire	2023-12-24	100.00	LC09_L1TP_125062_20231224_20231224_02_T1
125062	Postfire	2024-06-01	100.00	LC09_L1TP_125062_20240601_20240601_02_T1

Data yang digunakan dalam penelitian ini menggunakan 3 band utama, yaitu band 4, band 5, dan band 7. Ketiga band tersebut dipilih karena dianggap relevan untuk mendukung tujuan analisis yang dilakukan. Pada Gambar 4.1, visualisasi hasil data raster dari masing-masing band. Gambar 4.1 bagian (a) menunjukkan hasil visualisasi raster pada band 4, sedangkan bagian (b) memperlihatkan visualisasi raster dari band 5. Selanjutnya, Gambar 4.1 bagian (c) menampilkan data raster dari band 7. Setiap visualisasi disusun untuk merepresentasikan kondisi data secara menyeluruh. Visualisasi tersebut mencakup seluruh kombinasi *pathrow* dan kondisi citra yang digunakan dalam penelitian.

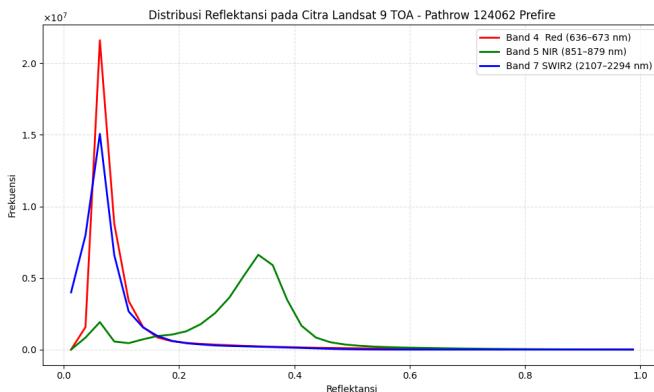


Gambar 4.1 Raster Landsat per band: (a) band 4, (b) band 5 dan (c) band 7

Data yang digunakan telah dikonversi ke reflektansi TOA dalam skala 0 hingga 1, dikarenakan data digunakan diakses melalui *Google Earth Engine* telah dilakukan koreksi radiometrik. Namun pada umumnya, data yang diakses melalui website USGS, perlu dilakukan koreksi radiometrik dikarenakan data masih dalam digital number dengan format 16 bit yang perlu dilakukan konversi ke reflektansi.

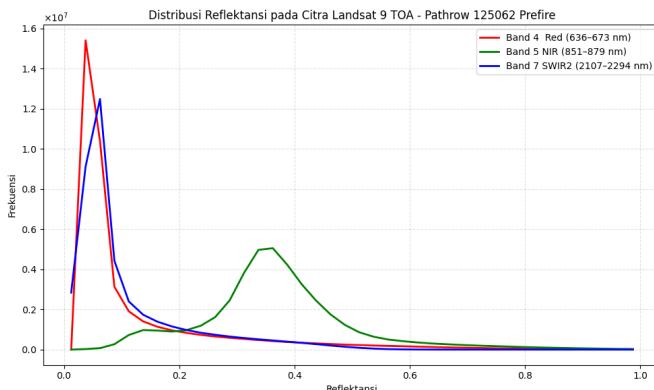
Pada Gambar 4.2 menunjukkan distribusi reflektansi pada kondisi sebelum kebakaran (*prefire*) untuk area *pathrow* 124062. Terlihat bahwa Band 5 (NIR) memiliki dua puncak distribusi, dengan intensitas tertinggi berada di rentang reflektansi sekitar 0.35. Sementara itu,

Band 4 (Red) dan Band 7 (SWIR2) menunjukkan puncak pada nilai reflektansi rendah (sekitar 0.05). Vegetasi cenderung memiliki nilai reflektansi rendah pada SWIR karena penyerapan air dan selulosa dalam jaringan tanaman [38]. Sehingga menunjukkan citra pada kondisi ini masih memiliki dominan masih memiliki vegetasi sehat.



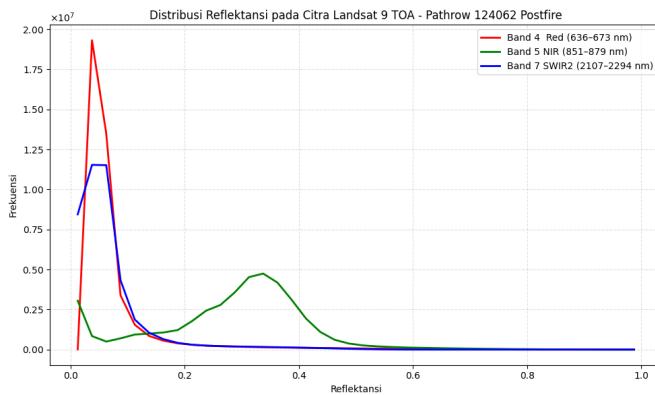
Gambar 4.2 Distribusi reflektansi Pahtrow 124062 - *Prefire*

Sementara itu, Gambar 4.3 juga menunjukkan distribusi reflektansi *prefire* namun untuk area *pathrow* 125062. Pola yang ditampilkan konsisten dengan Gambar 4.2, di mana Band 5 (NIR) kembali mendominasi reflektansi menengah (0.35 – 0.4). Band 4 dan Band 7 juga memiliki puncak di nilai rendah sekitar 0.05, menunjukkan bahwa area ini merupakan dominan masih memiliki vegetasi sehat sama seperti pada Gambar 4.2.



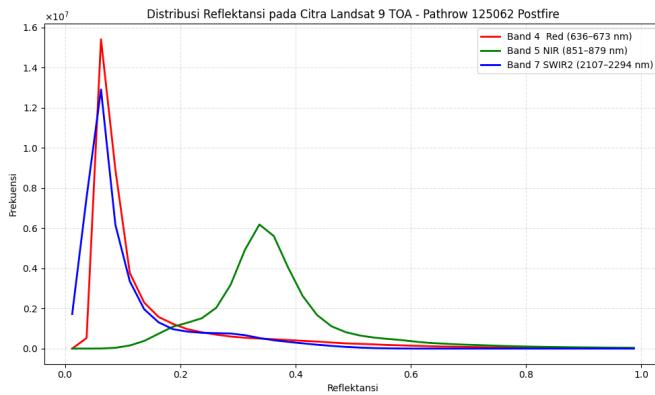
Gambar 4.3 Distribusi reflektansi Pahtrow 125062 - *Prefire*

Pada Gambar 4.4 menunjukkan perubahan penurunan signifikan pada puncak reflektansi Band 5 (NIR) daripada Gambar 4.2. Sementara itu, Band 4 (Red) dan terutama Band 7 (SWIR2) menunjukkan sedikit pergeseran dan penyebaran nilai reflektansi.



Gambar 4.4 Distribusi reflektansi Pahtrow 124062 - *Postfire*

Namun, Pada Gambar 4.5, terjadi penurunan drastis pada reflektansi NIR, ditandai oleh hilangnya puncak distribusi pada sekitar reflektansi 0.4. Sebaliknya, distribusi band Red dan SWIR2 meningkat pada kisaran reflektansi rendah.



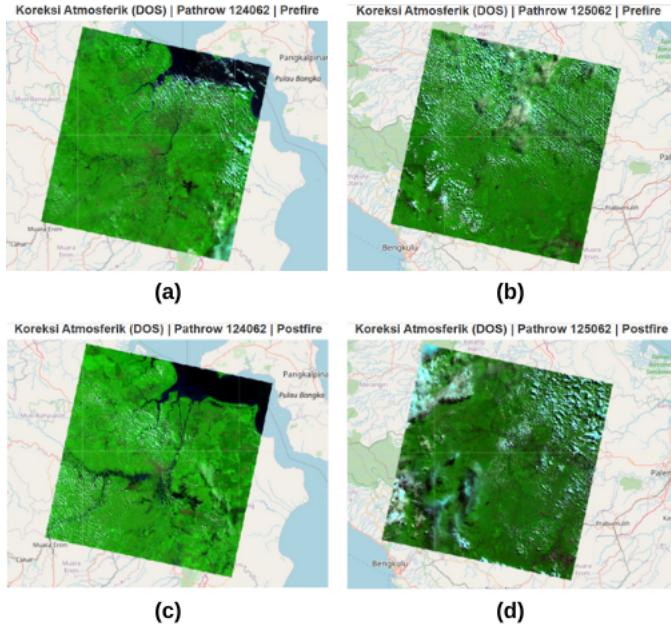
Gambar 4.5 Distribusi reflektansi Pahtrow 125062 - *Postfire*

4.2 Data Preprocessing

4.2.1 Koreksi Atmosferik

Koreksi atmosferik merupakan tahap penting dalam pra pemrosesan citra satelit untuk menghilangkan pengaruh atmosfer terhadap nilai reflektansi yang terekam sensor. Salah satu metode yang digunakan dalam penelitian ini adalah *Dark Object Subtraction* (DOS). Pada Gambar 4.6 bagian (a) dan (c) menunjukkan hasil dari koreksi atmosferik menggunakan metode DOS di *pathrow* 124062 pada kedua kondisi, serta pada Gambar 4.6 bagian (b) dan (d) menunjukkan hasil dari koreksi atmosferik menggunakan metode DOS di *pathrow* 125062 pada kondisi *prefire* dan *postfire*. Citra ditampilkan dalam komposit *false color* dengan kombinasi Band 7, Band 5, dan Band 4, yang umum digunakan untuk analisis vegetasi karena mampu menampilkan perbedaan tajam antara vegetasi sehat, area terbuka, dan area terbakar.

Pada Gambar 4.6, terlihat pada citra hasil koreksi atmosferik, warna hijau pada vegetasi menjadi lebih jelas dan tajam, menunjukkan bahwa nilai reflektansi telah diperbaiki dan gangguan dari efek atmosfer telah dikurangi. Dengan perbandingan antara kondisi *prefire* dan *postfire* pada masing-masing *pathrow*, khususnya pada *pathrow* 125062 *postfire*, area dengan warna cerah kehijauan pudar dan tampak lebih kasar mengindikasikan adanya degradasi vegetasi atau dampak kebakaran setelah koreksi dilakukan. Secara keseluruhan, penerapan koreksi atmosferik ini penting untuk memastikan bahwa perbandingan nilai reflektansi antar waktu menjadi lebih valid dan dapat digunakan dengan akurat dalam perhitungan indeks spektral seperti NDVI, NBR, dan dNBR.



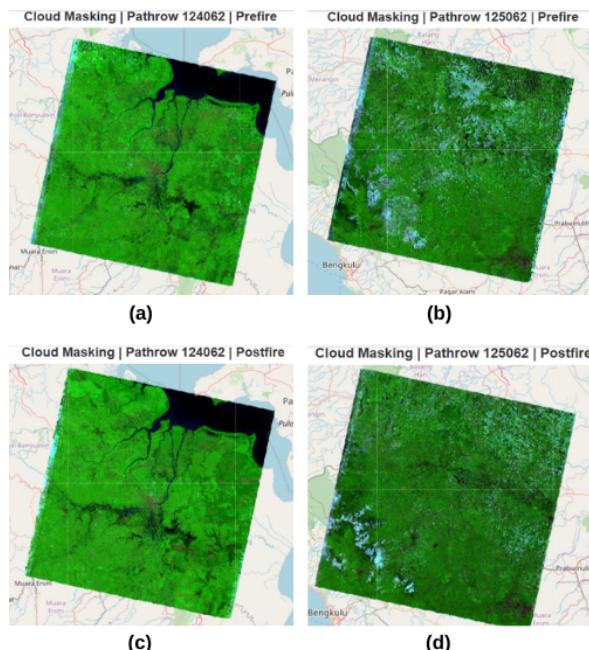
Gambar 4.6 Koreksi Atmosferik (DOS) pada kondisi *prefire* dan *postfire*

4.2.2 *Cloud Masking*

Cloud masking merupakan langkah penting dalam pra-pemrosesan citra satelit untuk mengurangi pengaruh awan dan bayangan awan yang dapat mengganggu akurasi interpretasi spasial maupun spektral. Awan cenderung memiliki reflektansi tinggi pada kanal-kanal tertentu, sehingga keberadaannya dapat menyebabkan distorsi dalam analisis indeks vegetasi maupun deteksi area terbakar. Oleh karena itu, mengidentifikasi dan menghilangkan piksel-piksel yang tertutup awan menjadi bagian krusial sebelum dilakukan analisis lebih lanjut. Dalam penelitian ini, proses *cloud masking* diterapkan pada citra Landsat 9 dengan memanfaatkan *Quality Assessment* (QA) Band, yang menyediakan informasi bitmask tentang kondisi atmosfer dan permukaan pada setiap piksel. Berdasarkan referensi Landsat Collection 2 Level-1 QA_PIXEL, masking dilakukan dengan mempertimbangkan beberapa bit penting berdasarkan Tabel 3.4.

Proses masking dilakukan dengan mempertahankan piksel yang tidak mengandung *fill*, *dilated cloud*, *cirrus*, *cloud*, dan *cloud shadow*, serta

hanya memilih piksel yang ditandai sebagai *clear*. Dengan demikian, hanya piksel yang memiliki kepercayaan tinggi sebagai wilayah bersih yang digunakan dalam proses analisis lanjutan, sementara piksel lain disaring untuk menghindari distorsi data. Pada Gambar 4.7 bagian (a) dan (c) menunjukkan hasil dari proses cloud masking di *pathrow* 124062 pada kondisi *prefire* dan *postfire*, serta Pada Gambar 4.7 bagian (b) dan (d) menunjukkan hasil dari proses *cloud masking* di *pathrow* 125062 pada kedua kondisi. Citra ditampilkan dalam komposit *false color*, yang efektif dalam menyorot vegetasi dan perubahan akibat kebakaran. Sebelum dilakukan masking, area seperti *pathrow* 125062 *postfire* menunjukkan tutupan awan dan bayangan yang luas. Setelah proses masking, area tersebut berhasil diminimalkan. Meskipun tidak semua gangguan atmosfer dapat dihilangkan.

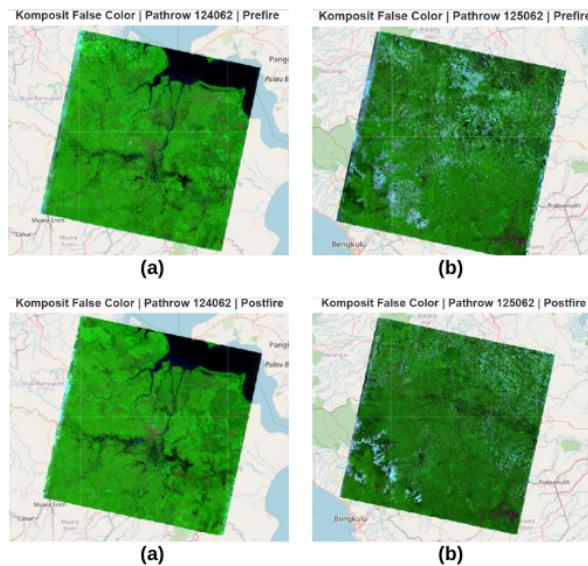


Gambar 4.7 Cloud Masking (QA Bands) pada kondisi *prefire* dan *postfire*

4.2.3 Komposit Citra

Proses komposit citra digunakan sebagai salah satu inputan citra dalam model segmentasi ini. Komposit citra menampilkan citra pada

kombinasi band tertentu, pada penelitian ini menggunakan komposit citra *False Color* dengan kombinasi band yaitu band 7 (SWIR), band 5 (NIR), dan band 4 (Red) [39]. Penggunaan Komposit Citra *false color* didasari oleh pada penelitian Made, dkk [7], yang menunjukkan hasil bahwa segmentasi citra menggunakan U-Net pada inputan komposit citra menggunakan *false color* memiliki nilai akurasi, IoU dan *Dice Coeficient* lebih unggul dibandingkan dengan komposit citra menggunakan *natural color* terkhusus pada citra satelit [7]. Gambar 4.8 menunjukkan komposit citra *false color* yang telah dilakukan Koreksi atmosferik dan cloud masking.



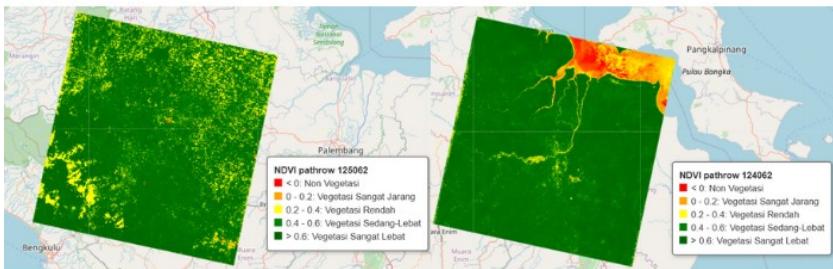
Gambar 4.8 Komposit Citra (*False Color*) pada kondisi *prefire* dan *postfire*

4.3 Ekstraksi Fitur

4.3.1 Normalized Difference Vegetation Index (NDVI)

Berdasarkan Gambar 4.9, hasil ekstraksi nilai NDVI kondisi *postfire* dari dua *pathrow* citra Landsat 9, yaitu *pathrow* 124062 dan *pathrow* 125062, menunjukkan variasi spasial tingkat kehijauan yang mencerminkan kondisi vegetasi di wilayah studi. Nilai NDVI dihitung berdasarkan perbedaan pantulan spektral antara kanal *Near-Infrared* (NIR) dan kanal merah (Red), yang pada Landsat 9 masing-masing

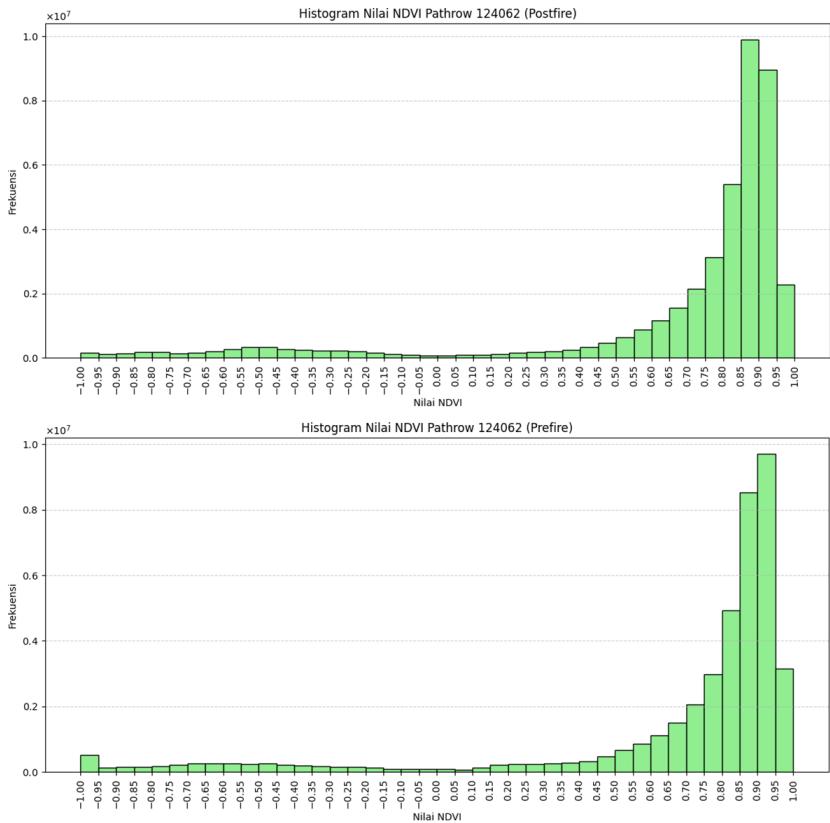
direpresentasikan oleh Band 5 dan Band 4. Perhitungan dilakukan secara piksel per piksel untuk menghasilkan informasi spasial mengenai tingkat kerapatan vegetasi.



Gambar 4.9 Citra NDVI pada *pathrow* 124062 dan *pathrow* 125062

Gambar 4.10 dan Gambar 4.11 menunjukkan distribusi nilai NDVI dari citra Landsat 9 pada wilayah dengan *pathrow* 124062 dan 125062. Histogram tersebut merepresentasikan jumlah piksel terhadap nilai NDVI yang berkisar antara -1 hingga +1. Pada Gambar 4.10 (*pathrow* 124062 - *Prefire*), distribusi nilai NDVI menunjukkan kecenderungan yang sangat kuat ke arah nilai positif tinggi. Puncak frekuensi terdapat pada rentang 0.90 hingga 0.95, yang mengindikasikan dominasi tutupan vegetasi lebat. Nilai negatif dan mendekati nol relatif sangat kecil, menandakan bahwa area non-vegetasi seperti badan air, permukiman, atau tanah terbuka hanya mencakup sebagian kecil dari keseluruhan wilayah citra.

Namun, Pada Gambar 4.10 (*pathrow* 124062 - *Postfire*), distribusi nilai NDVI menunjukkan kecenderungan yang sangat kuat ke arah nilai positif tinggi. Puncak frekuensi terdapat pada rentang 0.85 hingga 0.90, yang mengalami penurunan daripada kondisi *prefire*, yang menunjukkan terdapatnya perubahan vegetasi akibat kebakaran. Dan begitupula terjadi pada rentang 0.95 hingga 1 yang juga mengalami penurunan. Nilai negatif dan mendekati nol relatif sangat kecil, menandakan bahwa area non-vegetasi seperti badan air, permukiman, atau tanah terbuka hanya mencakup sebagian kecil dari keseluruhan wilayah citra

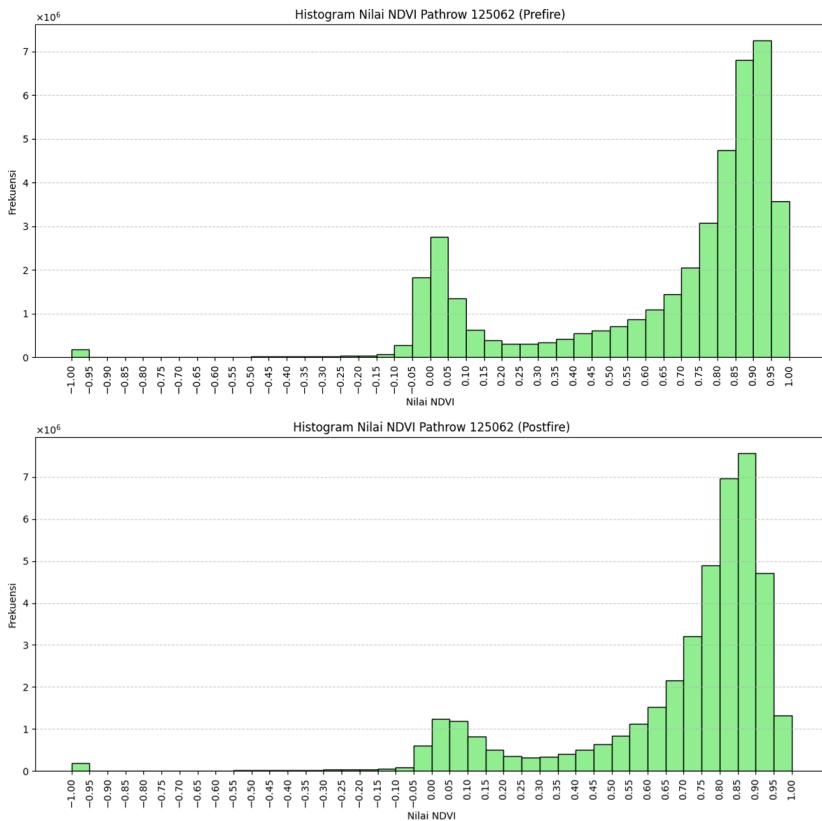


Gambar 4.10 Histogram NDVI *pathrow* 124062

Pada Gambar 4.11 (pathrow 125062 - *prefire*), distribusi nilai NDVI menunjukkan pola yang terkonsentrasi pada rentang nilai positif antara 0.70 hingga 0.90. Puncak histogram yang dominan pada kisaran ini mencerminkan kondisi tutupan lahan yang didominasi oleh vegetasi lebat dan sehat. Sebaran histogram yang sempit dan terfokus di sisi kanan mengindikasikan bahwa wilayah ini secara umum memiliki tutupan vegetasi yang relatif homogen dan belum mengalami gangguan.

Sebaliknya, pada Gambar 4.11 (pathrow 125062 - *postfire*), meskipun puncak distribusi NDVI masih berada pada kisaran yang sama (0.70 hingga 0.90), histogram menunjukkan sebaran yang lebih luas dan merata ke rentang nilai NDVI yang lebih rendah. Terdapat peningkatan

frekuensi yang signifikan pada nilai NDVI antara 0.10 hingga 0.60, yang menunjukkan keberadaan area dengan vegetasi sedang hingga rendah. Hal ini mengindikasikan adanya degradasi vegetasi atau perubahan tutupan lahan akibat kejadian kebakaran, yang menyebabkan keragaman tutupan lahan menjadi lebih tinggi dibandingkan dengan kondisi sebelum kebakaran.

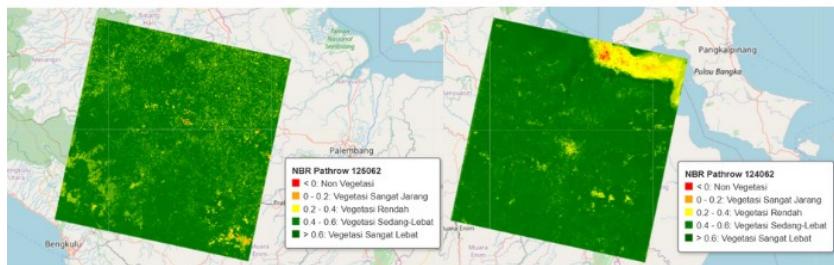


Gambar 4.11 Histogram NDVI pathrow 125062

4.3.2 Normalized Burn Ratio (NBR)

Pada Gambar 4.12 menunjukkan hasil ekstraksi nilai Normalized Burn Ratio (NBR) kondisi *postfire* dari citra Landsat 9, pada *pathrow* 125062 dan *pathrow* 124062. NBR dihitung menggunakan kanal inframerah dekat (NIR) dan kanal inframerah gelombang pendek (SWIR), yang pada citra Landsat 9 masing-masing direpresentasikan

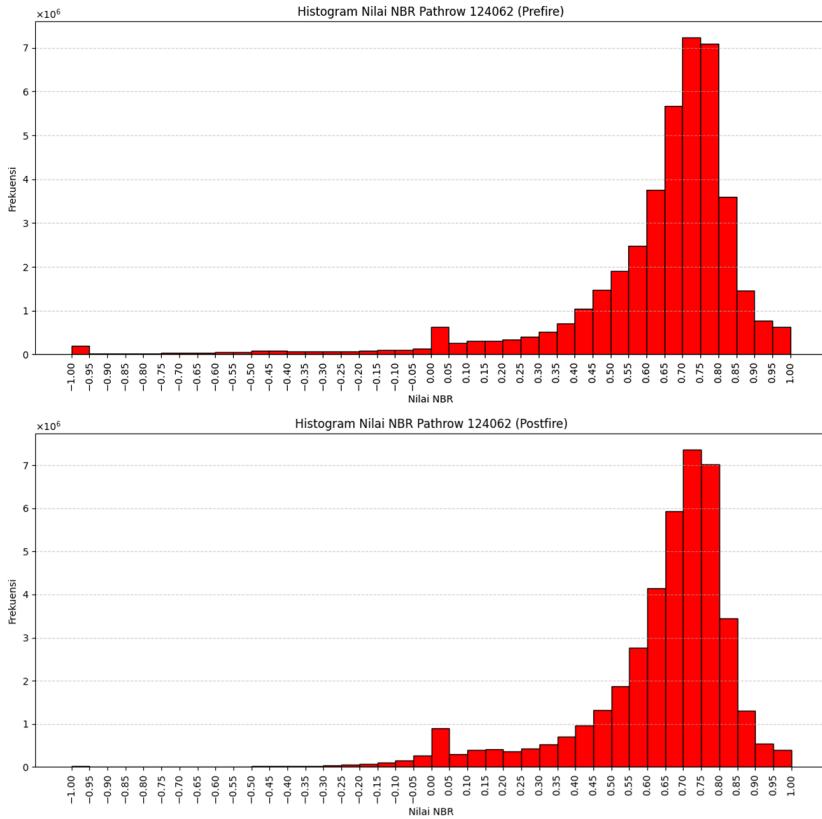
oleh Band 5 dan Band 7. NBR merupakan salah satu indeks yang umum digunakan untuk mendeteksi area yang terdampak kebakaran hutan dan lahan, dengan nilai yang menurun secara signifikan pada area terbakar akibat hilangnya vegetasi dan peningkatan kelembaban tanah.



Gambar 4.12 Citra NBR pada pathrow 125062 dan pathrow 124062

Pada Gambar 4.13 (pathrow 124062 - *prefire*) menunjukkan distribusi nilai NBR sebelum kejadian kebakaran menunjukkan puncak yang cukup tajam pada kisaran 0.65 hingga 0.80, dengan sebaran yang relatif sempit dan terpusat di sisi kanan histogram. Hal ini mengindikasikan bahwa sebagian besar wilayah memiliki kondisi vegetasi yang sehat dan tidak terbakar.

Namun, pada Gambar 4.13 (pathrow 124062 - *postfire*), setelah kebakaran, histogram NBR tetap menunjukkan puncak pada kisaran 0.60 hingga 0.80, namun terdapat peningkatan frekuensi pada nilai NBR yang lebih rendah, terutama di bawah 0.60. Munculnya distribusi yang lebih menyebar ke arah kiri menunjukkan adanya penurunan nilai NBR di beberapa area, yang mengindikasikan kerusakan vegetasi akibat kebakaran. Meskipun puncak nilai masih tinggi, penyebaran ini menandakan bahwa sebagian wilayah mengalami degradasi atau hilangnya biomassa, dengan peningkatan area yang memperlihatkan karakteristik bekas terbakar.

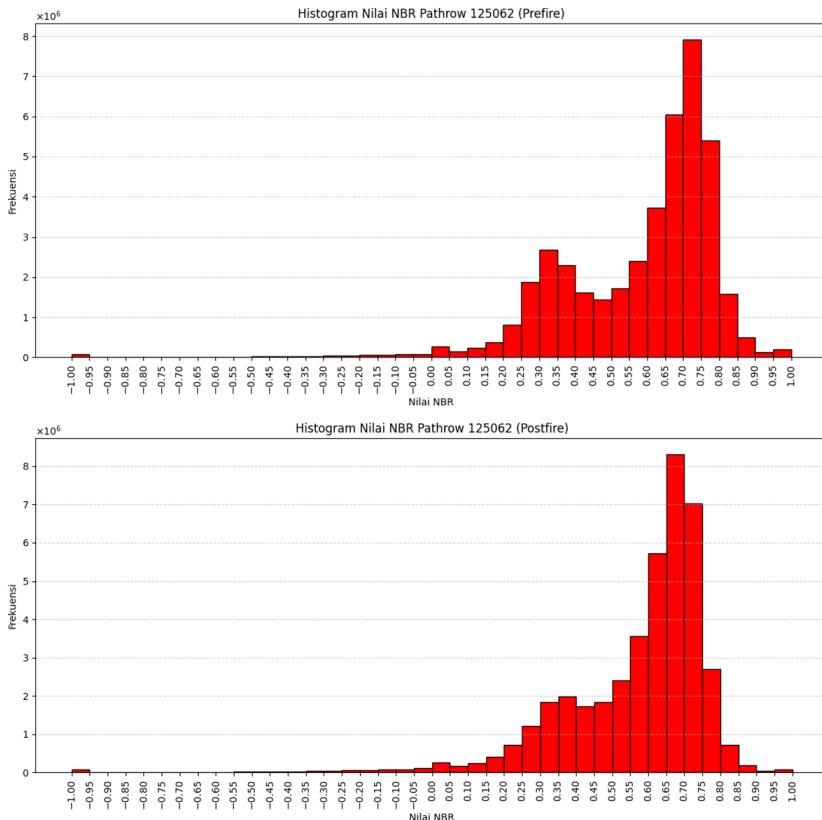


Gambar 4.13 Histogram NBR *pathrow* 124062

Pada Gambar 4.14 (*pathrow* 125062 – *prefire*), histogram nilai NBR menunjukkan dua puncak utama, yaitu pada kisaran 0.30–0.35 dan 0.70–0.75. Puncak tertinggi berada pada rentang nilai NBR 0.70–0.75 yang mencerminkan dominasi tutupan vegetasi lebat dan sehat sebelum terjadinya kebakaran. Sementara itu, kemunculan puncak tambahan pada nilai NBR yang lebih rendah mengindikasikan keberadaan area dengan vegetasi yang tidak terlalu rapat atau tutupan lahan campuran. Sebaran histogram yang relatif luas menunjukkan bahwa wilayah ini memiliki keragaman kondisi tutupan lahan sebelum kejadian kebakaran.

Namun, pada Gambar 4.14 (*pathrow* 125062 -*postfire*), distribusi nilai NBR mengalami pergeseran ke arah nilai yang lebih rendah, dengan

konsentrasi frekuensi yang lebih menyebar pada kisaran 0.40 hingga 0.70. Meskipun puncak nilai NBR masih berada pada kisaran 0.70, jumlah piksel dalam rentang tersebut terlihat menurun dibandingkan kondisi *prefire*. Hal ini mengindikasikan adanya degradasi vegetasi akibat kebakaran, di mana sebagian wilayah yang sebelumnya memiliki nilai NBR tinggi mengalami penurunan reflektansi vegetatif, yang tercermin dari penurunan nilai NBR secara keseluruhan.

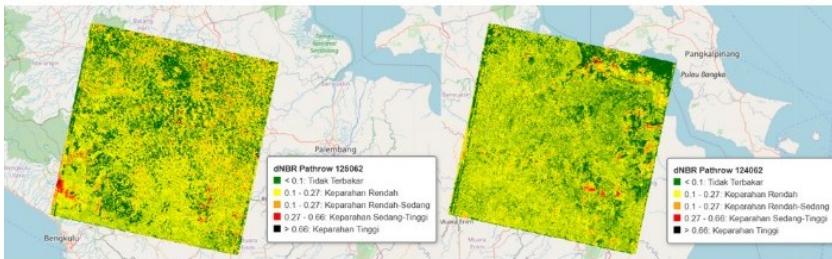


Gambar 4.14 Histogram NBR *pathrow* 125062

4.3.3 *Difference Normalized Burn Ratio (dNBR)*

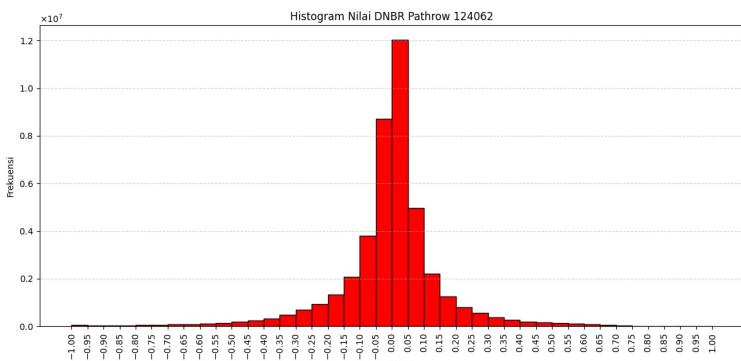
Gambar 4.15 menunjukkan hasil *difference Normalized Burn Ratio* (dNBR) untuk dua *pathrow* Landsat 9, yaitu *pathrow* 124062 (Gambar 4.15 bagian a) dan *pathrow* 125062 (Gambar 4.15 bagian b). Nilai dNBR diperoleh dengan menghitung selisih antara indeks NBR

sebelum kebakaran (*prefire*) dan setelah kebakaran (*postfire*), sehingga mampu menggambarkan tingkat keparahan perubahan vegetasi akibat kejadian kebakaran hutan dan lahan. Terlihat pada *pathrow* 124062, menunjukkan keparahan tinggi kebakaran berada diarah timur dan tenggara serta beberapa di arah utara dekat ke laut. Pada *pathrow* 125062, keparahan tinggi berada lebih tepatnya di barat daya dan tenggara.



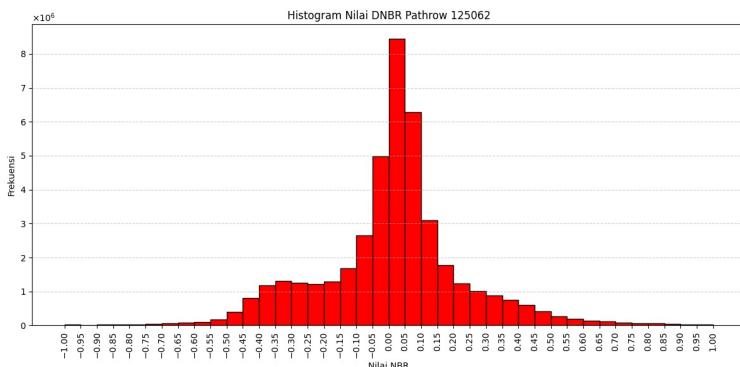
Gambar 4.15 Citra dNBR pada *pathrow* 124062 dan 125062

Pada Gambar 4.16 menunjukan dNBR pada *pathrow* 124062, histogram memperlihatkan nilai dNBR berada pada kisaran 0.00 hingga 0.05 dengan puncak tertinggi. Sebaran ini mengindikasikan bahwa area mengalami sedikit perubahan vegetasi yang signifikan atau bisa dikatakan tidak terbakar. Walaupun nilai dNBR diatas 0.1 masih ada yang menunjukkan terdapat keparahan kebakaran, walaupun pada keparahan kebakaran tinggi (>0.6) menunjukkan frekuensinya tidak banyak dibandingkan keparahan rendah dan sedang.



Gambar 4.16 Histogram dNBR Pahtrow 124062

Namun pada Gambar 4.17, distribusi nilai dNBR pada *pathrow* 125062 menunjukkan pola yang lebih menyebar dengan frekuensi piksel yang jauh lebih tinggi. Histogram memperlihatkan sebaran yang lebih luas, yang mengindikasikan adanya dampak kebakaran yang lebih besar dibandingkan dengan *pathrow* 124062. Peningkatan jumlah piksel pada kelas dNBR menengah hingga tinggi ini mencerminkan kerusakan vegetasi yang lebih luas, mulai dari tingkat ringan hingga sedang, bahkan terdapat indikasi kecil terhadap area dengan keparahan berat. Berdasarkan distribusi tersebut, dapat disimpulkan bahwa *pathrow* 125062 mengalami kejadian kebakaran yang lebih signifikan dibandingkan *pathrow* 124062.

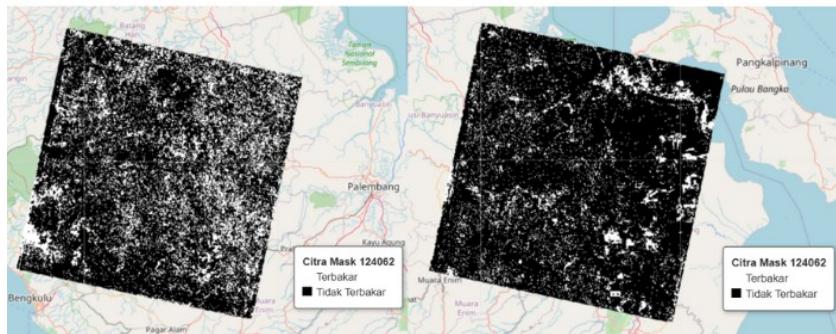


Gambar 4.17 Histogram dNBR *pathrow* 125062

4.4 Masking Citra

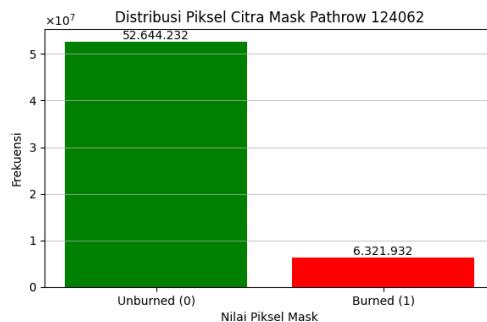
Pada Gambar 4.18 menunjukkan hasil *masking* citra dari dua *pathrow* Landsat 9, yaitu *pathrow* 125062 (Gambar 4.16 bagian a) dan *pathrow* 124062 (Gambar 4.16 bagian b), yang dihasilkan dari proses thresholding terhadap citra *differenced Normalized Burn Ratio* (dNBR). Proses ini bertujuan untuk mengidentifikasi dan memisahkan area terbakar dan area tidak terbakar yang digunakan sebagai *ground truth (actual)*. *Masking* dilakukan dengan menggunakan nilai ambang (*threshold*) pada dNBR, di mana nilai dNBR lebih besar dari 0.1 dikategorikan sebagai area terbakar (diberikan nilai 1, ditampilkan dalam warna putih pada citra *mask*), sedangkan nilai dNBR 0.1 dikategorikan sebagai area tidak terbakar (diberi nilai 0, ditampilkan

dalam warna hitam). Nilai ambang 0.1 dipilih berdasarkan tabel dNBR yang menunjukkan kondisi *burned area* pada Tabel 3.6.



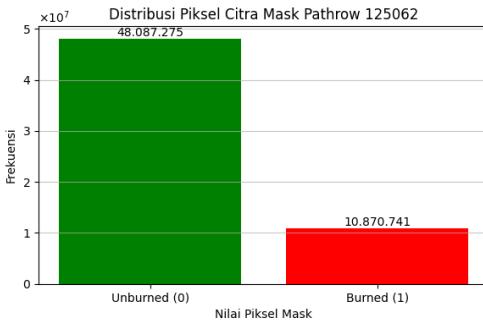
Gambar 4.18 Citra mask pada pathrow 124062 dan 125062

Pada Gambar 4.19 menunjukkan distribusi piksel pada citra *mask* pathrow 124062, berdasarkan gambar terlihat bahwa piksel menunjukkan *burned* frekuensinya sebanyak 6.321.932, sedangkan 52.644.232 diantaranya merupakan *unburned*.



Gambar 4.19 Disribusi piksel citra *mask* pathrow 124062

Pada Gambar 4.20 menunjukkan distribusi piksel pada citra *mask* pathrow 125062, berdasarkan gambar terlihat bahwa piksel menunjukkan *burned* frekuensinya sebanyak 10.870.741, sedangkan 48.087.275 diantaranya merupakan *unburned*.



Gambar 4.20 Disribusi piksel citra mask pathrow 125062

4.5 Band Stacking

Proses *band stacking* pada penelitian ini dilakukan untuk citra kondisi *postfire*, yang selanjutnya digunakan sebagai inputan dalam *training* model segmentasi U-Net. Tujuan utama dari *band stacking* adalah membentuk citra *multiband* yang menggabungkan informasi spektral dan indeks vegetasi ke dalam satu representasi data yang komprehensif. Dalam hal ini, tiga sumber kanal yang digunakan adalah: komposit citra *false color*, NDVI, dan NBR, sehingga setiap citra hasil *band stacking* memiliki total lima kanal (5 band).

Band stacking dilakukan terhadap citra pada *pathrow* 124062 dan 125062, yang sebelumnya telah melalui proses koreksi atmosferik, *cloud masking*, komposit citra, serta penghitungan indeks NDVI dan NBR. Setiap *layer* disatukan secara spasial pada domain yang sama dan dalam format numerik raster yang seragam menjadi citra *multiband*. Tabel 4.5 menunjukkan urutan band disimpan pada proses *band stacking*.

Tabel 4.5 Urutan Band citra *multiband* disimpan

Band	Informasi disimpan
Band 1	NDVI
Band 2	NBR
Band 3	False Color (Band 4)
Band 4	False Color (Band 5)
Band 5	False Color (Band 7)

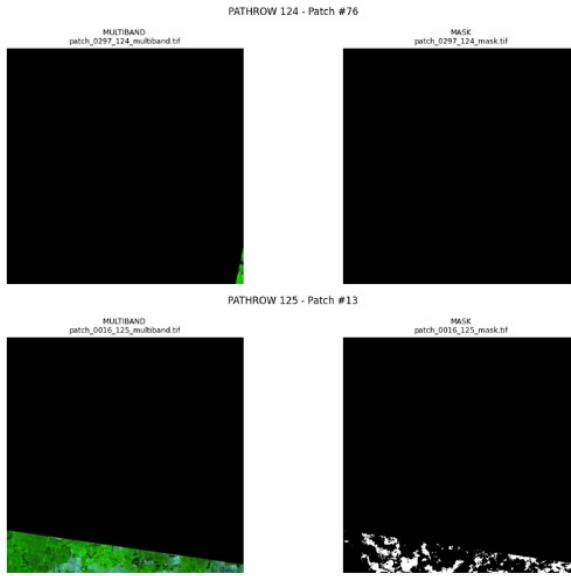
Proses *band stacking* ini memungkinkan model untuk memanfaatkan tidak hanya nilai reflektansi mentah dari kanal Landsat, tetapi juga informasi indeks vegetasi yang telah diperoleh sebelumnya. Hal ini memperkuat kemampuan model dalam membedakan antara area vegetasi sehat, area terbakar, dan area terbuka dengan akurasi spasial yang lebih baik.

4.6 *Split Data*

Tahapan sebelum proses *split data* dilakukan, terlebih dahulu dilakukan pengecekan ukuran citra pada seluruh *pathrow*. Hasil pengecekan menunjukkan bahwa ukuran citra belum seragam, di mana terdapat perbedaan beberapa piksel dari citra diunduh dari *Google Earth Engine*, walaupun sudah menggunakan *filter pathrow* di library ee. Pada citra *pathrow* 124062 tercatat memiliki ukuran 7587 x 7772 piksel, sedangkan pada *pathrow* 125062 ukurannya adalah 7584 x 7774 piksel.

Untuk menyeragamkan ukuran, dilakukan proses pemotongan (*clipping*) raster menggunakan data *shapefile World Reference System-2 (WRS-2) PathRow* milik Landsat, yang disediakan oleh U.S. Geological Survey (USGS) yang merupakan batas *pathrow* resmi [40]. Setelah proses *clipping*, ukuran citra menjadi seragam, yaitu 7313×6533 piksel. Sebelum proses split data dilakukan, citra dipecah menjadi beberapa potongan (*patch*) agar dapat digunakan dalam *training* model. Proses ini disebut *image patching*, di mana citra dibagi menjadi *patch* berukuran 512×512 piksel. Proses *image patching* dilakukan dengan tumpang tindih (*overlapping*) sebesar 50%.

Namun, berdasarkan pengamatan pada salah beberapa *patch* ditunjukkan pada Gambar 4.21, terlihat bahwa beberapa *patch* citra memiliki kualitas yang tidak layak digunakan. *Patch* tersebut sebagian besar tidak memuat informasi yang relevan karena dominan area citra hanya berisi piksel hitam yang mendominasi tampilan, sehingga tidak bermanfaat untuk proses *training* model. Jika *patch* seperti ini tetap digunakan, hal tersebut dapat menurunkan kualitas dataset dan memengaruhi kinerja model.



Gambar 4.21 Sampel citra tidak layak

Untuk mengatasi hal tersebut, diterapkan proses *image filtering* guna menghapus *patch* yang tidak layak. Suatu *patch* dinilai tidak layak apabila pada seluruh band terdapat piksel dominan berwarna hitam melebihi threshold 30%. Dengan menggunakan citra *patch* pada *multiband*. *Patch* yang memenuhi kriteria ini dihapus dan tidak digunakan dalam tahap pemrosesan selanjutnya, beserta citra mask yang pasangan citra tersebut. Hasil *image patching* sebelum dilakukan *filtering* ditunjukkan pada Tabel 4.6, di mana dari dua *pathrow* (124062 dan 125062) diperoleh total 1296 *patch* citra berpasangan (citra *multiband* dan citra *mask*).

Tabel 4.6 Jumlah *patch* citra sebelum filtering

<i>pathrow</i>	Jumlah <i>patch</i>	Citra diperoleh
124062	648	
125062	648	
Total	1296	

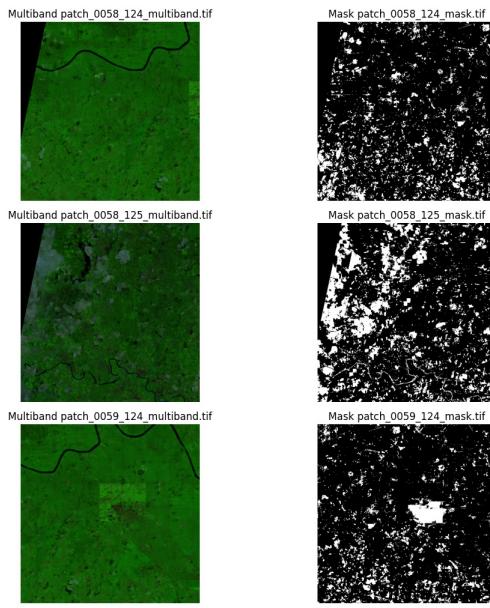
Setelah melalui proses *image filtering*, sebanyak 144 *patch* setiap *pathrow* dinyatakan tidak layak digunakan sebagaimana ditunjukkan

pada Tabel 4.7. Dengan demikian, jumlah citra layak yang digunakan dalam penelitian ini adalah 504 *patch* berpasangan setiap *pathrow* yang digunakan, dengan total *patch* sebesar 1008 pasangan (citra *multiband* dan citra mask), Citra layak ini selanjutnya digunakan pada proses *split data*.

Tabel 4.7 Jumlah data setelah *filtering*

<i>pathrow</i>	Jumlah <i>patch</i> citra tidak layak	Jumlah <i>patch</i> citra layak
124062	144	504
125062	144	504
Total	288	1008

Pada Gambar 4.22 menunjukkan beberapa pasangan citra *patch* yang layak dan bisa digunakan pada proses *split data*.



Gambar 4.22 Sampel citra layak digunakan dalam segmentasi

Citra yang telah dinyatakan layak inilah yang kemudian digunakan untuk proses *split data* menjadi tiga *subset*, yaitu data latih (*training*), data validasi (*validation*), dan data uji (*testing*). Pembagian dilakukan dengan rasio 70% untuk data latih, 15% untuk data validasi, dan 15%

untuk data uji, sehingga proporsi dataset tetap seimbang dan representatif untuk melatih sekaligus mengevaluasi kinerja model segmentasi yang dikembangkan, ditunjukkan pada Tabel 4.8.

Tabel 4.8 Rasio *split data*

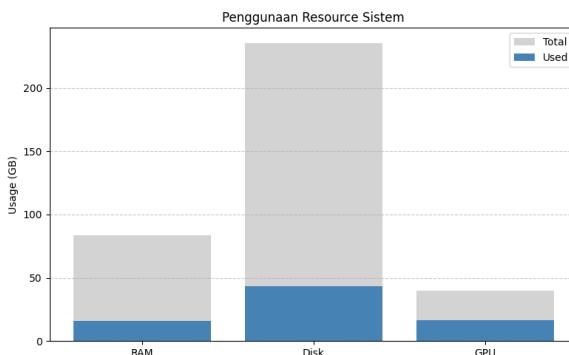
Data	Percentase	Jumlah Data
Train	70%	706
Test	15%	151
Val	15%	151
Total	100%	1008

4.7 Model U-Net

Pada tahap *training* model, data yang telah melalui proses *split data* menjadi data *training* dan *validation* digunakan sebagai inputan dalam proses *training* model U-Net. Arsitektur U-Net yang digunakan merujuk pada rancangan sebagaimana ditampilkan pada Gambar 3.3, dengan struktur simetris *encoder - decoder* yang dirancang khusus untuk segmentasi citra. Model U-Net dikompilasi menggunakan *hyperparameter* berdasarkan Tabel 3.7, berupa fungsi *loss* *binary_crossentropy* dan *optimizer* Adam dengan *learning rate* sebesar 0.0001, yang bertujuan mengoptimalkan konvergensi terhadap segmentasi biner. Proses *training* juga dilengkapi dengan dua mekanisme *callback*, yaitu *EarlyStopping* dan *ReduceLROnPlateau*, yang masing-masing berfungsi menghentikan *training* ketika tidak terjadi perbaikan pada *val_loss* setelah lima epoch berturut-turut, serta menurunkan nilai *learning rate* sebesar 50% jika tidak terjadi penurunan *val_loss* dalam tiga *epoch*. Model dilatih dengan jumlah *epoch* maksimum sebanyak 200 dan ukuran *batch size* 4. *EarlyStopping* berfungsi menghentikan *training* ketika *loss* berhenti membaik dan mencegah *overfitting* [41]. *ReduceLROnPlateau* berfungsi menjaga proses *training* tetap efektif dan memaksimalkan kinerja model dan mencegah *overfitting* [42].

Proses *training* ini dijalankan menggunakan perangkat komputasi dengan spesifikasi sebagaimana ditunjukkan pada Tabel 3.2. Waktu eksekusi *training* model tercatat selama 20 menit 21 detik. Selama

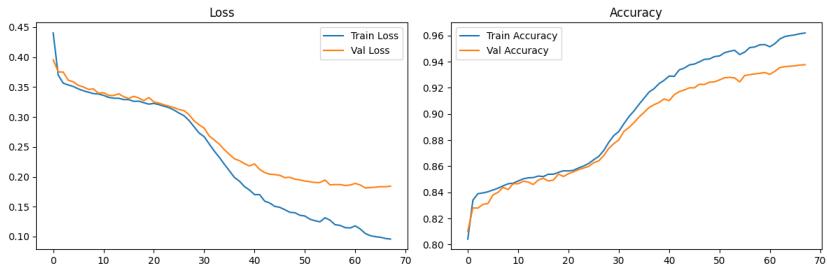
proses *training* model, penggunaan memori GPU tercatat sebesar 16.68 GB dari total kapasitas 40 GB, 16.16 GB dari total kapasitas 83.48 untuk RAM serta 43.49 GB dari total kapasitas 235.68 GB untuk Disk. Pada Gambar 4.23 menunjukkan penggunaan *resource* sistem. Hal ini menandakan bahwa model U-Net mampu beroperasi secara efisien dalam memanfaatkan kapasitas komputasi yang tersedia, tanpa mengalami kendala memori yang berarti, walaupun pada penelitian ini ukuran citra dan jumlah data dimiliki cukup besar.



Gambar 4.23 Penggunaan resource sistem

Pada Gambar 4.24 menunjukkan grafik *training loss*, *validation loss*, *training accuracy*, dan *validation accuracy* selama proses *training* menggunakan arsitektur U-Net dengan fungsi *loss binary crossentropy* dan optimasi Adam. Berdasarkan grafik tersebut, terlihat bahwa nilai loss untuk data *training* dan validasi sama-sama mengalami penurunan secara konsisten hingga epoch ke-68 dengan *learning rate* optimal sebesar 2.5×10^{-5} . Tidak terdapat lonjakan atau fluktuasi signifikan pada *validation loss*, yang mengindikasikan bahwa model mampu menjaga generalisasi dan tidak mengalami *overfitting*. Hal ini diperkuat oleh tren nilai akurasi yang meningkat secara bertahap, baik pada data *train* maupun *validation*. Nilai *validation accuracy* yang mendekati *training accuracy* menunjukkan bahwa model tidak hanya belajar pada data *training*, tetapi juga memiliki performa prediksi yang baik terhadap data yang belum pernah dilihat sebelumnya. Selain itu, penggunaan strategi *EarlyStopping* dan *ReduceLROnPlateau* juga turut berkontribusi dalam mengoptimalkan proses *training* dengan

menghindari overfitting [42].



Gambar 4.24 Grafik loss dan akurasi model

Pada Tabel 4.9 merupakan parameter model U-Net menunjukkan ringkasan struktur arsitektur model U-Net yang digunakan dalam penelitian. Parameter tersebut menunjukkan setiap *layer* berupa ukuran citra, *channel*, kernel dan *layer* yang terhubung.

Tabel 4.9 Parameter model U-Net

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 512, 512, 5)	0	-
conv2d (Conv2D)	(None, 512, 512, 64)	2,944	input_layer
conv2d_1 (Conv2D)	(None, 512, 512, 64)	36,928	conv2d
max_pooling2d (MaxPooling2D)	(None, 256, 256, 64)	0	conv2d_1
conv2d_2 (Conv2D)	(None, 256, 256, 128)	73,856	max_pooling2d
conv2d_3 (Conv2D)	(None, 256, 256, 128)	147,584	conv2d_2
max_pooling2d_1 (MaxPooling2D)	(None, 128, 128, 128)	0	conv2d_3
conv2d_4 (Conv2D)	(None, 128, 128, 256)	295,168	max_pooling2d_1
conv2d_5 (Conv2D)	(None, 128, 128, 256)	590,080	conv2d_4
max_pooling2d_2 (MaxPooling2D)	(None, 64, 64, 256)	0	conv2d_5
conv2d_6 (Conv2D)	(None, 64, 64, 512)	1,180,160	max_pooling2d_2
conv2d_7 (Conv2D)	(None, 64, 64, 512)	2,359,808	conv2d_6
max_pooling2d_3 (MaxPooling2D)	(None, 32, 32, 512)	0	conv2d_7
conv2d_8 (Conv2D)	(None, 32, 32, 1024)	4,719,616	max_pooling2d_3
conv2d_9 (Conv2D)	(None, 32, 32, 1024)	9,438,208	conv2d_8
conv2d_transpose (Conv2DTranspose)	(None, 64, 64, 512)	2,097,664	conv2d_9
concatenate (Concatenate)	(None, 64, 64, 1024)	0	conv2d_transpose, conv2d_7
conv2d_10 (Conv2D)	(None, 64, 64, 512)	4,719,104	concatenate
conv2d_11 (Conv2D)	(None, 64, 64, 512)	2,359,808	conv2d_10
conv2d_transpose_1 (Conv2DTranspose)	(None, 128, 128, 256)	524,544	conv2d_11
concatenate_1 (Concatenate)	(None, 128, 128, 512)	0	conv2d_transpose_1, conv2d_5
conv2d_12 (Conv2D)	(None, 128, 128, 256)	1,179,904	concatenate_1
conv2d_13 (Conv2D)	(None, 128, 128, 256)	590,080	conv2d_12
conv2d_transpose_2 (Conv2DTranspose)	(None, 256, 256, 128)	131,200	conv2d_13
concatenate_2 (Concatenate)	(None, 256, 256, 256)	0	conv2d_transpose_2, conv2d_3
conv2d_14 (Conv2D)	(None, 256, 256, 128)	295,040	concatenate_2
conv2d_15 (Conv2D)	(None, 256, 256, 128)	147,584	conv2d_14
conv2d_transpose_3 (Conv2DTranspose)	(None, 512, 512, 64)	32,832	conv2d_15
concatenate_3 (Concatenate)	(None, 512, 512, 128)	0	conv2d_transpose_3, conv2d_1
conv2d_16 (Conv2D)	(None, 512, 512, 64)	73,792	concatenate_3
conv2d_17 (Conv2D)	(None, 512, 512, 64)	36,928	conv2d_16
conv2d_18 (Conv2D)	(None, 512, 512, 1)	65	conv2d_17

4.8 Evaluasi Model

Evaluasi model U-Net dilakukan menggunakan empat metrik utama, yaitu *Binary Accuracy*, *Intersection over Union (IoU)*, *Dice Coefficient*, dan *Binary Cross Entropy (BCE)*. Berdasarkan hasil evaluasi yang disajikan pada Tabel 4.4, model berhasil mencapai nilai *Binary Accuracy* sebesar 0.93523, yang menunjukkan bahwa mayoritas piksel pada citra berhasil diklasifikasikan dengan benar. Nilai *Intersection over Union (IoU)* diperoleh sebesar 0.70858, mengindikasikan tingkat tumpang tindih yang baik antara area prediksi dan *ground truth* mendekati nilai 1. Selain itu, *Dice Coefficient* yang diperoleh mencapai 0.82944, memperkuat bukti bahwa segmentasi yang dilakukan model memiliki kesesuaian spasial yang sangat baik terhadap label *ground truth*. Sementara itu, nilai *Binary Cross Entropy (BCE)* yang dicapai adalah sebesar 0.18111, yang menunjukkan tingkat kesalahan prediksi yang relatif rendah selama proses evaluasi. Hasil evaluasi model ditunjukkan pada Tabel 4.10.

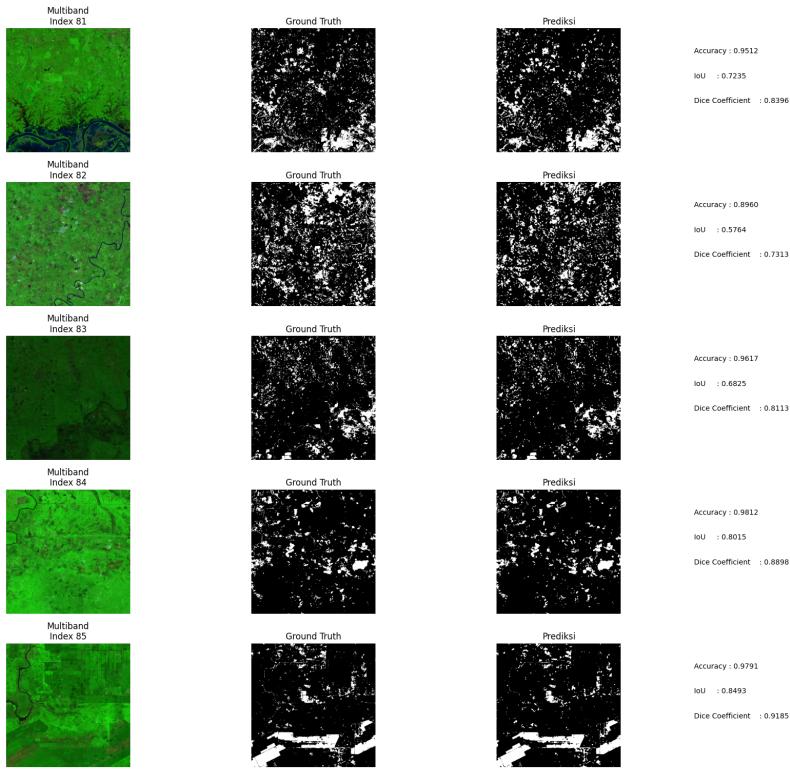
Tabel 4.10 Hasil Evaluasi Model

Evaluasi Model	Nilai
<i>Binary Accuracy</i>	0.93523
IoU	0.70858
<i>Dice Coefficient</i>	0.82944
<i>Binary Cross Entropy</i>	0.18111

Pada Gambar 4.25 merupakan visualisasi beberapa gambar hasil prediksi model yang terdiri dari citra *multiband* yang merupakan citra inputan model, pada visualisasi ini hanya menampilkan band komposit *False Color* dari 5 band yang dimiliki pada citra *multiband* tersebut yaitu NDVI dan NBR. Selanjutnya terdapat citra *ground truth* merupakan citra mask yang merupakan label dari segmentasi, terdapat prediksi, merupakan citra hasil prediksi model U-Net dalam segmentasi *burned area* di Sumatera Selatan menggunakan Citra Landsat 9 beserta dengan hasil akurasi, IoU dan *Dice Coefficient* citra. Secara umum, performa model tergolong sangat baik, yang menunjukkan bahwa sebagian besar piksel berhasil diklasifikasikan

dengan benar. Kinerja terbaik terlihat seperti pada *multiband index* 85, dengan *Binary Accuracy* 0.9791, IoU 0.8493, dan *Dice Coefficient* 0.9185, mengindikasikan segmentasi yang sangat presisi terhadap area terbakar. Demikian pula, *index* 84 juga menunjukkan performa tinggi dengan nilai *Binary Accuracy* 0.9812, IoU 0.8015 dan *Dice Coefficient* 0.8898.

Sebaliknya, prediksi pada *index* 82 menghasilkan performa terendah, dengan IoU hanya 0.5764 dan *dice coefficient* 0.7313, menunjukkan ketidaksesuaian yang lebih tinggi terhadap *ground truth*. Hal ini kemungkinan disebabkan oleh gangguan visual atau spektral seperti tutupan awan, kabut asap, atau variabilitas vegetasi yang sulit dibedakan dari area terbakar. Berdasarkan dari visualisasi hasil, prediksi model umumnya mampu merepresentasikan pola spasial kebakaran dengan baik dan mendekati *ground truth*, terutama pada area dengan tingkat kontras tinggi antara vegetasi hijau dan bekas kebakaran.



Gambar 4.25 Citra prediksi segmentasi model U-Net

4.9 Pembahasan segmentasi *burned area*

Penelitian ini mengadopsi arsitektur model U-Net yang serupa dengan pendekatan yang dikembangkan oleh Prabowo, dkk [5]. Namun, terdapat sejumlah perbedaan signifikan dalam konfigurasi input dan teknik pemrosesan data. Penelitian ini menggunakan lima kanal (band) input, yang terdiri atas tiga kanal komposit *false color*, serta dua kanal tambahan berupa indeks vegetasi *Normalized Difference Vegetation Index* (NDVI) dan indeks kebakaran *Normalized Burn Ratio* (NBR). Penambahan dua kanal ini merupakan bagian dari strategi ekstraksi fitur yang dirancang untuk memperkaya informasi spektral dari citra Landsat 9. Strategi ini secara langsung menjawab rumusan masalah pertama, yaitu mengenai bagaimana teknik ekstraksi fitur dari citra Landsat 9 diterapkan dalam segmentasi area terbakar di wilayah Sumatera Selatan.

Integrasi kanal NDVI dan NBR dalam input citra dilakukan karena kedua indeks tersebut terbukti efektif dalam mendeteksi perubahan vegetasi dan kondisi kebakaran. NDVI memberikan informasi tentang tingkat kehijauan vegetasi, sementara NBR sensitif terhadap perubahan suhu dan struktur biomassa akibat kebakaran. Dengan menggabungkan indeks-indeks ini bersama kanal spektral utama, model *deep learning* dapat belajar pola yang lebih kompleks dan kontekstual mengenai area yang terdampak kebakaran.

Dalam aspek augmentasi data, penelitian ini menerapkan skema *overlapping* secara menyeluruh pada seluruh citra *training*, berbeda dari pendekatan Prabowo, dkk [5]. Hanya menerapkan *overlapping* pada beberapa citra dan menambahkan rotasi sebagai variasi spasial. Strategi *overlapping* menyeluruh digunakan untuk mencakup variasi spasial yang luas pada wilayah yang terdampak kebakaran, terutama pada lokasi yang memiliki area terbakar dengan cakupan besar dan tidak merata.

Pelabelan *burned area* dilakukan dengan menggunakan metode *thresholding* terhadap nilai dNBR, berbeda dengan pendekatan Prabowo yang menggunakan delineasi manual oleh pakar Sistem Informasi Geografis (SIG). Pendekatan *thresholding* dipilih karena lebih efisien, konsisten, dan telah diterapkan dalam penelitian terdahulu oleh Made, dkk [7], yang menunjukkan bahwa label (*ground truth*) yang dihasilkan melalui dNBR cukup representatif untuk segmentasi area kebakaran. Dengan demikian, aspek ekstraksi fitur dan pelabelan telah mencerminkan proses awal yang kuat dalam membentuk dataset yang kaya dan informatif.

Selanjutnya, untuk menjawab rumusan masalah kedua, yaitu mengenai implementasi model U-Net dalam segmentasi area terbakar, penelitian ini membangun dan melatih arsitektur U-Net menggunakan lima kanal input yang telah dijelaskan sebelumnya. Proses *training* dilakukan dengan jumlah *epoch* sebanyak 200, menggunakan fungsi *loss Binary Cross Entropy*(BCE). Model dilatih menggunakan GPU A100 melalui platform *Google Colab Pro* untuk mengakomodasi kebutuhan

komputasi yang tinggi akibat ukuran data yang besar dan jumlah pasangan data citra serta label yang mencapai 1008 pasang. Hal ini menunjukkan bahwa implementasi U-Net dilakukan secara *end-to-end* dengan pendekatan yang sistematis, mulai dari *data preprocessing*, ekstraksi fitur, pelabelan, hingga *training* model.

Dari sisi performa, penelitian ini menunjukkan akurasi *training* sebesar 0.97 dengan nilai *loss* sebesar 0.098, menggunakan jumlah *epoch* yang sama seperti pada penelitian Prabowo, yaitu sebanyak 200. Walaupun terdapat perlakuan memanfaatkan callback seperti *early stopping* dan *ReduceLROnPlateau*. Pada hasil penelitian ini yang menunjukkan nilai *loss* sedikit lebih tinggi dibandingkan penelitian Prabowo, dkk [5] yang mencapai *loss* sebesar 0.07, nilai akurasi yang lebih tinggi menunjukkan bahwa model mampu mempelajari pola area terbakar dengan lebih optimal. Hal ini mengindikasikan bahwa kombinasi input spektral yang lebih kaya dan strategi augmentasi yang lebih luas mampu meningkatkan performa generalisasi model.

Untuk menjawab rumusan masalah ketiga, yakni evaluasi model U-Net dalam segmentasi area terbakar, penelitian ini membandingkan hasil evaluasi model terhadap penelitian sebelumnya oleh Made, dkk [7]. Evaluasi dilakukan menggunakan empat metrik utama, yaitu *Binary Accuracy*, *Intersection over Union* (IoU), *Dice Coefficient*, dan nilai *loss Binary Cross Entropy* (BCE). Hasil perbandingan ditampilkan pada Tabel 4.11.

Tabel 4.11 Perbandingan performa segmentasi model U-Net

Evaluasi Model	Hasil Penelitian Penulis	Hasil Penelitian Made, dkk. (2023)
<i>Binary Accuracy</i>	0.94	0.95
IoU	0.71	0.78
<i>Dice Coefficient</i>	0.83	0.69
<i>Binary Cross-Entropy</i>	0.18	0.14

Nilai akurasi model dalam penelitian ini mencapai 0.94, sedikit lebih rendah dibandingkan nilai 0.95 pada penelitian Made. Namun, model dalam penelitian ini menunjukkan performa yang lebih baik pada metrik *Dice Coefficient*, yaitu sebesar 0.83 dibandingkan 0.69. Hal ini

menunjukkan bahwa model mampu menghasilkan segmentasi spasial yang lebih presisi, dengan tingkat kesesuaian yang lebih tinggi antara prediksi dan label sebenarnya. Meskipun nilai IoU yang diperoleh sebesar 0.71 berada sedikit di bawah nilai 0.78 pada penelitian Made, nilai tersebut masih berada pada kategori kinerja yang baik untuk segmentasi biner.

Nilai *Binary Cross Entropy* (BCE) yang diperoleh sebesar 0.18 sedikit lebih tinggi dibandingkan nilai 0.14 dari penelitian Made. Namun, perbedaan ini tergolong kecil dan masih dalam batas toleransi yang wajar. Secara keseluruhan, model menunjukkan performa yang kompetitif, terutama pada metrik *Dice Coefficient* yang sangat relevan dalam konteks tugas segmentasi area terbakar. Hal ini menegaskan bahwa pendekatan ekstraksi fitur berbasis kanal NDVI dan NBR, ditambah dengan metode pelabelan dNBR sebagai label segementasi, memberikan kontribusi yang signifikan dalam meningkatkan akurasi segmentasi. Namun, terdapat perbedaan hasil evaluasi model tersebut didasari dari penulis hanya menggunakan cakupan di Sumatera Selatan sedangkan peneliti Made(2023) mencakup beberapa wilayah seluruh Sumatera.

Lebih lanjut, penelitian ini memiliki keunggulan dalam hal pemanfaatan citra satelit terbaru, yaitu Landsat 9, yang memiliki keunggulan spektral dan temporal untuk pemantauan permukaan lahan secara berkala. Pengambilan dan praproses data dilakukan menggunakan platform *Google Earth Engine* (GEE), yang memberikan efisiensi dalam akuisisi dan pemrosesan data skala besar. Selain itu, implementasi model *deep learning* U-Net dikombinasikan dengan fitur spasial dan spektral yang relevan telah menghasilkan model segmentasi yang dapat diandalkan untuk deteksi area kebakaran di wilayah Sumatera Selatan pada tahun 2023.

Namun demikian, penelitian ini juga menghadapi beberapa keterbatasan. Proses *training* model memerlukan sumber daya komputasi yang besar, mengingat ukuran input citra yang cukup tinggi, jumlah kanal mencapai lima, serta jumlah pasangan data yang besar.

Proses ini hanya dapat berjalan optimal dengan dukungan GPU kelas atas seperti NVIDIA A100 melalui layanan *Google Colab Pro*. Dengan mempertimbangkan seluruh aspek tersebut, dapat disimpulkan bahwa penelitian ini berhasil menjawab ketiga rumusan masalah yang diajukan. Teknik ekstraksi fitur melalui penambahan kanal NDVI dan NBR terbukti efektif, implementasi arsitektur U-Net telah dilakukan dengan baik pada data Landsat 9, dan evaluasi model menunjukkan kinerja yang kompetitif serta relevan untuk segmentasi area terbakar di Sumatera Selatan pada tahun 2023.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Pendekatan segmentasi citra berbasis model U-Net berhasil diterapkan untuk segmentasi *burned area* menggunakan citra satelit Landsat 9 di wilayah Sumatera Selatan. Proses data preprocessing yang melibatkan koreksi atmosferik (menggunakan metode *Dark Object Subtraction*), *cloud masking* berbasis QA Band, dan pembuatan komposit citra *false color* (band 7-5-4), secara signifikan meningkatkan kualitas data inputan model. Salah satu kontribusi penting dalam penelitian ini adalah penggunaan indeks vegetasi NDVI dan indeks kebakaran NBR sebagai tambahan input model, di samping citra komposit *false color*. Integrasi dua indeks spektral ini terbukti memberikan kontribusi yang signifikan dalam meningkatkan kinerja model. NDVI membantu membedakan vegetasi sehat dari lahan terbuka atau terbakar, sementara NBR sangat sensitif terhadap perubahan akibat kebakaran. Dengan menambahkan kedua indeks tersebut ke dalam citra *multiband*, model memperoleh informasi spektral yang lebih kaya, yang berdampak pada peningkatan akurasi segmentasi area terbakar.

Model U-Net yang dilatih menunjukkan performa pelatihan yang stabil, tanpa indikasi *overfitting* maupun *underfitting*. Hal ini ditunjukkan oleh penurunan konsisten nilai *loss* serta peningkatan akurasi pada data latih dan validasi. Hasil evaluasi model menunjukkan indikasi kemampuan model dalam menghasilkan segmentasi piksel yang presisi dan spasial konsisten terhadap *ground truth*, dengan *binary accuracy* sebesar 0.93523, IoU 0.70858, *dice coefficient* 0.82944 serta *binary cross entropy* 0.18111.

5.2 Saran

Penelitian segmentasi *burned area* menggunakan U-Net berbasis citra Landsat 9 di wilayah Sumatera Selatan (*pathrow* 124062 dan *pathrow* 125062) menunjukkan tantangan besar dalam hal sumber daya

komputasi. Dalam hal Ukuran data yang besar dan kompleksitas spasial memerlukan pemrosesan intensif, mendorong peneliti memanfaatkan *resource* yang besar dari sisi GPU yang tidak optimal jika dilakukan secara lokal. Oleh karena itu, ke depan disarankan untuk memanfaatkan platform berbasis *cloud* seperti Google Cloud Platform (GCP), yang menyediakan infrastruktur *big data* untuk pemrosesan paralel, serta skalabilitas tinggi.

Selain efisiensi komputasi, perluasan cakupan spasial ke seluruh wilayah Sumatera dan penggunaan rentang waktu yang lebih panjang (misalnya 2015–2025) akan meningkatkan nilai analisis temporal dan tren kebakaran. Metode yang digunakan juga dapat ditingkatkan dengan model segmentasi terkini seperti Attention U-Net, U-Net++, atau SegFormer, yang terbukti lebih akurat dan efisien dalam segmentasi citra resolusi tinggi. Pendekatan ini akan memperkuat deteksi *burned area* secara presisi dan responsif terhadap perubahan lingkungan. Pemanfaatan citra dengan resolusi lebih tinggi seperti Sentinel-2 dapat dipertimbangkan untuk meningkatkan presisi spasial segmentasi, terutama pada area heterogen.

DAFTAR PUSTAKA

- [1] Badan Nasional Penanggulangan Bencana (BNPB), *Kebakaran hutan dan lahan agustus 2023*, Diakses pada 7 Maret 2025, 2023. sumber: <https://data.bnrb.go.id/pages/kebakaran-hutan-dan-lahan-agustus-2023>.
- [2] Kementerian Lingkungan Hidup dan Kehutanan, *Menteri lhk pantau karhutla di oki*, Diakses pada 4 Juni 2025, 2023. sumber: <https://www.ditjenppi.org/indonesia/berita2/pkhl/menteri-lhk-pantau-karhutla-di-oki>.
- [3] Novitasari, H. Kaskoyo, A. Darmawan, T. Endaryanto, C. Wulandari, dan S. Bakri, “Kebijakan kelembagaan dalam tindakan mitigasi dan penanganan kebakaran hutan dan lahan di sumatera selatan”, *Jurnal Hutan Tropis*, vol. 12, no. 1, hlmn. 59–71, Mar. 2024.
- [4] U.S. Geological Survey (USGS), *Landsat 9 data users handbook*, Version 1.0, LSDS-2082, U.S. Geological Survey, Sioux Falls, South Dakota, Feb. 2022. sumber: <https://www.usgs.gov/media/files/landsat-9-data-users-handbook>.
- [5] Y. Prabowo, A. D. Sakti, K. A. Pradono, dkk., “Deep learning dataset for estimating burned areas: Case study, indonesia”, *Data*, vol. 7, 6 Juni 2022. sumber: <https://www.mdpi.com/2306-5729/7/6/78>.
- [6] C. Muñoz-Gómez dan J. Rodrigo-Comino, “Designing a multitemporal analysis of land use changes and vegetation indices to assess the impacts of severe forest fires before applying control measures”, *Forests*, vol. 15, no. 2036, 2024. sumber: <https://doi.org/10.3390/f15112036>.
- [7] I. M. Murwantara, M. A. Witarsah, dan R. Hudi, “U-net wildfire classification in sumatra island based on sentinel-2 and landsat-8 satellite images”, di dalam *Proceedings - International Conference on Smart-Green Technology in Electrical and Information Systems, ICSGTEIS*, Institute of Electrical and

- Electronics Engineers Inc., 2023, hlmn. 59–64. sumber: <https://ieeexplore.ieee.org/document/10424373>.
- [8] A. Rasul, G. R. F. Ibrahim, H. M. Hameed, dan K. Tansey, “A trend of increasing burned areas in iraq from 2001 to 2019”, *Environment, Development and Sustainability*, vol. 23, hlmn. 5739–5755, 2021. sumber: <https://doi.org/10.1007/s10668-020-00842-7>.
 - [9] MetroTV News. “2.948 hektare lahan di sumsel terbakar dalam kurun waktu delapan bulan”. (2024), sumber: <https://www.metrotvnews.com/read/b1oC9ved-2-948-hektare-lahan-di-sumsel-terbakar-dalam-kurun-waktu-delapan-bulan>.
 - [10] Q. Zhang, D. Wang, D. Fu, F. Gong, X. He, dan Y. Wang, “Characterization of landsat-8 and landsat-9 reflectivity and ndvi continuity based on google earth engine”, *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, hlmn. 621–638, 2025. sumber: <https://ieeexplore.ieee.org/document/10745744>.
 - [11] NASA/Goddard Space Flight Center, Landsat Science, *Landsat-9 stills cover 3*, <https://landsat.gsfc.nasa.gov/wp-content/uploads/2023/09/L9-Stills-Cover-3.png>, 2023.
 - [12] C. T. Pinto, X. Jing, dan L. Leigh, “Evaluation analysis of landsat level-1 and level-2 data products using in situ measurements”, *Remote Sensing*, vol. 12, 16 Agt. 2020. sumber: <https://www.mdpi.com/2072-4292/12/16/2597>.
 - [13] United Nations Office for Outer Space Affairs, *Top of the atmosphere (toa)*, 2025. sumber: <https://www.un-spider.org/node/10958>.
 - [14] S. Nair, S. Sharifzadeh, dan V. Palade, “Farmland segmentation in landsat 8 satellite images using deep learning and conditional generative adversarial networks”, *Remote Sensing*, vol. 16, 5 Mar. 2024. sumber: <https://www.mdpi.com/2072-4292/16/5/823>.
 - [15] P. Liu, W. Zhuang, W. Kou, L. Wang, Q. Wang, dan Z. Deng, “Fire severity outperforms remote sensing indices in exploring post-fire vegetation recovery dynamics in complex plateau

- mountainous regions”, *Forests*, vol. 16, hlmn. 263, 2 Feb. 2025. sumber: <https://www.mdpi.com/1999-4907/16/2/263>.
- [16] N. Zrira, A. Jimi, M. D. Nardo, I. Elafi, M. Gallab, dan R. C. E. Ouazzani, “Gcbam-unet: Sun glare segmentation using convolutional block attention module”, *Applied System Innovation*, vol. 7, 6 Des. 2024. sumber: <https://www.mdpi.com/2571-5577/7/6/128>.
- [17] O. Ronneberger, P. Fischer, dan T. Brox, “U-net: Convolutional networks for biomedical image segmentation”, Mei 2015. sumber: <http://arxiv.org/abs/1505.04597>.
- [18] R. Azad, E. K. Aghdam, A. Rauland, dkk., “Medical image segmentation review: The success of u-net”, Nov. 2022. sumber: <http://arxiv.org/abs/2211.14830>.
- [19] L. Nieradzik, G. Scheuermann, D. Saur, dan C. Gillmann, “Effect of the output activation function on the probabilities and errors in medical image segmentation”, Sept. 2021. sumber: <http://arxiv.org/abs/2109.00903>.
- [20] M. U. Danish, M. Buwaneswaran, T. Fonseka, dan K. Grolinger, “Graph attention convolutional u-net: A semantic segmentation model for identifying flooded areas”, 2024. sumber: <https://arxiv.org/abs/2502.15907>.
- [21] J. Wu, Y. Zhang, K. Wang, dan X. Tang, “Skip connection u-net for white matter hyperintensities segmentation from mri”, *IEEE Access*, vol. 7, hlmn. 155 194–155 202, 2019. sumber: <https://ieeexplore.ieee.org/document/8877824>.
- [22] L. Knopp, M. Wieland, M. Rättich, dan S. Martinis, “A deep learning approach for burned area segmentation with sentinel-2 data”, *Remote Sensing*, vol. 12, 15 Agt. 2020.
- [23] I. Naseer, S. Akram, T. Masood, M. Rashid, dan A. Jaffar, “Lung cancer classification using modified u-net based lobe segmentation and nodule detection”, *IEEE Access*, vol. 11, hlmn. 60 279–60 291, 2023.
- [24] W. K. Baek, M. J. Lee, dan H. S. Jung, “Land cover classification from rgb and nir satellite images using modified u-net model”, *IEEE Access*, vol. 12, hlmn. 69 445–69 455, 2024.

- [25] F. Pech-May, R. Aquino-Santos, O. Alvarez-Cardenas, J. L. Arandia, dan G. Rios-Toledo, “Segmentation and visualization of flooded areas through sentinel-1 images and u-net”, *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, hlmn. 8996–9008, 2024.
- [26] Y. Zhang, F. Li, H. Xu, X. Li, dan S. Jiang, “Efficient convolutional neural networks utilizing fine-grained fast fourier transforms †”, *Electronics (Switzerland)*, vol. 13, 18 Sept. 2024. sumber: <https://www.mdpi.com/2079-9292/13/18/3765>.
- [27] A. Zhang, Z. C. Lipton, M. Li, dan A. J. Smola, *Dive into Deep Learning*, ArXiv preprint arXiv:2106.11342v4, Version 4, Juni 2021. sumber: <https://arxiv.org/abs/2106.11342v4>.
- [28] V. Vigneron, H. Maaref, dan T. Q. Syed, “A new pooling approach based on zeckendorf’s theorem for texture transfer information”, *Entropy*, vol. 23, hlmn. 1–17, 3 Mar. 2021. sumber: <https://www.mdpi.com/1099-4300/23/3/279>.
- [29] K. Machida, I. Nambu, dan Y. Wada, “Transposed convolution as alternative preprocessor for brain-computer interface using electroencephalogram”, *Applied Sciences (Switzerland)*, vol. 13, 6 Mar. 2023. sumber: <https://www.mdpi.com/2076-3417/13/6/3578>.
- [30] Z. Ji, D. Yao, R. Chen, dkk., “U-net_{ac}: A novel u-net-based model for endometrial cancer cell image segmentation”, *Information (Switzerland)*, vol. 14, 7 Juli 2023. sumber: [mdpi.com/2078-2489/14/7/366](https://www.mdpi.com/2078-2489/14/7/366).
- [31] C. I. Cira, M. Á. Manso-Callejo, N. Yokoya, T. Sălăgean, dan A. C. Badea, “Impact of tile size and tile overlap on the prediction performance of convolutional neural networks trained for road classification”, *Remote Sensing*, vol. 16, 15 Agt. 2024. sumber: <https://www.mdpi.com/2072-4292/16/15/2818>.
- [32] A. O. Amole, O. E. Ajiboye, S. Oladipo, I. K. Okakwu, I. A. Giwa, dan O. O. Olusanya, “Performance analysis of artificial intelligence models for classification of transmission line losses”, *Energies*, vol. 18, 11 Juni 2025. sumber: <https://www.mdpi.com/1996-1073/18/11/2742>.

- [33] A. Balasch, M. Beinhofer, dan G. Zauner, “The relative confusion matrix, a tool to assess classifiablility in large scale picking applications”, di dalam *2020 IEEE International Conference on Robotics and Automation (ICRA)*, 2020, hlmn. 8390–8396.
- [34] R. Niri, S. Zahia, A. Stefanelli, dkk., “Wound segmentation with u-net using a dual attention mechanism and transfer learning”, *Journal of Imaging Informatics in Medicine*, 2025. sumber: <https://link.springer.com/article/10.1007/s10278-025-01386-w>.
- [35] X. Cao, Y. Tian, Z. Yao, Y. Zhao, dan T. Zhang, “Semantic segmentation network for unstructured rural roads based on improved sppm and fused multiscale features”, *Applied Sciences (Switzerland)*, vol. 14, 19 Okt. 2024.
- [36] Badan Pusat Statistik Provinsi Sumatera Selatan, *Provinsi Sumatera Selatan Dalam Angka 2024*. Palembang: Badan Pusat Statistik Provinsi Sumatera Selatan, 2024, vol. 42, Katalog: 1102001.16. sumber: <https://sumsel.bps.go.id>.
- [37] S. H. Lee, M. H. Lee, T. H. Kang, H. R. Cho, H. S. Yun, dan S. J. Lee, “Comparative analysis of dnbr, dndvi, svm kernels, and isodata for wildfire-burned area mapping using sentinel-2 imagery”, *Remote Sensing*, vol. 17, 13 Juli 2025. sumber: <https://www.mdpi.com/2072-4292/17/13/2196>.
- [38] T. S. Le, R. Harper, dan B. Dell, *Application of remote sensing in detecting and monitoring water stress in forests*, Juli 2023. sumber: <https://www.mdpi.com/2072-4292/15/13/3360>.
- [39] U.S. Geological Survey, *Common landsat band combinations*, Accessed: 14 March 2025, 2021. sumber: <https://www.usgs.gov/media/images/common-landsat-band-combinations>.
- [40] U.S. Geological Survey, *Landsat WRS-2 Descending Path/Row Shapefile*, <https://www.usgs.gov/media/files/landsat-wrs-2-descending-path-row-shapefile>, 2023.
- [41] R. H. Hassan, M. T. Hassan, M. S. I. Sameem, dan M. A. Rafique, “Personality-aware course recommender system using deep learning for technical and vocational education and training”, *Information (Switzerland)*, vol. 15, 12 Des. 2024.

- [42] S. I. Hussain dan E. Toscano, “Optimized deep learning for mammography: Augmentation and tailored architectures”, vol. 16, 5 Mei 2025. sumber: <https://www.mdpi.com/2078-2489/16/5/359>.

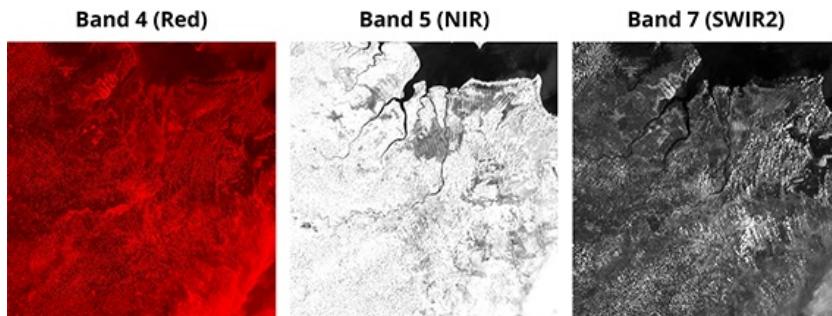
LAMPIRAN

LAMPIRAN A

Data Penelitian

A. Gambaran Data Citra (raster)

Berikut gambaran data citra Landsat 9 TOA dalam raster pada *pathrow* 124062 pada 6 November 2023, berformat geoTiff:



B. Gambaran Nilai Reflektansi Data Citra

Berikut gambaran nilai reflektansi citra Landsat 9 TOA pada *pathrow* 124062 pada 6 November 2023, hanya menampilkan sebagian nilai reflektansi dari titik tengah citra berukuran 6x6:

Nilai Reflektansi Citra Band 4

...
...	0.3569	0.1840	0.1582	0.2390	0.3758	0.4476
...	0.3497	0.1762	0.1306	0.1547	0.2417	0.2857
...	0.3896	0.2477	0.1127	0.0937	0.1208	0.1732
...	0.4353	0.2951	0.1102	0.0935	0.1256	0.2043
...	0.3735	0.2182	0.1278	0.1038	0.1241	0.2349
...	0.2730	0.1443	0.1270	0.1039	0.0887	0.1984
...

Nilai Reflektansi Citra Band 5

...
...	0.5029	0.3094	0.25	0.3488	0.4945	0.5785
...	0.4921	0.2716	0.2071	0.2359	0.3374	0.4043
...	0.5296	0.3756	0.2547	0.2229	0.2034	0.2904
...	0.5749	0.454	0.3278	0.3058	0.271	0.3491
...	0.5336	0.4155	0.3754	0.3929	0.3766	0.4142
...	0.4584	0.3863	0.3681	0.4374	0.4822	0.4589
...

Nilai Reflektansi Citra Band 7

...
...	0.2962	0.1291	0.0978	0.1958	0.3389	0.4017
...	0.2919	0.135	0.0731	0.1052	0.196	0.2601
...	0.3273	0.2049	0.0756	0.0654	0.1003	0.166
...	0.3617	0.2535	0.0894	0.0824	0.109	0.1788
...	0.3287	0.2084	0.1329	0.1076	0.1236	0.2019
...	0.2628	0.164	0.1449	0.1188	0.1013	0.1763
...

LAMPIRAN B

Perhitungan Manual Konvolusi

Konvolusi merupakan salah satu bagian terpenting dalam model U-Net baik pada proses *Downsampling*, *Bottleneck* bahkan *Upsampling*. Misalkan terdapat data input (X) berukuran matriks 5×5 dibangkitkan secara acak dan kernel W bermatriks 3×3 sebagai berikut:

$$X = \begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 3 & 1 \\ 1 & 0 & 1 & 2 & 2 \\ 2 & 1 & 0 & 1 & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix}, \quad W = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Dengan menggunakan stride bernilai 1, sehingga output konvolusi yang dihasilkan berupa matriks berukuran 3×3 sebagai berikut:

$$\text{Output} = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}$$

Operasi konvolusi dihitung per elemen dengan cara menjumlahkan hasil perkalian elemen-elemen kernel dengan elemen-elemen patch pada input citra secara berurutan. Berikut perhitungan setiap elemen-nya:

Konvolusi untuk elemen a:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 3 & 1 \\ 1 & 0 & 1 & 2 & 2 \\ 2 & 1 & 0 & 1 & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & .. & .. \\ .. & .. & .. \\ .. & .. & .. \end{bmatrix}$$

$$a = (1)(1) + (2)(0) + (3)(0) + \dots + (1)(1) = 3$$

Konvolusi untuk elemen b:

$$\begin{bmatrix} 1 & \boxed{2} & \boxed{3} & \boxed{0} & 1 \\ 0 & \boxed{1} & \boxed{2} & \boxed{3} & 1 \\ 1 & \boxed{0} & \boxed{1} & \boxed{2} & 2 \\ 2 & 1 & 0 & 1 & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & \mathbf{6} & .. \\ .. & .. & .. \\ .. & .. & .. \end{bmatrix}$$

$$b = (2)(1) + (3)(0) + (0)(0) + \dots + (2)(1) = 6$$

Konvolusi untuk elemen c:

$$\begin{bmatrix} 1 & 2 & \boxed{3} & \boxed{0} & \boxed{1} \\ 0 & 1 & \boxed{2} & \boxed{3} & \boxed{1} \\ 1 & 0 & \boxed{1} & \boxed{2} & \boxed{2} \\ 2 & 1 & 0 & 1 & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & \mathbf{8} \\ .. & .. & .. \\ .. & .. & .. \end{bmatrix}$$

$$c = (3)(1) + (0)(0) + (1)(0) + \dots + (2)(1) = 8$$

Konvolusi untuk elemen d:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ \boxed{0} & \boxed{1} & \boxed{2} & 3 & 1 \\ \boxed{1} & \boxed{0} & \boxed{1} & 2 & 2 \\ \boxed{2} & \boxed{1} & \boxed{0} & 1 & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ \mathbf{0} & \dots & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

$$d = (0)(1) + (1)(0) + (2)(0) + \dots + (0)(1) = 0$$

Konvolusi untuk elemen e:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & \boxed{1} & \boxed{2} & \boxed{3} & 1 \\ 1 & \boxed{0} & \boxed{1} & \boxed{2} & 2 \\ 2 & \boxed{1} & \boxed{0} & \boxed{1} & 1 \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ 0 & \mathbf{3} & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

$$e = (1)(1) + (2)(0) + (3)(0) + \dots + (1)(1) = 3$$

Konvolusi untuk elemen f:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & \boxed{2} & \boxed{3} & \boxed{1} \\ 1 & 0 & \boxed{1} & \boxed{2} & \boxed{2} \\ 2 & 1 & \boxed{0} & \boxed{1} & \boxed{1} \\ 1 & 2 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & \mathbf{5} \\ \dots & \dots & \dots \end{bmatrix}$$

$$f = (2)(1) + (3)(0) + (1)(0) + \dots + (1)(1) = 5$$

Konvolusi untuk elemen g:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 3 & 1 \\ \boxed{1} & \boxed{0} & \boxed{1} & 2 & 2 \\ \boxed{2} & \boxed{1} & \boxed{0} & 1 & 1 \\ \boxed{1} & \boxed{2} & \boxed{1} & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ \mathbf{3} & .. & .. \end{bmatrix}$$

$$g = (1)(1) + (0)(0) + (1)(0) + \dots + (1)(1) = 3$$

Konvolusi untuk elemen h:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 3 & 1 \\ 1 & \boxed{0} & \boxed{1} & \boxed{2} & 2 \\ 2 & \boxed{1} & \boxed{0} & \boxed{1} & 1 \\ 1 & \boxed{2} & \boxed{1} & \boxed{0} & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & \mathbf{0} & .. \end{bmatrix}$$

$$h = (0)(1) + (1)(0) + (2)(0) + \dots + (0)(1) = 0$$

Konvolusi untuk elemen i:

$$\begin{bmatrix} 1 & 2 & 3 & 0 & 1 \\ 0 & 1 & 2 & 3 & 1 \\ 1 & 0 & \boxed{1} & \boxed{2} & \boxed{2} \\ 2 & 1 & \boxed{0} & \boxed{1} & \boxed{1} \\ 1 & 2 & \boxed{1} & \boxed{0} & \boxed{0} \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & 0 & 2 \end{bmatrix}$$

$$i = (1)(1) + (2)(0) + (2)(0) + \dots + (0)(1) = 2$$

Sehingga diperoleh hasil perhitungan konvolusi dengan kernel 3x3, sebagai berikut:

$$= \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & 0 & 2 \end{bmatrix}$$

LAMPIRAN C

Perhitungan Manual Konvolusi Transpos

Konvolusi Transpos merupakan salah satu bagian terpenting dalam model U-Net pada proses *Upsampling*, yang membantu mengembalikan resolusi citra. Dimisalkan data input(X) berukuran 2×2 dan kernel (W) berukuran 2×2 , sebagai berikut:

$$X = \begin{bmatrix} 0 & 1 \\ 2 & 3 \end{bmatrix}, \quad W = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Dalam perhitungan ini, dilakukan operasi konvolusi transpos dengan *stride* sebesar 1, sehingga ukuran output yang dihasilkan adalah 3×3 . Proses konvolusi transpos berbeda dari konvolusi konvensional karena bertujuan untuk meningkatkan resolusi spasial dari data input.

Prinsip dari konvolusi transpos adalah melakukan *perkalian skalar* antara elemen-elemen X dengan kernel W , kemudian *menempatkan hasilnya secara overlap* ke dalam matriks output pada posisi yang sesuai, dan terakhir melakukan penjumlahan elemen yang bertumpang tindih. Berikut perhitungan setiap data input X dengan kernel W :

Konvolusi Transpos untuk elemen $X=0$

$$\begin{bmatrix} 0 & \dots \\ \dots & \dots \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 \times 0 & 0 \times 0 \\ 0 \times 0 & 1 \times 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Konvolusi Transpos untuk elemen $X=1$

$$\begin{bmatrix} \dots & \boxed{1} \\ \dots & \dots \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 \times 1 & 0 \times 1 \\ 0 \times 1 & 1 \times 1 \end{bmatrix} = \begin{bmatrix} 0 & \boxed{1} & 0 \\ 0 & \boxed{0} & \boxed{1} \\ 0 & 0 & 0 \end{bmatrix}$$

Konvolusi Transpos untuk elemen X=2

$$\begin{bmatrix} \dots & \dots \\ \boxed{2} & \dots \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1x2 & 0x2 \\ 0x2 & 1x2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ \boxed{2} & \boxed{0} & 0 \\ \boxed{0} & \boxed{2} & 0 \end{bmatrix}$$

Konvolusi Transpos untuk elemen X=3

$$\begin{bmatrix} \dots & \dots \\ \dots & \boxed{3} \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1x3 & 0x3 \\ 0x3 & 1x3 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & \boxed{3} & \boxed{0} \\ 0 & \boxed{0} & \boxed{3} \end{bmatrix}$$

Selanjutnya dijumlahkan semua hasil perkalian setiap elemen X dengan W, dan diperoleh hasil tranpos konvolusi 2x2 dengan output matriks berukuran 3x3 sebagai berikut:

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 \\ 2 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 3 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 2 & 3 & 1 \\ 0 & 2 & 3 \end{bmatrix}$$

LAMPIRAN D

Perhitungan Manual Fungsi Aktivasi

Pada model U-Net, terdapat fungsi aktivasi yang digunakan yaitu ReLU dan Sigmoid. Sigmoid digunakan karena menghasilkan probabilitas untuk klasifikasi biner.

A. ReLU (*Rectified Linear Unit*)

Misalkan kita menggunakan data sebagai berikut:

$$A = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & 0 & -2 \end{bmatrix}$$

Fungsi aktivasi ReLU didefinisikan dengan persamaan sebagai berikut:

$$\text{ReLU}(x) = \max(0, x)$$

Maka, penerapan fungsi ReLU pada setiap elemen matriks A adalah sebagai berikut:

$$\text{ReLU}(A) = \begin{bmatrix} \max(0, 3) & \max(0, 6) & \max(0, 8) \\ \max(0, 0) & \max(0, 3) & \max(0, 5) \\ \max(0, 3) & \max(0, 0) & \max(0, -2) \end{bmatrix}$$

$$\text{ReLU}(A) = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & 0 & 0 \end{bmatrix}$$

Catatan: Nilai ReLU tidak akan negatif, karena ReLU menghasilkan nilai nol untuk input bernilai negatif dan mempertahankan nilai input apabila bernilai positif.

B. Sigmoid

Misalkan kita menggunakan data hasil perhitungan fungsi aktivasi ReLU sebelumnya sebagai berikut:

$$A = \begin{bmatrix} 3 & 6 & 8 \\ 0 & 3 & 5 \\ 3 & 0 & 0 \end{bmatrix}$$

Fungsi aktivasi sigmoid didefinisikan dengan persamaan sebagai berikut:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Maka penerapan fungsi sigmoid pada setiap elemen matriks A adalah:

$$\sigma(A) = \begin{bmatrix} \sigma(3) & \sigma(6) & \sigma(8) \\ \sigma(0) & \sigma(3) & \sigma(5) \\ \sigma(3) & \sigma(0) & \sigma(0) \end{bmatrix} = \begin{bmatrix} \frac{1}{1+e^{-3}} & \frac{1}{1+e^{-6}} & \frac{1}{1+e^{-8}} \\ \frac{1}{1+e^0} & \frac{1}{1+e^{-3}} & \frac{1}{1+e^{-5}} \\ \frac{1}{1+e^{-3}} & \frac{1}{1+e^0} & \frac{1}{1+e^0} \end{bmatrix}$$

Dihitung secara numerik (dengan pembulatan 4 angka di belakang koma) dengan hasil sigmoid sebagai berikut:

$$\sigma(A) \approx \begin{bmatrix} 0.9526 & 0.9975 & 0.9997 \\ 0.5 & 0.9526 & 0.9933 \\ 0.9526 & 0.5 & 0.5 \end{bmatrix}$$

Catatan: Nilai sigmoid akan selalu berada di antara 0 dan 1. Nilai besar menghasilkan sigmoid mendekati 1, sedangkan nilai kecil (negatif besar) akan mendekati 0.

LAMPIRAN E

Perhitungan Manual *Max Pooling*

Max Pooling merupakan salah satu bagian proses yang terjadi dalam model U-Net pada proses *downsampling*. Perhitungan Manual *Max Pooling* (Kernel 2×2), menggunakan Stride 2), diberikan matriks input:

$$A = \begin{bmatrix} 1 & 3 & 2 & 1 \\ 4 & 6 & 5 & 2 \\ 3 & 1 & 0 & 1 \\ 2 & 4 & 1 & 3 \end{bmatrix}$$

Langkah-langkah Max Pooling dilakukan per blok:

$$\text{Blok kiri atas : } \begin{bmatrix} 1 & 3 \\ 4 & 6 \end{bmatrix} \rightarrow \text{nilai} = 6$$

$$\text{Blok kanan atas : } \begin{bmatrix} 2 & 1 \\ 5 & 2 \end{bmatrix} \rightarrow \text{nilai} = 5$$

$$\text{Blok kiri bawah : } \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix} \rightarrow \text{nilai} = 4$$

$$\text{Blok kanan bawah : } \begin{bmatrix} 0 & 1 \\ 1 & 3 \end{bmatrix} \rightarrow \text{nilai} = 3$$

Hasil dari proses perhitungan Max Pooling adalah sebagai berikut:

$$\text{Output} = \begin{bmatrix} 6 & 5 \\ 4 & 3 \end{bmatrix}$$

LAMPIRAN F

Perhitungan Manual Evaluasi model

Evaluasi model dilakukan menggunakan empat metrik umum, yaitu: *Binary Accuracy*, IoU, *Dice Coefficient*, dan *Binary Cross Entropy (BCE)*. Misalkan terdapat data prediksi dan data ground truth (*actual/label*) dalam segmentasi *burned area* dibangkitkan secara acak sebagai berikut:

$$Prediksi = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}, \quad Actual = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 1 \end{bmatrix}$$

Dari data tersebut, terlebih dahulu dicari *confusion matrix*. Misalkan telah diperoleh nilai *confusion matrix*, yang akan digunakan pada proses selanjutnya sebagai berikut:

		Prediksi	
		0 (<i>unburned</i>)	1 (<i>burned</i>)
Actual	0 (<i>unburned</i>)	TN = 5	FP = 4
	1 (<i>burned</i>)	FN = 2	TP = 14

1. *Binary Accuracy*

Binary Accuracy mengukur seberapa banyak prediksi yang benar dibandingkan total seluruh prediksi. Dihitung dengan persamaan berikut dan diperoleh hasil sebagai berikut:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{14+5}{14+5+4+2} = \frac{19}{25} = 0.76$$

2. *Intersection over Union (IoU)*

IoU mengukur tumpang tindih antara area prediksi positif dengan label positif. Dihitung dengan persamaan berikut dan diperoleh hasil sebagai berikut:

$$\text{IoU} = \frac{TP}{TP+FP+FN} = \frac{14}{14+4+2} = \frac{14}{20} = 0.70$$

3. Dice Coefficient

Dice Coefficient memberikan ukuran harmonik dari presisi dan sensitivitas. Dihitung dengan persamaan berikut dan diperoleh hasil sebagai berikut:

$$\text{Dice Coefficient} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} = \frac{2 \cdot 14}{2 \cdot 14 + 4 + 2} = \frac{28}{34} = 0.82$$

4. Binary Cross Entropy (BCE)

Binary Cross Entropy (BCE) dihitung berdasarkan probabilitas output model. Berikut adalah misalkan terdapat data dari 10 piksel beserta probabilitas dan nilai loss yang telah diketahui:

Ground truth (y_i)	Prediksi	Probabilitas (p_i)	Loss
1	1	0.95	-0.022
0	0	0.10	-0.046
0	0	0.15	-0.071
1	1	0.85	-0.071
0	0	0.05	-0.022
1	1	0.90	-0.046
1	1	0.80	-0.097
0	0	0.20	-0.097
0	0	0.20	-0.097
1	1	0.88	-0.055
1	1	0.92	-0.036
1	1	0.89	-0.051
BCE			0.05925

Nilai Loss yang telah diketahui diperoleh dari persamaan berikut:

$$BCE = -\frac{1}{N} \sum_{i=1}^N [Loss_i] \quad (\text{F.1})$$

$$BCE = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (\text{F.2})$$

Binary Cross Entropy dihitung berdasarkan persamaan. Sehingga nilai BCE pada perhitungan diperoleh yaitu sebesar 0.05925.

LAMPIRAN G

Dataset dan Prediksi Segmentasi Burned Area

Dataset patch yang telah diproses dan digunakan dalam prediksi segmentasi *burned area* menggunakan model U-Net serta hasil prediksi segmentasi *burned area* bisa dilihat pada QR code berikut:

